Infron

补充实验完成 · 按独立批次解读

INFRON RESEARCH / INFERENCE PERFORMANCE

NVIDIA DGX Spark
双节点系统与推理性能评估

Qwen3.8 Flash Next Abliterated · GB10硬件、双机系统与模型服务的分层测量

数据截止（协调世界时） 2026-10-17 08:58:45 UTC

01 · 研究背景、摘要与结论

大语言模型推理系统的性能由计算、内存数据供给、设备间协作和请求调度共同决定。单一峰值算力或单请求生成速度无法描述不同输入长度、并发和缓存条件下的服务表现。本研究以双 NVIDIA DGX Spark / GB10 为实验平台，对已接入 Infron 的 `qwen/qwen3.8-flash-next-abliterated` 开展分层性能测量，建立从硬件资源到用户响应的可追溯证据。

实验分别使用合成张量、固定长度的原生引擎请求，以及公开题库和业务文本。硬件计时、引擎阶段计时与公网响应独立统计；固定条件重复测量，数值校验、样本量及未完成范围随结果报告。方法依据NVIDIA推理指标定义与MLPerf的负载场景思想；本研究为自定义实验，不宣称标准榜单认证。 NVIDIA · MLPerf

测试领域、测试项与主要结论

下表概括本次实际测量及辅助分析。点击领域名称可查看详细结果；计算和内存带宽范围取自相同条件下两节点的中位数。题库仅作性能负载，不评价模型答案正确性。

表 01–01 测试领域、测试项与主要结论

测试领域	涵盖的测试项	主要结论与适用范围
GPU计算	通用FP32乘加；FP32 / 允许TF32 / FP16 / BF16 / FP8 / NVFP4矩阵；结构化稀疏。	8,192³稠密矩阵：BF16 94.08–94.34、FP8 191.88–192.64 TFLOP/s。速率取决于规模、数据与库路径。
内存与CPU/GPU协同	连续 / 跨步读写、随机访问、共享内存、统一内存首次访问及CPU资源竞争。	8 GiB连续复制为 223–227 GB/s（读＋写字节口径）；CPU竞争可降低GPU数据供给。不是物理DRAM事务带宽。
独立算子与执行效率	归一化、Softmax、归约、注意力；内核启动、CUDA Graphs与多执行流。	已建立逐规模耗时基线；多流配对耗时比为 0.95–1.25倍，并行收益需按具体条件判断。
双机通信与重叠	RDMA网络；NCCL聚合、收集、分发；计算与通信串行 / 重叠对照。	1 GiB AllReduce总线带宽 21.81 GB/s；完成 840次通信、120次重叠试验。本次NCCL未启用GPU直接网络访问。
引擎内部阶段	预填充（处理输入）、解码（生成输出）、排队与双节点GPU时间线。	单并发预填充 2,427–3,354词元/s；固定256输出的解码为 49.8–60.2词元/s。限于已测合成输入，计时含引擎调度。
公网服务与到达负载	六套题库共60条提示；并发1 / 2 / 4 / 8、思考档位、独立到达与达标吞吐。	短提示并发1→8：合计 45.1→158.9词元/s，正文首字95分位 1.65→2.39秒；高到达率出现排队拒绝。

测试领域	涵盖的测试项	主要结论与适用范围
输入 / 输出与业务形态	1K–256K长度设计空间；八类业务输入 / 输出比例、长上下文与实际生成量。	长输入的等待更长；长度扩展完成 290/299次，达到预设目标的最大输出为 4,096词元。256K实际输出尚未验证。
前缀缓存与保留	六档共享比例；首次 / 复用、空闲保留、竞争恢复和周期复用。	32K名义等待300秒组缓存词元比例 91.7%；8K周期复测六轮均约 100%。结论限于这些有效窗口，不代表长期命中率。
持续性能与温度	分段计算、带宽与混合负载；频率、温度、功率、自动退避及性能保持。	两节点分别完成 60 / 60 / 120分钟；混合阶段冷却占时为 16.4% / 6.0%（节点0 / 1）。退避影响墙钟吞吐；三阶段不等于连续4小时业务验证。
可观测性与瓶颈解释	客户端、引擎与节点监控；GPU阶段剖析、硬件缓存和内存计数器诊断。	已区分各层计时边界；硬件计数器仅部分可读，缺少代表性负载的物理内存流量，尚不能确定模型的唯一瓶颈。
H200技术对照	按计算、内存供给、容量、设备互联、跨节点网络和功率逐项对照。	H200标称内存带宽更高，互联与功耗边界不同。本项采用官方规格参照，未进行同模型H200实测，不给出推理加速排名。
成本与投资回报	实付API费用；双机US$10,000采购、电费、自用 / 售卖的1 / 3 / 5年回报。	短提示并发8、75%有效生产比例情景：自用回本 5.48年、五年ROI –8.7%；按参考API综合价2倍售卖，回本 2.65年。未计其他运营费。

覆盖边界：本轮执行与归档已结束。公网长度清单仍有8次未发送、1次未完整；混合干扰5组候选仅执行3组，0组满足完整配对条件。硬件、原生长输出、剖析、即时缓存复用与连续一小时窗口分别报告其已完成清单，不能据此宣称所有设想均已验证。

原生引擎固定输出补充结果：已完整验证最高 260,096词元输出。公网自然结束数据仍为独立样本，不能用原生结果替代其端到端测量。

02 · 实验对象与部署配置

模型身份与权重来源

表 02-01 模型身份与权重来源

项目	定义与本次范围
对外调用名称	qwen/qwen3.8-flash-next-abliterated
权重仓库与版本	dealignai 发布的模型权重；be794b990578ef3031eccf9f28e675a289a09ee9
基础模型与修改	作者声明基于 Qwen/Qwen3.8-Flash-Next，并进行了权重层面的去拒答修改。该来源声明不构成本报告对行为或质量变化的验证。
模型内部结构标识	Qwen4ExpForConditionalGeneration / qwen4_exp；配置文件内部类名与对外模型名称不同，按原文件保留。
文本网络结构	48 层、隐藏维度 2,560；512 个路由专家、每个 token 选择 10 个；36 层线性注意力与 12 层完整注意力。专家数不是参数量；没有经核对的总参数 / 激活参数数量。
量化范围	模型卡说明路由专家使用 NVFP4 W4A4（四位权重与激活）；注意力、共享专家及其他排除模块并非全部四位。量化器配置为 ModelOpt 0.46.0 / NVFP4。
模态与上下文	来源包含文本与视觉组件；本次仅测试文本输入与文本流输出。配置上下文上限为 262,144 token，须容纳输入和生成；该值不是已实测通过的服务边界。
来源核对边界	保存了模型卡、配置、分词器与聊天模板；节点基线加载路径指向同一仓库版本。没有重新散列全部权重分片。模型卡许可标识为 qwen-community-license-1.0。

固定版本模型配置 · 本地来源清单与散列

推理端点与数据范围速览

表 02-02 推理端点与数据范围速览

硬件参数	配置
节点与芯片	2 × NVIDIA DGX Spark / GB10 Grace Blackwell
CPU（每节点）	20 核 Arm：10 × Cortex-X925 + 10 × Cortex-A725
GPU（每节点）	Blackwell；6,144 个 CUDA 核心；第五代 Tensor Core
统一内存	每节点 128 GB LPDDR5x；双节点物理容量合计 256 GB
内存带宽（每节点）	273 GB/s；256-bit
标称计算峰值（每节点）	最高 1 PFLOP/s（FP4、稀疏计算）
网络接口	ConnectX-7：标称 200 Gb/s；以太网：10 GbE
额定功率（每节点）	GB10 热设计功耗 140 W；电源 240 W

NVIDIA 硬件规格 · NVIDIA 网络规格

表 02–03 推理端点与数据范围速览

推理端点核心参数	配置值
平台端点	POST `https://api.example.invalid/v1/chat/completions`
模型与路由	`qwen/qwen3.8-flash-next-abliterated`；`infron/cn`；跨供应商回退关闭
引擎与并行	SGLang 0.5.21；双节点、两路张量并行
量化与加载精度	NVFP4 / `modelopt_fp4`；`dtype=auto`；`kv_cache_dtype=auto`
计算后端	注意力：FlashInfer；混合专家：FlashInfer CUTLASS
上下文与预填充分块	上下文上限 262,144 词元（输入 + 输出）；分块 8,192 词元
运行槽位与内存分配	最大运行请求数 48；静态内存分配比例 0.75
多词元预测（MTP）	开启；EAGLE 路径；预测步数 3、分支数 1、草稿词元数 4
前缀缓存与调度	RadixCache 开启；计算与调度重叠开启
测试请求参数	温度 0；流式输出；思考预算 none / low；客户端并发 1 / 2 / 4 / 8

节点配置记录

完整启动命令与解析后的参数见附录C。

实验材料与范围摘要

表 02–04 实验材料与范围摘要

材料 / 范围	本次定义
自然题库	六套公开基准，各10条，共60条独立提示；只作性能负载。
受控服务负载	输入 / 输出1K–256K设计空间、八类业务、前缀比例与保留诊断；完成量见第05节。
引擎与硬件	原生引擎231条正式请求；双节点计算、内存、算子、通信及分阶段持续负载。
对照与经济模型	H200采用官方规格作架构参照；采购、电价与利用率用于成本情景。

03 · 实验设计、材料与工作负载

系统性能由计算、数据供给、跨设备协作与请求调度共同决定。本方案设置四个测量层级：硬件微基准、独立算子、双机系统、端到端模型服务。每一层固定自己的工作量与计时边界，再利用匹配条件建立解释链。硬件实验使用合成张量；公开题集只用于服务工作负载。算子数值校验属于实现正确性检查，与模型答案评分无关。

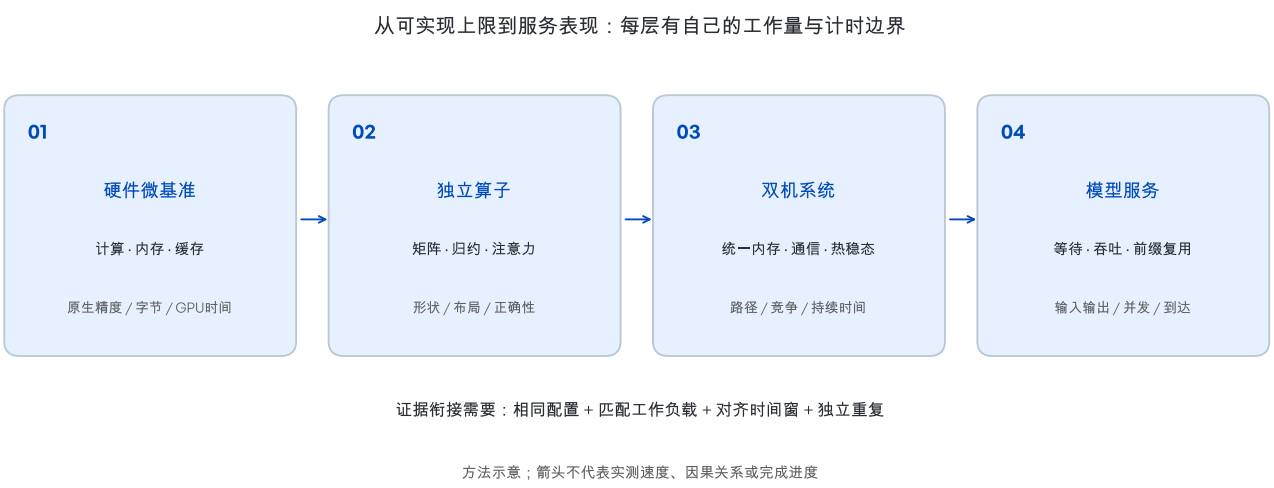


图 03-01 研究层级与证据衔接

示意图。箭头表示解释依赖，不表示已经完成的测试或可直接相减的耗时。

表 03-01 实验设计、材料与工作负载

层级	测量边界	可回答的范围
GPU硬件	设备端运算与内存访问	特定精度、规模与状态下的可实现上限
独立算子	数据准备、内核执行、同步分别计时	实现效率、形状敏感性与数据搬运代价
双机系统	CPU/GPU协同、集合通信与持续负载	资源竞争、通信代价及性能保持
模型服务	客户端经Infron至双节点再返回响应	真实路径的等待、吞吐、缓存与费用

GB10采用共享LPDDR5X统一内存；128GB不等于GPU独占可分配容量，双机256GB也不是单个共享地址池。273GB/s是每节点标称内存带宽；1PFLOP/s是稀疏FP4规格。效率比较必须匹配精度、稀疏性、频率和数据流量口径。GPU的L1/L2缓存以字节访问计数；推理前缀缓存以输入词元复用计数，两者分别统计。 NVIDIA

理解硬件结果所需的概念

表 03-02 理解硬件结果所需的概念

概念	定义与测量意义
CUDA核心与Tensor Core	前者执行通用并行运算，后者加速特定矩阵乘加。FP32 / FP16 / FP8 / FP4分别描述数值格式；位数较少不等于任意任务必然更快。
矩阵乘法与M、N、K	GEMM指通用矩阵乘法。A为M×K、B为K×N，输出为M×N。矩阵形状改变并行度与数据复用，须与精度一起报告。
GPU内核与CUDA Graphs	内核是一次在GPU执行的程序；执行流组织有序任务。CUDA Graphs复用事先记录的任务依赖，可能减少CPU重复提交开销。
L1/L2、共享内存与统一内存	L1/L2是硬件缓存；CUDA共享内存是线程块使用的片上空间；GB10统一内存是CPU/GPU共享的系统内存。三者容量、延迟和访问规则不同。
RDMA与GPU直接路径	RDMA允许网卡远程读写注册内存；GPU直接路径还需确认网卡实际访问GPU缓冲区。普通RDMA测试本身不证明GPU直接通信。
NCCL集合通信	NCCL是GPU通信库。AllReduce聚合后把结果发给各节点；AllGather收集各节点分片；ReduceScatter聚合后把不同结果分片交给各节点。

评测基准：来源、任务形式与本次用途

本次以六套公开基准构成固定题库，并用长度、业务和缓存负载补充系统压力条件。公开基准原本用于评价模型回答；本研究使用其中的题目作为可重复的请求输入，记录等待时间、实际生成量、吞吐与节点资源。基准名称标识输入来源，不代表本次执行了该基准的完整能力评测。

表 03-03 评测基准：来源、任务形式与本次用途

基准与原始用途	本次输入构造与性能用途	实际选中任务示例
MMLU-Pro 跨学科知识与推理选择题，原始测试集覆盖 14 个学科；通常按选项正确率评价。	使用问题及原始选项，去除少样本解题示范。提供含专业术语和选项列表的短输入。	直流电机需要哪种绕组；从给定选项中选择。 mmlu_11888
MATH-500 由 MATH 基准选取的 500 道数学题，涵盖代数、几何、数论等；原任务评估数学答案正确性。	保留题干和数学表达式，要求把最终答案放入 \boxed{}。用于观察数学文本生成时的长度与等待。	求一个绝对值不等式的整数解个数。 math_386
GSM8K 小学数学应用题，通常需多步四则运算；原任务核对最终数值答案。使用 main/test 分割。	保留应用题，要求写出解答并以 #### 标记最终数值。提供自然语言叙述与运算步骤混合的负载。	根据三人的年龄倍数关系计算其中一人的年龄。 gsm_1104
IFEval 指令遵循评测，使用可程序检查的语言、格式、字数或关键词约束；原任务检查这些约束是否满足。	直接使用原始指令，保留其中的语言与格式约束。观察受约束请求的响应形态和实际生成量。	仅用波斯语写一首关于尤达进入另一宇宙的诗。 ifeval_1477
HumanEval+ Python 函数级程序生成；“+”表示 EvalPlus 扩充了正确性测试输入。原任务通过执行测试检验程序。	保留函数签名、说明和题内示例，要求返回完整 Python 代码块。用于测量函数生成的流式输出。	实现 largest_divisor(n)，返回小于 n 的最大约数。 HumanEval_24
MBPP+ 基础 Python 编程任务；采用 EvalPlus 整理并扩展测试的 378 题版本。原任务检查程序功能正确性。	保留任务描述及题内断言示例，要求返回完整 Python 代码块。提供较短的代码生成输入。	实现返回两个数中较小值的函数，并满足题内断言。 Mbpp_404

示例是已选任务的简短转述；发送时使用固定题库中的原始提示。参考解答和隐藏测试不加入请求，题目自带的示例或断言保留。HumanEval+、MBPP+ 的扩展测试未执行，“+”不会在本次转化为更多生成请求；不计算准确率、指令通过率或代码测试通过率。

数据版本、样本规模与长度分布

“来源规模”指本次读取的固定版本或测试分割，“候选数”指参与抽样的题目数，“选用数”指最终独立提示数。词元是分词器的计数单位，不等同于单词或汉字。下表长度按本模型分词器计算，仅计提示正文；实际接口输入还包含聊天模板和角色标记。

表 03-04 数据版本、样本规模与长度分布

固定数据来源与版本	来源规模 → 候选数 → 选用数	正文词元：最短 / 中位 / 最长
MMLU-Pro 版本：b189ec765aa7	12,032 → 1,400 → 10	70 / 166 / 386
MATH-500 版本：6e4ed1a2a79a	500 → 500 → 10	36 / 64 / 188
GSM8K 版本：740312add88f	1,319 → 1,319 → 10	46 / 76.5 / 112
IFEval 版本：0a1b0fe7298a	541 → 541 → 10	24 / 43.5 / 83
HumanEval+ EvalPlus 0.3.1 SHA-256: 42526ec0e7d5	164 → 164 → 10	77 / 153 / 315

固定数据来源与版本	来源规模 → 候选数 → 选用数	正文词元：最短 / 中位 / 最长
MBPP+ EvalPlus 0.3.1 SHA-256: `b54e76275524`	378 → 378 → 10	55 / 72.5 / 144

版本栏展示提交标识或数据文件 SHA-256 的前 12 位；链接指向对应来源，完整标识与本地文件散列见来源清单。EvalPlus 0.3.1 是取数工具版本，两个数据文件另以各自散列固定。

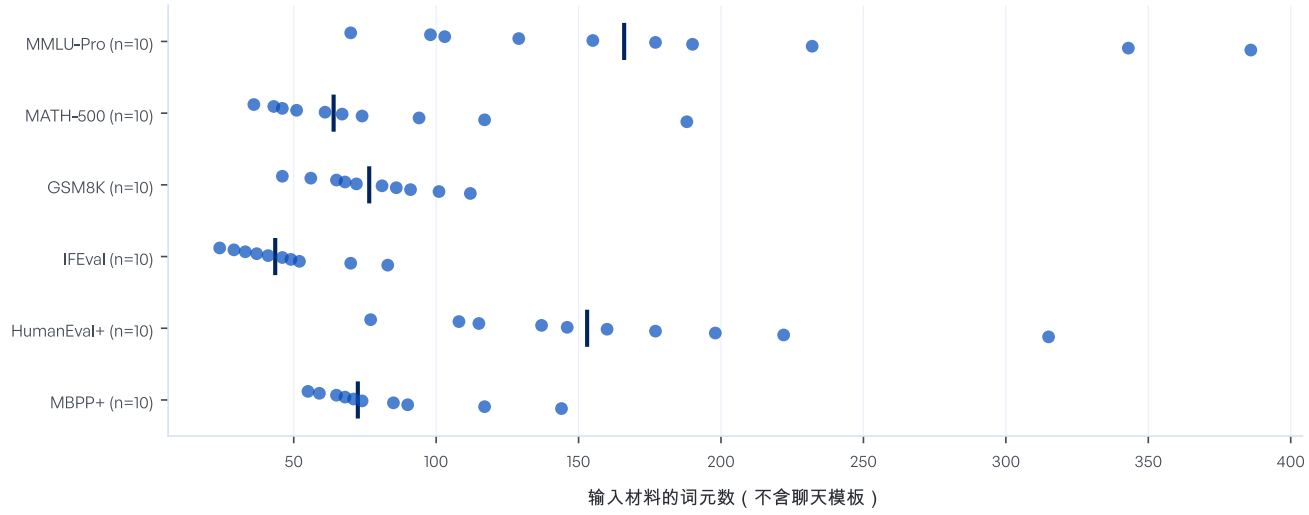


图 03-02　题库长度分布

每个点是一条固定提示，每套 10 条；竖线表示中位数。60 条正文长度合计覆盖 24–386 词元，因此这部分测量主要对应短输入，长输入性能由独立长度负载测量。

抽样方法与可比较范围

候选池共 4,302 条。MMLU-Pro 先从 12,032 道测试题中按 14 个学科各取 100 条，形成 1,400 条候选；其余五套使用表中完整版本或测试分割。随后，每套候选按提示正文词元数排序，分成十个数量尽量相等的长度层；每层按固定种子 `20261014-performance-v2` 与题目编号生成 SHA-256 排序，取最小者。最终每套 10 条，共 60 条；选择过程不使用模型输出。

最终 MMLU-Pro 样本覆盖工程、数学、物理、化学、健康、经济、计算机科学和法律八个学科，其中物理与经济各两条，其余各一条；MATH-500 样本覆盖七个原始主题中的五个。长度分层有助于保留提示长度差异，但每套 10 条不足以支持学科排名或完整题集的性能泛化。六套等量混合也不等于真实业务的流量占比。

同一组 60 条提示在并发 1 / 2 / 4 / 8 下各重复三轮，形成 720 次计划测量；低思考预算补充在并发 1 / 4 下各重复三轮，增加 360 次计划测量。这些重复用于比较性能，不增加独立题目数。自然题库输出上限为 1,024 词元，实际输出可提前结束；分题集比较时须同时查看实际输出长度和触顶比例。题目内容、输出量与缓存状态同时变化时，不能把延迟差异单独归因于题目“难度”。

固定 60 条提示 · 抽样规则 · 规模与样本核对记录

补充基准：长度、业务与缓存负载

短题库无法独立覆盖长上下文、长输出与缓存保留行为，因此另设以下受控负载。表中数量均为计划调用量，包含相应预热、校准或对照；实际完成量见第05节及结果章节。这里的 1K = 1,024 词元，输出长度参数表示生成上限。

表 03–05 补充基准：长度、业务与缓存负载

负载与材料来源	构造方式与计划规模	补充的性能范围
长度与长输出：Project Gutenberg《战争与和平》普通文本，以及本地生成的业务记录	输入与输出各设 1 / 2 / 4 / 8 / 16 / 32 / 64 / 128 / 256K 九档。81 个组合中，63 个有安全余量、1 个恰达边界、17 个越界；选取轴线、对角线及近边界条件等，共 299 次扩展调用。	区分输入处理等待与持续生成压力；同时记录输出达成率。256K 为输入与输出共享上限，不代表两者可同时达到 256K。
八类业务：本地生成的工单、订单、运维记录、代码及多轮消息	分类、改写、起草、摘要、分析、抽取、代码修改、多轮问答。每类在并发 1 / 4 下各 12 次测量＋1 次预热，共 192 次测量＋16 次预热＝208 次。	比较不同输入 / 输出比例下的响应与处理能力。材料为合成场景，场景比例不代表线上流量。
前缀比例：具有共同开头和不同后缀的合成记录	8K / 32K 输入 × 0% / 25% / 50% / 75% / 90% / 100% 共享前缀 × 6 个独立前缀对；每对预热和复测各一次，共 144 次。与业务负载合计 352 次。	目标比例控制输入的公共前缀；实际缓存命中由服务计数器核验，二者分别报告。
缓存保留与稳定性：独立生成的业务前缀与竞争请求	业务交叉 72 次、间隔保留 36 次、竞争与恢复 24 次、周期复用 28 次，共 160 次；与上述 144 次前缀比例实验分别统计。	观察空闲间隔、其他请求和重复访问后的复用变化；结合缓存计数窗口与延迟。短时诊断不等于长期稳定性证明。

长文本来源：Project Gutenberg及固定语料散列。具体长度组合、业务输入 / 输出示例、缓存间隔和并发控制见本节后文；全部代码与数据路径见附录 C。GPU 计算、内存和双机通信采用第 06–07 节的独立系统基准，与这里的模型请求题库分开统计。

模型服务实验与材料

每个测试条件固定输入、输出上限、思考档位和并发。自然题库重复三轮，长度矩阵分四个区组；请求和区组顺序按固定种子生成。基础与扩展负载均保留自然结束行为；长度达成按源站实际生成量核验，所有速度使用实际工作量。

固定并发测试在请求结束后补充新请求，用于比较处理能力；独立到达测试按预定随机时刻发起请求，用于观察排队和拒绝。两者全局在途上限均为 8。完整的执行数量、顺序和停止条件见 测试计划。

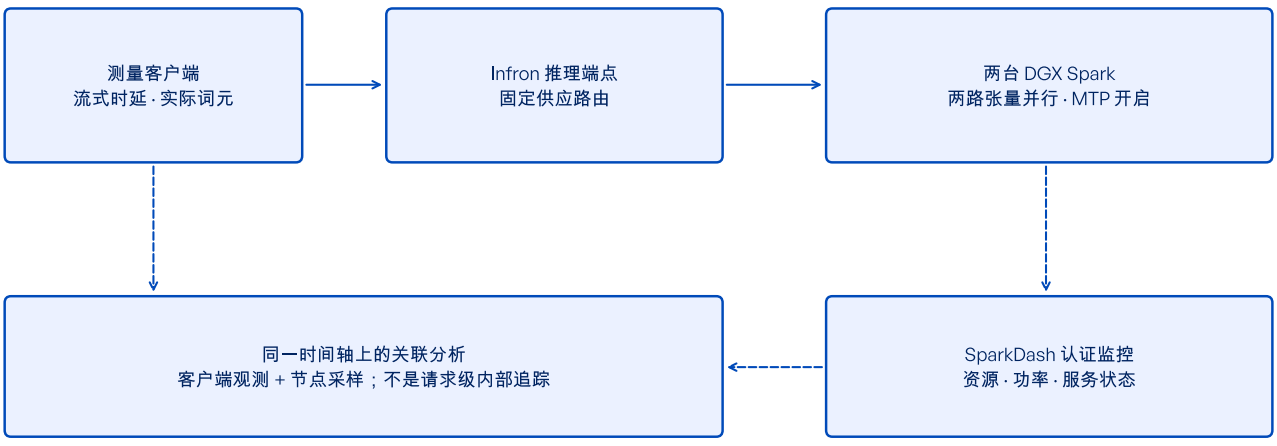


图 03–03 测量路径

客户端经 Infron 到双节点服务；监控按时间对齐。客户端延迟包含网络和服务等待。

与 SGLang、vLLM 官方评测方法的对应

实际推理引擎为 SGLang 0.5.21；vLLM 0.31.0 仅作为测量方法参照。下表区分官方工具的设计与本实验采用的规则，不构成两个引擎的性能比较。

表 03-06 与 SGLang、vLLM 官方评测方法的对应

方法依据	本实验的实现与解释
SGLang: benchmark layers	在线服务测试包含 HTTP、调度和生成。本次再包含 Infron 与公网路径；离线引擎或单批算子结果不能直接代替该服务延迟。
SGLang: sample count	官方建议请求数至少为最大并发的5倍。新增重复区组在并发1 / 4时分别用8 / 20次，重复3组；仍检查区组间变化，不仅凭样本数认定稳态。
SGLang 0.5.21: EOS · vLLM 0.31.0: EOS	两个工具的默认结束词元处理不同，显式固定参数。先比较自然结束与 ignore_eos=true，并检查转发请求和源站实际生成量；仅通过核验的固定输出进入长度受控比较。
vLLM: arrival / goodput	独立到达、客户端并发和达标吞吐分别记录。保留计划到达、实际发送、首片段和结束时间；排队与拒绝纳入用户等待及到达分母。当前采用泊松到达，突发到达作为后续扩展。
SGLang: shared prefixes	共享前缀作为可控输入；实际命中来自有效字段或隔离窗口的计数增量。自然业务与合成长输出分开，不用一种材料代表全部生成行为。

方法与源代码快照均保留版本和 SHA-256。框架命令只作为参照，本轮使用统一采集器保证同一路由、预算和证据格式。 源码及文档清单

公网长度扩展保留自然结束：校准请求的ignore_eos字段未传递到源站。输出达到上限的98%–100%仅表示该次长度达成。独立原生引擎实验使用已核验的固定输出，见第08节。 执行模式与证据

实验材料与长度构造

六套公开基准的来源、固定版本、抽样规则及 60 条提示的长度分布见本章前文。以下说明如何在这些短题目之外控制输入长度、输出上限和前缀结构。

长度控制材料为 Project Gutenberg 的《战争与和平》普通文本；按固定偏移抽取，并在开头放置不同标识，降低跨请求前缀复用。全文来源与 SHA-256 已保存；这类材料用于隔离长度因素，并不代表业务需求分布。业务扩展则使用本地生成的订单、工单、运维记录及代码，不含真实客户内容。 Project Gutenberg · 自然题目抽样清单 · 长文本来源与散列

长度覆盖：从 1K 到 256K 的可行域

1K = 1,024词元。 输入和输出分别设置1 / 2 / 4 / 8 / 16 / 32 / 64 / 128 / 256K九档。输入按完整聊天模板计数，输出是请求上限；实际生成量单独记录。当前262,144词元上下文由输入和输出共用，因此不能执行256K输入再加1K输出，也不能执行1K输入加256K输出。

81个设计格中，63格在预留1K后满足长度条件；128K＋128K只有零余量，列为边界；17格超出上下文。只挑选21个轴线 / 对角线条件执行，并增加254K→1K、1K→254K两个近边界探针。63格“长度可行”不代表网关输出上限、可用内存或时限已经验证。

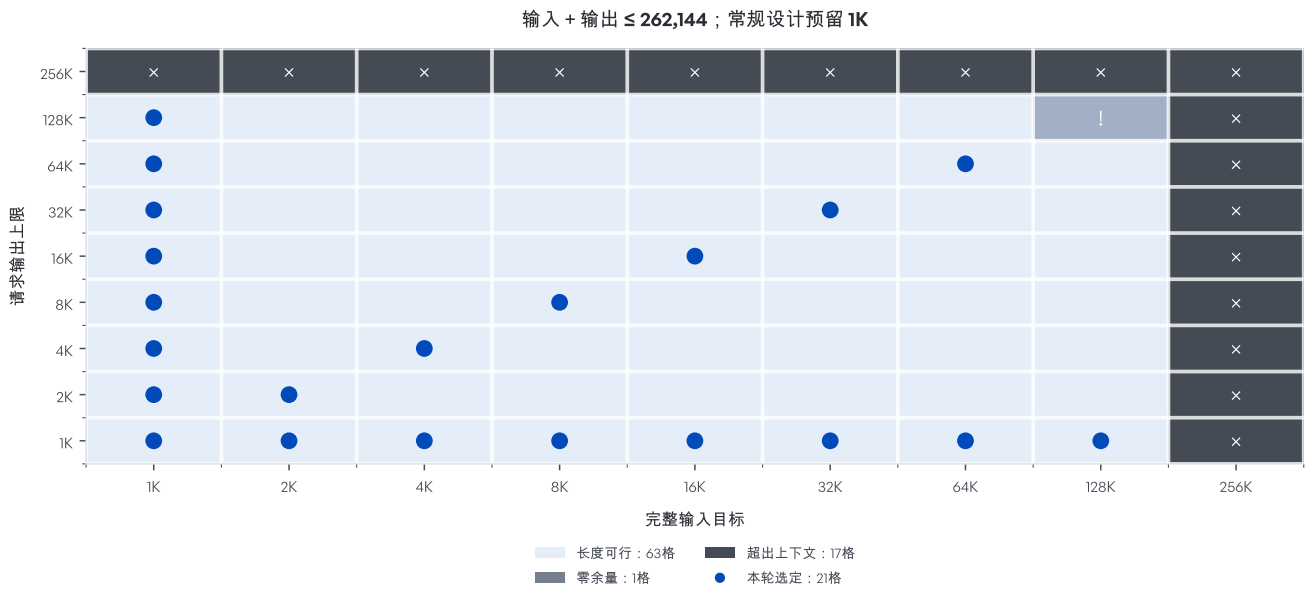


图 03-04　长度可行域

圆点表示本轮选定条件，颜色表示上下文算术约束；不表示实测完成。254K近边界探针另列。

表 03-07　长度覆盖：从 1K 到 256K 的可行域

负载组	输入→输出上限	调用数	测量目的
输入轴线	1–128K → 1K	24	保持输出上限，观察输入处理与首字等待。
输出轴线	1K → 2–128K	13	保持输入；≤8K每格3次，≥16K每格1次。
平衡长度	2 / 4 / 8 / 16 / 32 / 64K → 同档 / same	12	观察输入和生成共同增长；高档是单次探针。
近边界	254K → 1K；1K → 254K	2	每格1次，条件满足才发起；不报告尾分位。
长前缀	64 / 128K → 1K	36	0 / 50 / 100%目标重合；每格3对首次 / 复测。
业务锚点	见下表 / below	32	八类各1次预热＋3次测量，自然结束。
重复区组	1K → 4K；32K → 1K	178	并发1 / 4，每格3组×8 / 20次；另有10次预热。
参数校准	1K → 1K	2	同一短答要求分别采用自然结束与忽略结束词元。

长度扩展预先固定299次调用，按轴线、对角线与近边界组合选择；实际完成量与达成情况见第05、08节。

八类业务在长度空间中的代表点

表 03-08　八类业务在长度空间中的代表点

业务 / 长度	背景	典型输入→示意输出
批量工单分类 4K → 1K	多工单合并分流；记录变多时输出分类列表。	输入：20张工单；输出：[{id, category, reason}, …]
文档改写 4K → 4K	接近等量的信息重写，保留原文结构。	输入：运维流程；输出：客户操作指南章节。
长文起草 1K → 8K	简报扩展为手册，生成阶段占比较大。	输入：上线目标与约束；输出：准备、执行、恢复流程。

业务 / 长度	背景	典型输入→示意输出
长文摘要 32K → 1K	检索材料或日志压缩成少量结论。	输入：一个月记录；输出：关键事件与待办。
证据分析 32K → 8K	长材料加长解释，同时施加输入与生成负担。	输入：多批工单；输出：趋势、证据与替代解释。
批量字段提取 8K → 1K	文档转结构化列表；没有启用约束解码。	输入：多份订单；输出：[{order_id, amount, status}, …]
代码修改 16K → 4K	多函数上下文对应补丁与说明。	输入：账单模块；输出：幂等检查补丁及说明。
多轮助理 16K → 2K	历史消息加追问，保留多消息聊天结构。	输入：历史工单＋下一步怎么做；输出：操作建议。

以上输出是格式示意。长输出合成材料使用变化的编号、日期与业务记录，不要求分类任务产生256K答案。原有八类短负载保留为基线；新代表点与基线分组展示，不混合成一个业务平均分。

进入条件与解释边界

固定长度模式先核验转发的 ignore_eos=true 和 max_tokens，并要求源站实际生成达到上限的98%—100%。长度档按递增顺序保护性执行，顺序与时间效应可能混杂；未通过固定输出校准时，未发送条件采用自然结束；上一个输出档未达长度时不升级下一档。输出上限为1K的输入轴线每格3次，≥16K输出探针每格仅1次，不能据此给出稳定吞吐或95 / 99分位。代表区组通过完整性、实际长度与计数检查后才比较吞吐。

发送前检查完整输入＋输出上限≤262,144，以及并发×单请求预算≤262,144的保守占用包络；后者是本实验保护规则，不是引擎KV容量测量。时间准入按每请求120秒＋输出上限×0.08秒＋输入 / 300秒估算，区组结束再留300秒排空；0.08秒只是准入假设。保留原监控与费用保护，实际提前结束和未执行原因均记录。长前缀首次 / 复测分别采集隔离计数窗口，每格仅3对，不能证明长期保留。

八类业务的短负载基线

输入 / 输出比例先定义为“目标输入 token 数 ÷ 输出 token 上限”。它控制实验形状，但实际生成会提前结束；结果另报实际输入 / 实际输出比例。每类在并发 1 和 4 下各安排 12 次测量与 1 次预热，合计 208 次。每个条件分成 3 个区组，每组 4 次，区组顺序固定随机化。并发对照使用同一批材料，开头加入不同标识以减少跨条件前缀复用；样本量只支持诊断，不用于稳定的尾分位估计。

表 03–09 八类业务的短负载基线

场景	输入目标 → 输出上限	名义比例	背景与解释
工单分类	512 → 64	8:1	短问短答，模拟自动分流；关注等待而非长生成。
等量改写	2,048 → 2,048	1:1	输入输出规模接近，模拟文案重写；观察解码占用。
短提示长生成	512 → 2,048	0.25:1	少量要求生成长文，模拟内容起草；观察长输出成本。
长文档摘要	32,768 → 128	256:1	长材料压缩成短摘要；关注预填充与首片段等待。
长文档分析	32,768 → 2,048	16:1	长输入结合长分析；观察两阶段共同压力。
结构化提取	2,048 → 128	16:1	文本到短 JSON，模拟字段抽取；未启用 JSON 模式或工具接口。
代码修改	8,192 → 512	16:1	代码上下文和局部补丁；观察中长输入后短输出。
多轮业务助理	8,192 → 512	16:1	带历史的跟进问答；使用真实多条聊天消息结构。

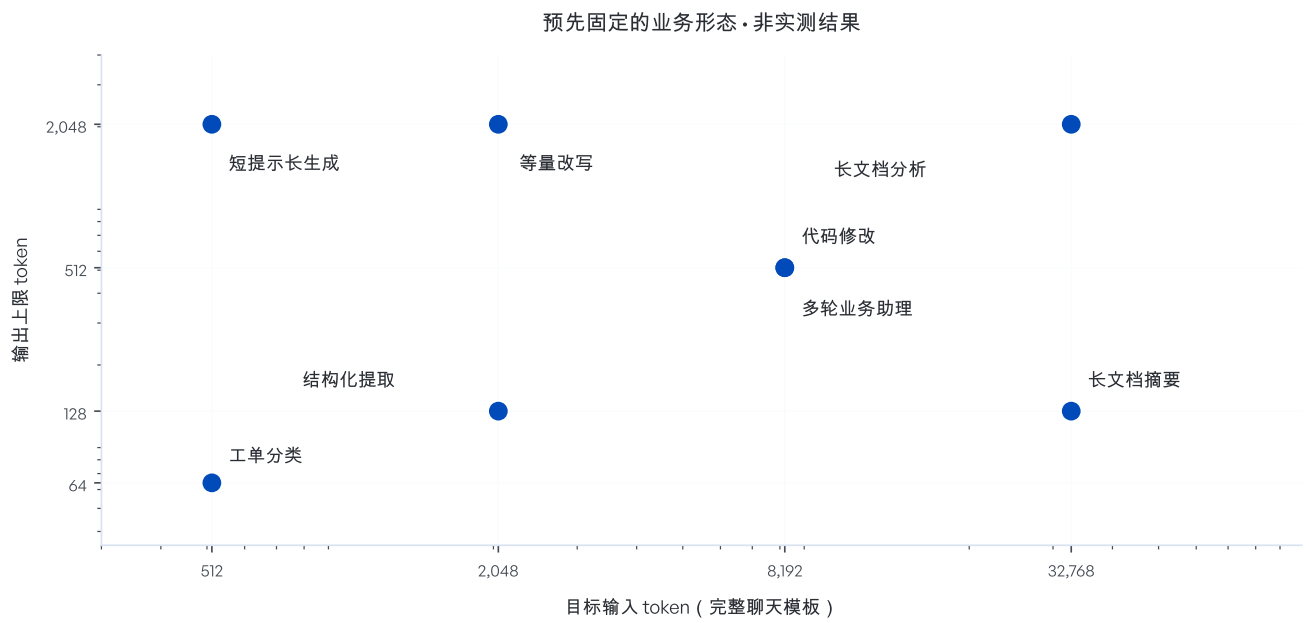


图 03–05　业务长度设计图

横轴为目标输入，纵轴为输出上限，均使用对数刻度。图中是预先固定的实验条件；实测完成后在结果部分报告实际输出。

典型输入 / 输出样例

以下均为精简的教学样例，输出为人工编写的形式示意，**不是本模型的实测回答**。实际请求包含为目标长度生成的记录；输入输出全文保留在逐请求证据中。

表 03–10　典型输入 / 输出样例

场景	典型输入（节选）	示意输出（节选）
工单分类	客户已付款，但重置访问权限失败。请分类。	{"category":"access","reason":"付款完成后仍无法访问"}
等量改写	将运维说明改写成客户操作指南，保留步骤与限制。	第一步，核对订单号；第二步，检查付款状态……
短提示长生成	基于上线简报，撰写含准备、操作和恢复流程的手册。	上线准备：确认负责人、回滚版本和告警规则……
长文档摘要	以下为长篇运营记录。用五点概括日期与未解决问题。	1. 访问恢复仍待处理；2. 已核对订单付款……
长文档分析	分析多批运营记录，列出趋势、证据、替代解释和下一步。	访问问题集中在付款后流程；需要进一步区分权限同步和客户端状态……
结构化提取	订单 INV-204，120 美元，已付款。返回四字段 JSON。	{"order_id":"INV-204","amount":120,"currency":"USD","status":"paid"}
代码修改	修改账单模块，避免超时重试重复处理同一订单。	if invoice_id in processed_ids: return existing_result
多轮业务助理	历史：客户已付款，访问重置失败。追问：运营团队下一步做什么?	先核对订单与付款状态，再检查访问权限同步并通知客户进展。

缓存比例：从可控输入到可观察命中

扩展使用 8,192 与 32,768 两档输入、0% / 25% / 50% / 75% / 90% / 100% 六档目标共享前缀，每格六个独立前缀对，共 72 对、144 次调用。每对串行执行一次预热和一次测量，输出上限均为 256，其他生成参数也相同。比例按完整聊天模板的 token 最长公共前缀精确复算；0% 仍可能共享模板头，故记录实际比例而不强行记零。

表 03–11 缓存比例：从可控输入到可观察命中

共享目标	业务背景	输入变化与示意输出
0%	互不相关的新工单	预热：工单 A；测量：不同记录 B。输出：B 的摘要。
25%	少量固定规则，多数动态材料	相同开头规则＋不同订单明细。输出：新订单处理要点。
50%	公共知识与用户上下文规模相近	相同前半部分＋新的后半部分。输出：新上下文摘要。
75%	较长固定知识材料，多条客户问询	知识主体相同，末段工单变化。输出：当前工单建议。
90%	大型公共材料，短个性化追问	保留九成前缀，替换末尾记录。输出：针对新记录的摘要。
100%	完全相同输入重复访问	完整输入相同再次请求。输出：同一材料的摘要；仍执行生成。

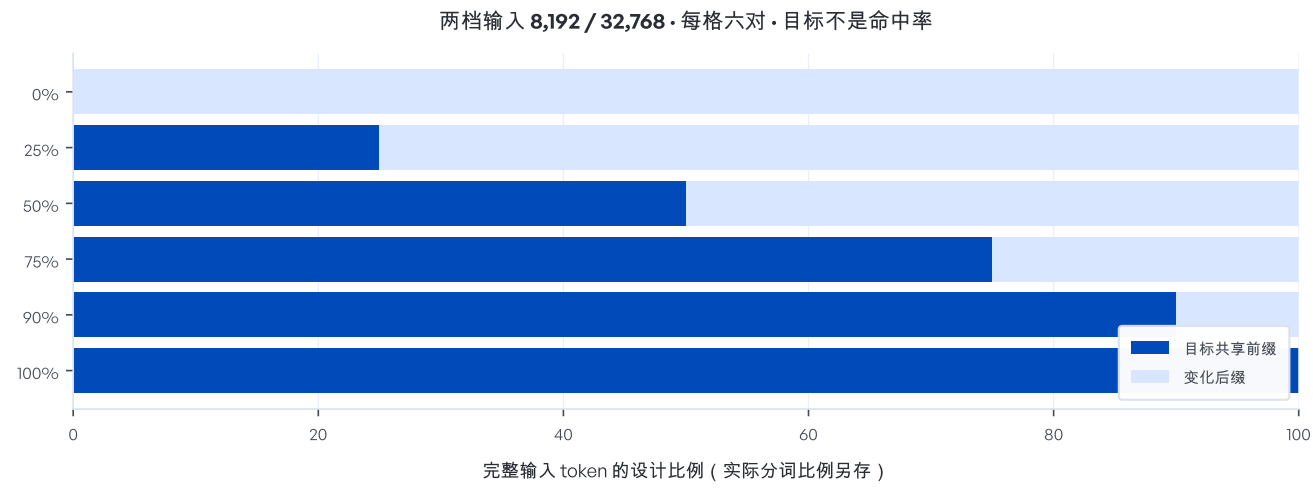


图 03–06 前缀控制图

深蓝为目标共享部分，浅蓝为变化部分；只描述输入构造，不表示已达到的缓存命中率。

共享前缀比例描述输入相似程度；实际缓存命中比例来自服务字段，字段缺失时不估算。

GPU与系统实验控制

独占窗口覆盖计算、内存、缓存、调度和独立算子；第二节点复验关键条件，双机执行集合通信。固定版本、数据类型、布局、内存状态及功耗策略；基础矩阵每格10轮；扩展矩阵一般5轮、预设关键条件10轮。普通启动与CUDA Graphs、串行与重叠、CPU内存与计算干扰采用配对条件。数值校验与性能剖析分开记录。完整条件、稳态规则及排程见测试计划第03节。

04 · 指标定义与统计方法

表 04–01 指标定义与统计方法

指标	含义与口径
正文首字延迟	从发送请求到第一个正文片段，单位秒；主要反映用户开始看到答案前的等待。
首个生成片段延迟	从发送到第一段思考、正文或工具内容；思考开启时可能早于正文。
完成时间	从发送到完整响应流结束，单位秒。
平均每词元耗时（估算）	（完成时间 − 首个生成片段延迟）÷（实际生成词元 − 1）；含流结束开销，不是逐词元间隔实测。
系统生成吞吐	同一条件全部有效区组的生成词元总数 ÷ 区组总时长，词元/s。
达标吞吐	同时满足等待和生成速度门槛的完整请求数 ÷ 测量窗口。等待从计划到达起算，包含客户端排队；拒绝保留在到达分母。
长度与缓存	分别记录输入、实际输出、输出上限、实际前缀重合及服务报告缓存量；输出上限不是输出量。
节点资源	GPU 活跃度、内存、温度、功率及运行状态按相同负载窗口统计；估算整机功率不是插座电表读数。

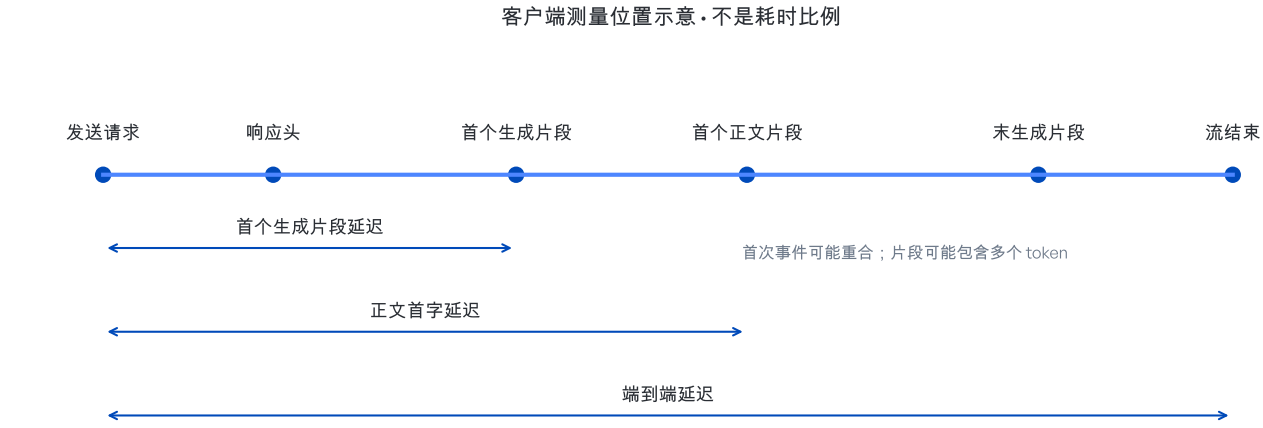


图 04–01 时间边界

首个生成片段和首个正文片段可能不同；示意距离不代表实测耗时。

中位数表示典型响应；95分位表示约95%的样本不超过该值。吞吐和延迟比较使用同一批连续完整区组，预热单列；失败记录保留在可靠性统计。每组同时给出请求数和区组数，重复同一题不增加独立题目数量。业务每格12次、缓存每格6对，只作诊断，不报告稳健99分位。

词元速度以核对后的源站生成计数为准；费用使用对应请求的实际账单。缺失计数、缓存或监控不补零。详细字段、公式和统计说明见附录A。

流式传输使用服务端发送事件（SSE）。一个事件可以包含多个词元，多词元预测时尤需注意：事件间隔反映客户端接收节奏，不能直接称为引擎逐词元延迟。长度扩展另报实际生成 / 上限的达成率、完整输入误差、长度合格数及每个区组的实际工作量。

缓存指标：输入结构、实际复用和稳定性

表 04–02 缓存指标：输入结构、实际复用和稳定性

缓存指标	定义与判定
输入前缀重合比例	完整聊天模板的最长公共词元前缀长度 / 探测输入长度。属于受控输入结构。
逐请求缓存词元比例	仅在字段有效的请求中，已缓存输入词元总数 / 输入词元总数；同时给出字段覆盖数 / 完整请求数。
有命中的请求比例	有效字段中缓存词元>0的请求数 / 有效字段请求数；模板少量命中也计入，不代表整段输入复用。
窗口缓存词元比例	同一服务窗口的累计缓存量增量 / 累计输入量增量；检查新鲜度、计数复位、服务标识及与请求计数的一致性，只取头节点一次。
配对等待收益	首次正文首字延迟−重复请求正文首字延迟，正值表示重复请求更快；另列相对变化。网络、执行顺序和负载可能共同影响，不直接称为缓存因果加速。
保留、竞争与恢复	按实际空闲间隔比较缓存比例；竞争后与立即复测相比，观察比例下降和等待增加；再次重复观察恢复。只对已施加的压力与时长成立。
时间稳定性与覆盖	报告有效窗口数 / 全部窗口数、实际跨度、词元加权平均、范围及至少3个有效窗口时的标准差；监控缺失、复位不补零或跨段相连。

GPU与系统指标的边界

计算以指定精度的运算量 / 设备时间报告；内存带宽区分有效读写字节和实际总线流量。硬件缓存的分母是访问量，前缀缓存的分母是输入词元。内核时间、CPU提交、集合通信与公网服务时间分别报告，不能跨实验相减。持续性能采用同负载预热基线；能效使用相同边界的积分能量。附录A给出公式、单位和数值校验要求。

统计以独立轮次或配对区组为单位，报告全部样本、有效分母、中位数、四分位距及95%区间；关键配对比较采用轮次成簇重采样，并给出各轮原始点。5轮扫描以描述性统计为主；10轮也不保证高精度区间。比率先在配对轮内计算再汇总。固定阶段之间随机化条件顺序，冷 / 热缓存及首次访问实验单列。短时微基准不报告服务尾延迟；少量轮次不报告稳健p99。稳态性能下降超过5%且持续两个10分钟窗口标为复核信号，结合温度、频率和负载验证，不能直接判为硬件故障。细粒度剖析有额外开销，计时结果与剖析结果分开保存。

05 · 实际覆盖与分析样本

本轮执行已结束，证据覆盖仍有明确缺口。固定实验的有效完成量、未执行条件及不完整观测分别统计；不计算一个合并全部实验的“总完成率”。完成响应不等于答案正确、达到指定输出长度或满足生产服务目标。

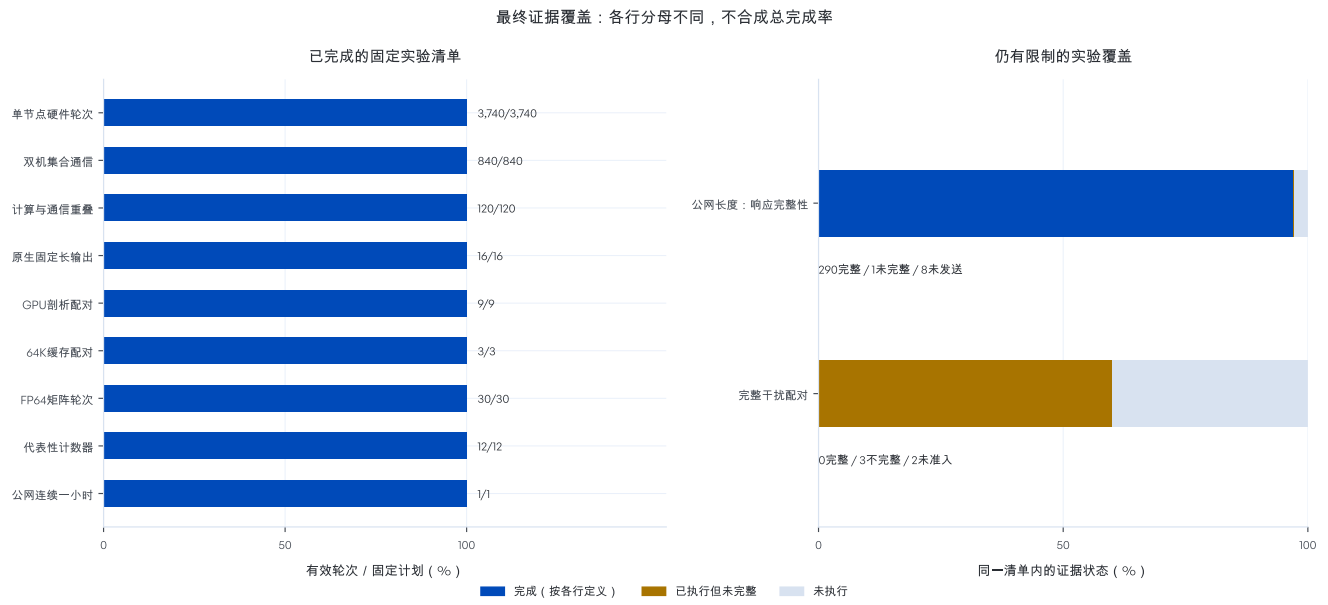


图 05–01　最终证据覆盖

左侧为已完成的固定清单；右侧分别保留公网长度缺口和不完整干扰配对。各行使用自己的样本单位与分母；公网完整响应不等于达到设定的输入与输出长度。

初始公网批次：请求结果与数量口径

表 05–01　初始公网批次：请求结果与数量口径

初始公网批次	设计数量的含义	已发送逻辑请求	完整 / 预期边界结果	未完整结果
接口与测量校准	12 (固定计划)	12	12	0
自然负载与并发扩展	720 (固定计划)	720	718	2
输入 / 输出长度矩阵	1,440 (固定计划)	1440	1435	5
思考预算配对	360 (固定计划)	360	360	0
长上下文与边界	37 (固定计划)	37	36	1
前缀缓存	90 (固定计划)	90	90	0
业务形态与缓存比例扩展	512 (固定计划)	512	507	5
开放到达与混合负载	2,000 (条件上限)	783	783	0
长度扩展与持续运行	3,000 (条件上限)	929	925	4

逻辑请求按预定样本去重，重试尝试另存；表中保留初始批次的原始结果，后续补测不回填其成功数。开放到达的2,000次与长度 / 持续阶段的3,000次为条件调用上限，不是必须发满的样本量。长度扩展本身另有299次固定清单，其未发送与未完整记录见下表；独立补测的一小时运行已结束。

硬件工作量不加入API请求分母。本批执行范围、阶段状态与受限条件见第06节；原始执行清单和状态文件保留独立记录。

独立引擎实验另计：当前归档78组、231条可分析正式请求，另有2条预检 / 剖析请求及双节点4份GPU时间线。该实验直接访问源站，不加入公网API请求及费用分母；完整定义与结果见第08节。

独立补充实验的证据覆盖

补充实验于2026年10月17日开展，状态：执行已结束，按有效覆盖交付。各批次保留各自的请求、日期和分母；以下新增结果不改写早期失败记录或原始成功率。费用没有预设金额上限，实际账单继续逐请求核对。

表 05-02 独立补充实验的证据覆盖

补充范围	已取得证据	定义
固定长输出	16 / 16	原生引擎；含1条校准，正式输出轴与等长输入输出
剖析配对	9 / 9	三种输入 / 并发，每种三轮剖析与无剖析
64K缓存	6 / 6	三个独立前缀的首次与立即复用
公网完整响应	1028	独立并发参考组、受影响条件、混合干扰及一小时运行
FP64矩阵	30 / 30	两个节点、三种规模、每格五轮
代表性计数器	12	成功返回有效字段的计算 / 访存剖析次数

未执行与结论受限的项目

表 05-03 未执行与结论受限的项目

范围	最终证据状态	结论限制
公网长度扩展	299次固定计划；291次已发送，290次完整；8次未发送、1次发送后未完整。	原生16条长输出是另一条测量路径，不能替代缺失的公网组合；自然结束也不等于达到固定输出长度。
长短请求混合干扰	5组候选中，3组已执行、2组未通过到达窗口准入；有效完整配对0组。	已执行组均有短请求本地拒绝，保留拒绝与等待观测，不给出完整配对的干扰倍数。
连续公网服务	连续3600.1秒；600次到达，599次完整，1次本地拒绝。	一小时窗口已完成，但到达成功率不是100%，也不代表全天可用性。
H200同负载对照	未执行：本轮没有H200设备。	只比较官方规格，不能报告实测推理加速比。
插座能耗	未测：没有插座电表数据。	功率传感器与持有成本情景不能替代整机实测电费。
物理DRAM流量与逐词元间隔	当前计数器 / 接口未提供所需完整观测。	逻辑字节带宽、事件片段间隔分别报告，不替代物理流量或严格逐词元时延。

06 · GPU计算、内存与算子

资源条件与比较方法。 驻留条件保留模型权重和服务进程；卸载条件在专用窗口停止双机推理进程，保持驱动、时钟策略与硬件相同。两组分别预热并执行相同基础矩阵，各自报告有效轮次。执行时间与内存状态同时变化，差值是资源条件的整体差异，不能单独证明缓存、调频或芯片机制的因果效应。

表 06-01 GPU计算、内存与算子

节点	资源条件	计划轮次	归档有效计时	内存保护跳过
0	模型驻留	1070	684	386
0	模型卸载	1070	1070	0
1	模型驻留	1070	990	80
1	模型卸载	1070	1070	0

服务恢复核验：通过；双节点启动参数、环境、工作目录及引擎核心配置与停服前一致。

本批以独立时间轮次补齐硬件证据。基础矩阵每节点107个条件、各10轮；扩展矩阵覆盖通用FP32乘加、随机指针追踪、共享内存、统一内存访问、CPU竞争、多执行流以及受支持的低精度 / 2:4稀疏矩阵计算。每次计时前后验证结果，保护跳过和不支持项不进入性能分母。原批49条有效记录保留为历史观测，不混入本批轮次。

表 06-02 GPU计算、内存与算子

节点	实验层	计划轮次	归档有效	保护跳过	不支持	失败	待完成
0	基础矩阵	1070	1070	0	0	0	0
0	扩展矩阵	800	800	0	0	0	0
1	基础矩阵	1070	1070	0	0	0	0
1	扩展矩阵	800	800	0	0	0	0

8条接口或校验边界不合格的记录单列审计，不计入性能样本及有效覆盖；原始记录与排除依据保留在分析汇总中。

指标口径。 TFLOP/s为每秒万亿次浮点运算；矩阵乘法按2MNK计数，2:4稀疏结果同时保留实际非零运算量，图中使用稠密等效口径。有效GB/s统计程序请求的读写字节，不等于DRAM物理流量。CUDA事件区间包含重复提交的主机间隙；随机指针访问的ns值也包含这一边界开销，不能解释为单条加载指令的固有延迟。统计采用各条件独立轮次的中位数和观测范围，不将循环迭代或两台设备当成大量独立设备样本。

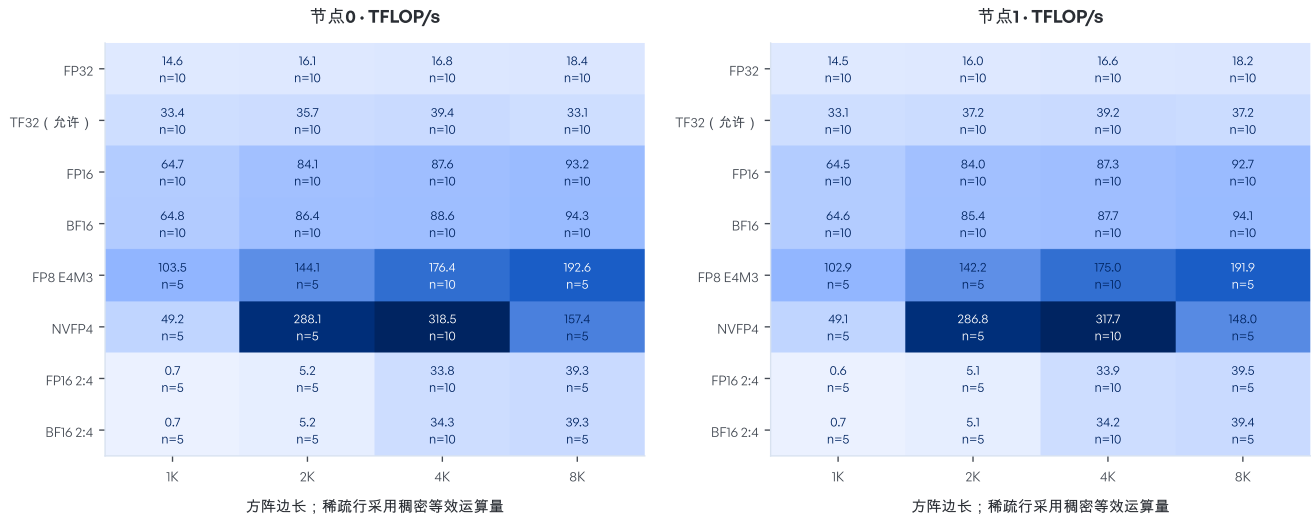


图 06–01　精度与规模

数值为实测中位TFLOP/s；空格表示没有有效归档数据。FP8、NVFP4、稀疏行采用各自明确的数据分布与库路径，不把行间差异直接归因于精度。

关键形状的逐精度、逐节点统计见附录B；本节图示保留规模趋势。

独立算子与调用边界

归约、Softmax和RMSNorm使用已安装PyTorch库；RMSNorm保留库内部输出分配。注意力使用强制Flash SDPA，BF16、16头、每头128维且不加因果掩码，分别测全长查询和单查询；这些是固定合成张量，不是该模型完整预填充或解码。1M元素加法比较普通提交与图重放，保持计算量一致。

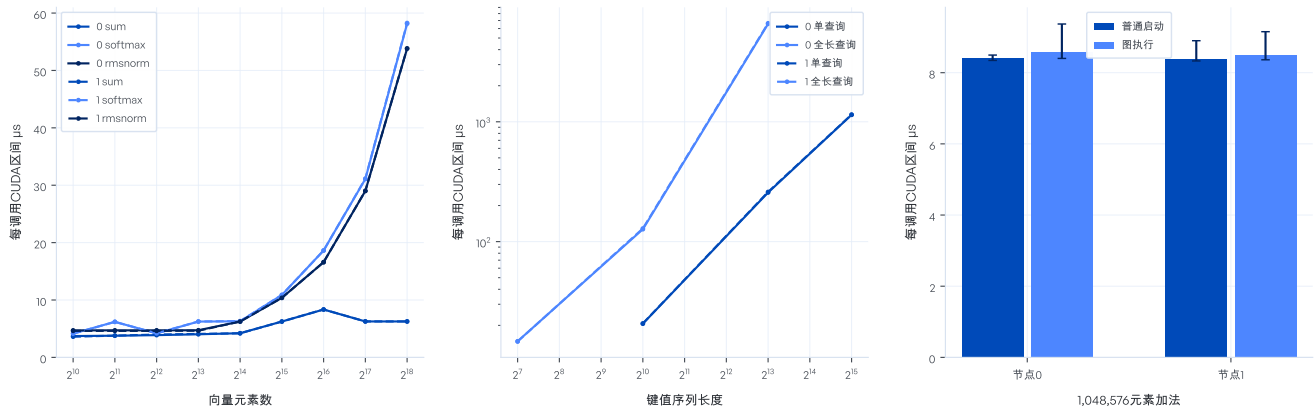


图 06–02　算子规模与启动方式

展示各条件轮次中位CUDA区间；加法误差线为观测范围。注意力纵轴为对数。

通用计算、数据供给与资源竞争

通用FP32测试以显式乘加指令比较1条依赖链与8条独立链，在相同每线程乘加数量下改变线程块和总并行量；编译汇编留档。随机指针测试让访问位置依赖上次加载结果，以128字节间距构造完整随机环，分别使用ca / cg缓存提示。共享内存改变同一线程束的地址步长。CPU竞争使用固定核心上的0 / 1 / 4 / 10 / 20个工作进程，以内存流和CPU计算作对照。多流比较保持每一串行 / 并行配对的矩阵数量相同。

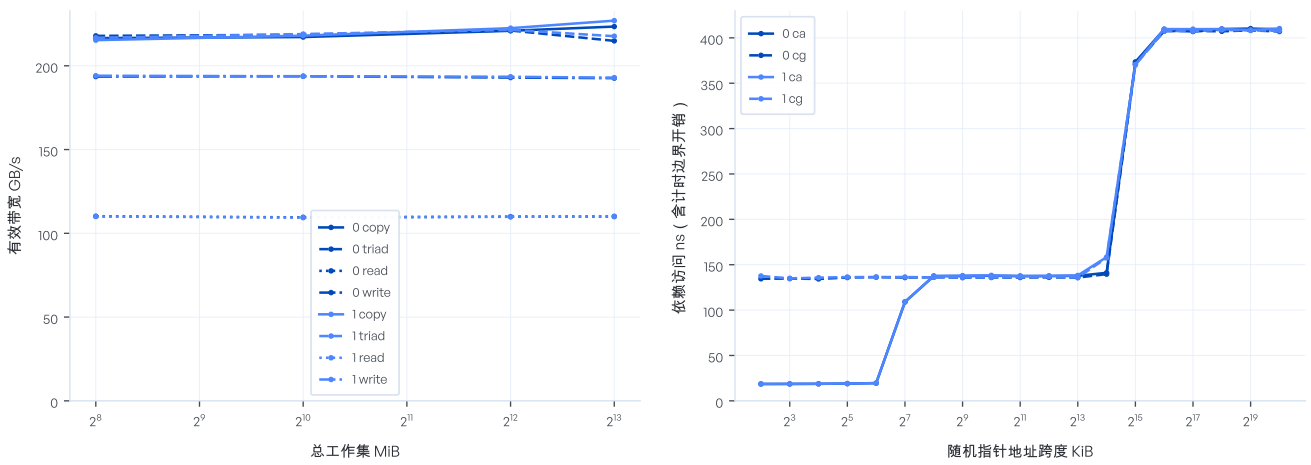


图 06–03　数据供给曲线

左图为有效读写带宽，右图为随机依赖访问时间。地址跨度不是实际DRAM事务量；曲线转折不能单独证明缓存容量或命中率。

表 06–03　通用计算、数据供给与资源竞争

实验	节点×条件	有效轮次	解释
通用FP32乘加	36	180	逐条件数据见CSV；单位和资源边界按工作负载区分
共享内存步长	12	60	逐条件数据见CSV；单位和资源边界按工作负载区分
空内核启动	4	40	逐条件数据见CSV；单位和资源边界按工作负载区分
多执行流	16	80	逐条件数据见CSV；单位和资源边界按工作负载区分
CPU资源竞争	18	90	逐条件数据见CSV；单位和资源边界按工作负载区分
管理内存首次 / 重复访问	2	10	逐条件数据见CSV；单位和资源边界按工作负载区分

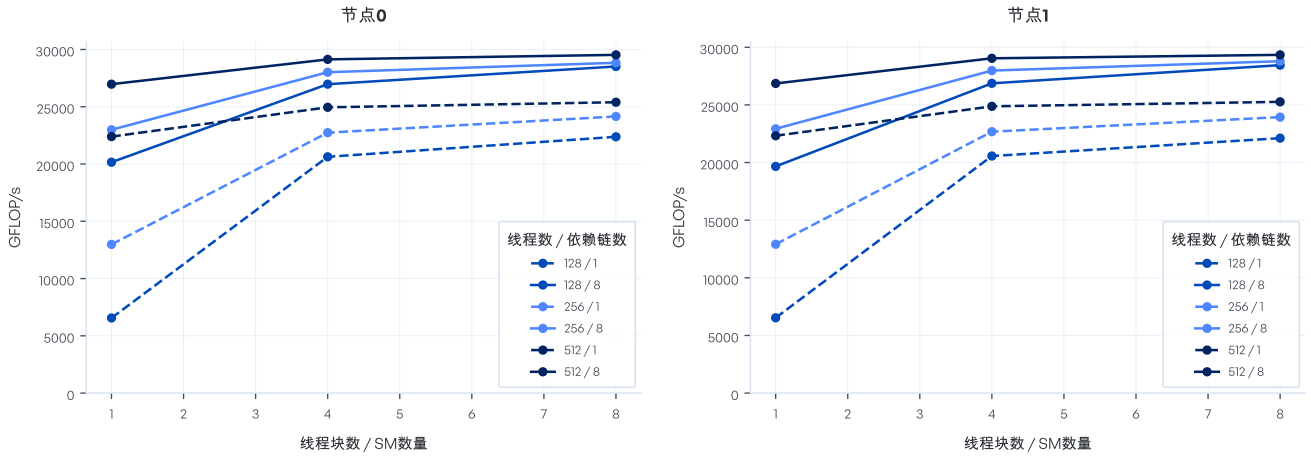


图 06–04　通用FP32并行性

固定每线程运算量，分别改变线程块大小、线程块数量与依赖链数；中位速率不代表Tensor Core峰值。

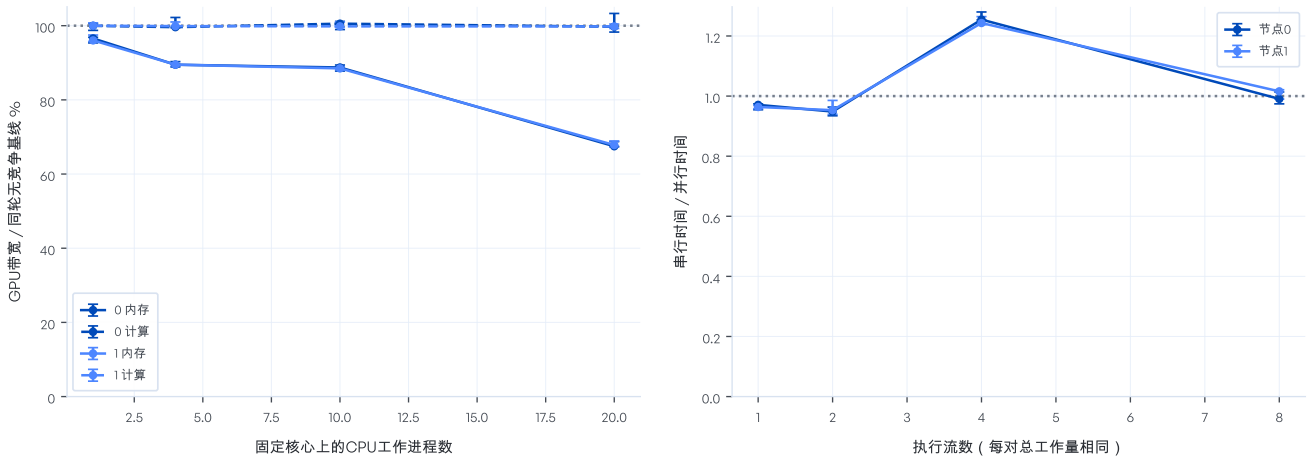


图 06–05　资源竞争与多流

左图将竞争条件除以同节点同轮的零竞争基线；右图比较同工作量的串行与多流时间。点为配对比值中位数，误差线为观测范围。

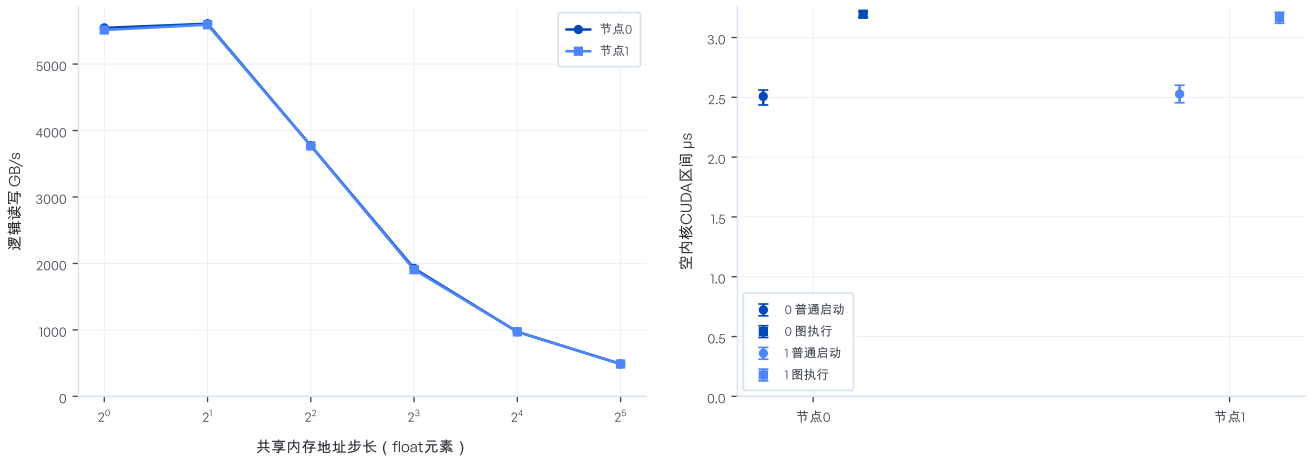


图 06–06　共享内存与启动

步长改变地址映射；没有硬件计数器时不能直接认定bank冲突次数。启动图包含主机重复提交造成的间隙，不是孤立内核的指令延迟。

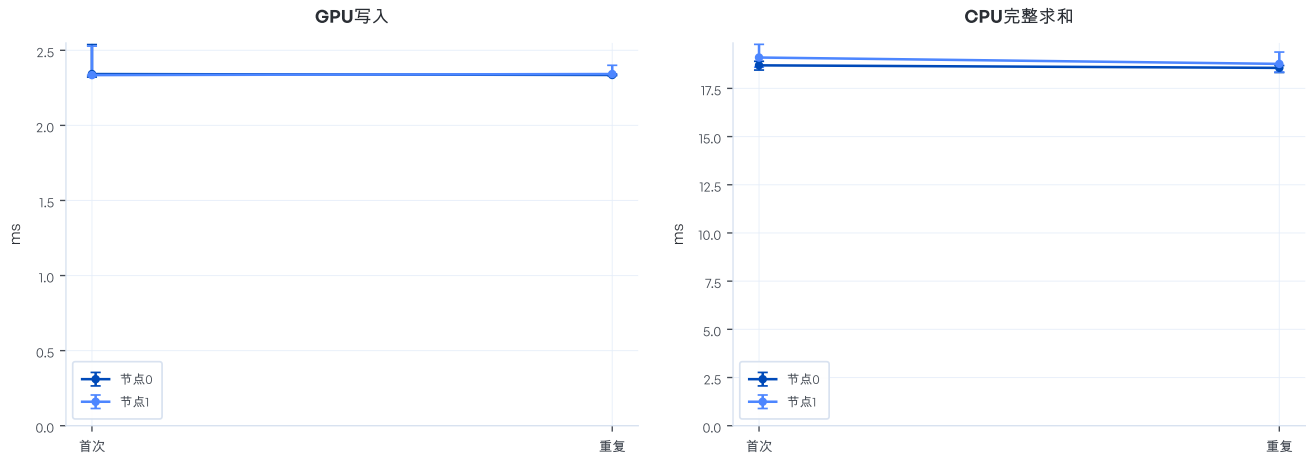


图 06-07 统一内存访问顺序

CPU初始化后，GPU写入两次，再由CPU完整求和两次。首次 / 重复在每轮同一分配内配对；CPU求和还包含归约计算，不等同数据迁移延迟。

表 06-04 通用计算、数据供给与资源竞争

节点	观察	结果	适用条件
0	通用FP32最高条件中位值	29529.7 GFLOP/s	512线程、8×SM线程块、8链；5轮
0	CPU竞争条件保持率范围	67.49—100.55%	8个条件的中位比值；逐条件范围见图
0	多流配对加速比范围	0.95—1.25×	4个条件的中位比值；逐条件范围见图
1	通用FP32最高条件中位值	29341.2 GFLOP/s	512线程、8×SM线程块、8链；5轮
1	CPU竞争条件保持率范围	67.82—100.00%	8个条件的中位比值；逐条件范围见图
1	多流配对加速比范围	0.95—1.24×	4个条件的中位比值；逐条件范围见图

NVFP4专项使用可精确表示的E2M1输入，显式固定每16元素块的幅度上限以获得单位尺度，先验证打包结果再测矩阵乘法。该控制隔离矩阵计算误差；不代表生产权重的量化误差或生产MoE内核性能。量化 / 打包和稀疏压缩耗时另外保存，内核轨迹与无剖析计时分开。计数器访问只作诊断，不改变系统权限；未取得的缓存命中率和活跃线程计数保留缺失。

表 06-05 通用计算、数据供给与资源竞争

节点	硬件计数器状态	可观测性范围
0	剖析内存分配受限	该探针单独执行通过；剖析时首次CUDA分配失败
1	探针字段部分可读	仅固定单线程块乘加；代表性矩阵与模型计数尚未测量

表 06-06 通用计算、数据供给与资源竞争

诊断计数器	节点0	节点1
活跃线程束占可持续峰值比例	不可用	16.56 %
L2扇区命中比例	不可用	83.91 %
DRAM读取字节	不可用	不可用
DRAM写入字节	不可用	不可用

上述可用数值来自服务恢复且空闲条件下的固定单线程块FP32乘加探针，只有一次成功剖析，目的为验证计数器访问。使用管理员身份调用Nsight Compute，不改变驱动权限配置，时钟控制与缓存控制均设为none。DRAM字节字段返回n/a，保留为缺失，不替换为0。该探针不代表大矩阵或模型的平均缓存命中率、物理带宽利用率及计算管线效率；共享L2等单元还可能受到其他GPU活动影响，不能用于模型Roofline归因。 NVIDIA权限说明 · Nsight Compute度量说明

本批逐条数据、条件汇总与保护状态 · 有效计时CSV。模型驻留下因内存不足跳过的条件，不能标记为芯片不支持；驻留与卸载模型后的结果按独立条件报告，不合并轮次或将差异直接归因于单个硬件机制。

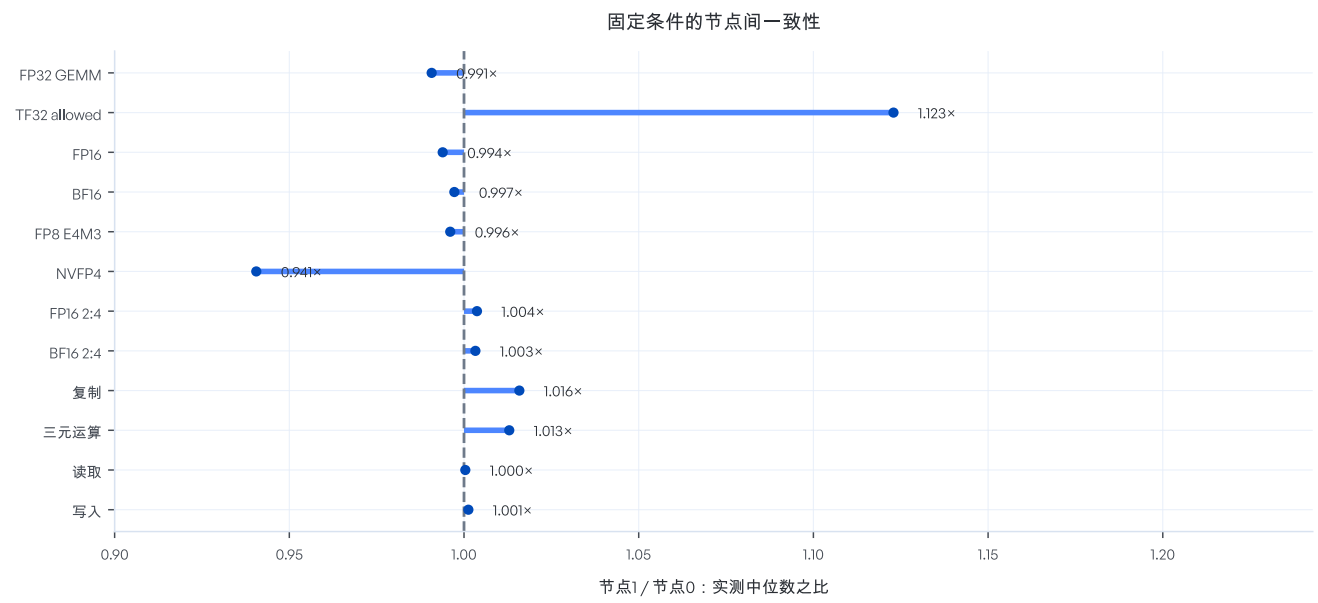


图 06-08 节点一致性

固定8192³矩阵与8 GiB访问条件下，节点1中位数 / 节点0中位数。比值用于描述两台已测设备，不能估计整个产品系列的个体差异。

FP64矩阵计算补充测量

卸载模型后运行CUDA上的双精度矩阵乘法，乘加按两次运算计数。输入为可精确表示的有符号二进制分数，每轮将九个跨行列位置与CPU双精度参考比较；下表只纳入校验通过的轮次。

表 06-07 FP64矩阵计算补充测量

节点	M=N=K	n	TFLOP/s 中位数［范围］
0	1024	5	**0.4130** [0.4107–0.4157]
0	4096	5	**0.4254** [0.4246–0.4254]
0	8192	5	**0.4280** [0.4280–0.4281]
1	1024	5	**0.4086** [0.4048–0.4097]
1	4096	5	**0.4246** [0.4246–0.4250]
1	8192	5	**0.4276** [0.4276–0.4277]

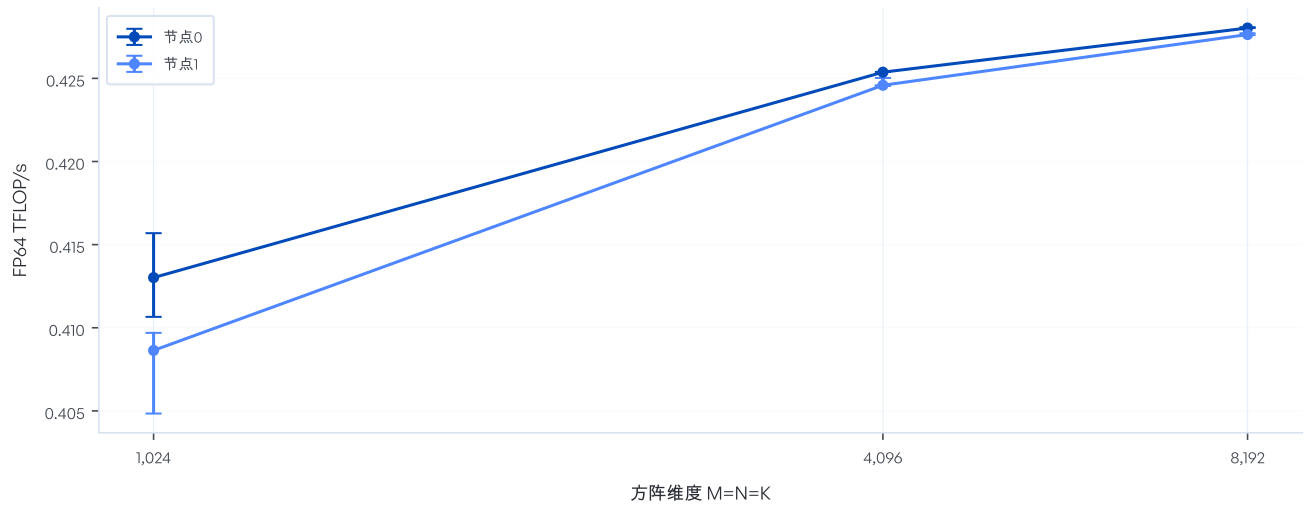


图 06–09 FP64规模效应

点为五轮中位数，误差线为观测范围；不用于预测低精度模型吞吐。

代表性核函数的硬件计数器

表 06–08 代表性核函数的硬件计数器

节点 / 核函数	指标	n	中位数［范围］	单位
0 / fma	剖析内核时长	3	936896.000 [936672.000–937504.000]	ns
0 / fma	L2扇区命中比例	3	15.690 [7.020–17.090]	%
0 / fma	SM吞吐占峰值比例	3	99.030 [99.020–99.040]	%
0 / fma	活跃warp比例	3	46.340 [46.340–46.350]	%
0 / triad	剖析内核时长	3	3831552.000 [3800544.000–3865088.000]	ns
0 / triad	L2扇区命中比例	3	0.010 [0.010–0.020]	%
0 / triad	SM吞吐占峰值比例	3	2.740 [2.690–2.740]	%
0 / triad	活跃warp比例	3	88.920 [88.470–92.660]	%
1 / fma	剖析内核时长	3	938752.000 [937888.000–939232.000]	ns
1 / fma	L2扇区命中比例	3	18.230 [18.000–45.320]	%
1 / fma	SM吞吐占峰值比例	3	99.030 [99.020–99.040]	%
1 / fma	活跃warp比例	3	46.340 [46.340–46.350]	%
1 / triad	剖析内核时长	3	3999008.000 [3891552.000–4325664.000]	ns
1 / triad	L2扇区命中比例	3	0.020 [0.010–0.070]	%
1 / triad	SM吞吐占峰值比例	3	2.590 [2.390–2.650]	%
1 / triad	活跃warp比例	3	87.300 [84.800–90.130]	%

计算核函数使用每线程八条独立乘加链、每个SM四个线程块；访存核函数使用三数组共768MiB工作集。管理员运行Nsight Compute，只采集一次指定内核；不修改全局驱动权限、时钟或缓存控制。计数只解释这两个核函数，不能当作模型平均命中率。当前接口未公布物理DRAM字节指标，因此仍不构建依赖该计数的模型Roofline。

07 · 双机通信与系统协同

设备间数据交换：端口、RDMA与集合通信

本实验每节点一个GPU通信进程（rank），双节点经ConnectX-7/RoCE连接。启用的物理端口标称200 Gb/s＝25 GB/s单向；两个逻辑接口共享该端口。RDMA记录测主机缓冲区，NCCL记录测GPU集合通信，两种实验按各自工作量统计。功能对应的H200互连参照统一见第10节。

表 07-01 设备间数据交换：端口、RDMA与集合通信

传输 / 操作	消息大小	轮次	中位速率	测量条件
RDMA Write / roceP2p1s0f1	8 MiB	3	13.629 GB/s (109.03 Gb/s)	2026-10-14；主机内存缓冲区，单逻辑路径
RDMA Write / rocep1s0f1	8 MiB	3	13.617 GB/s (108.94 Gb/s)	2026-10-14；主机内存缓冲区，单逻辑路径
all_gather	1 GiB	10	19.930 GB/s	2026-10-16；两GPU rank，总线口径
all_reduce	1 GiB	10	21.815 GB/s	2026-10-16；两GPU rank，总线口径
reduce_scatter	1 GiB	10	20.946 GB/s	2026-10-16；两GPU rank，总线口径

RDMA Write以ib_write_bw、单QP、单向8 MiB消息测试，每逻辑路径3轮；输出使用--report_gbits，除8换算GB/s。它是独立历史主机缓冲区测量，不能替代GPU集合通信或与其相加。当前NCCL日志确认NET/IB上的RoCE，并明确记录GPU Direct RDMA Disabled；不声称GPU直接RDMA路径。

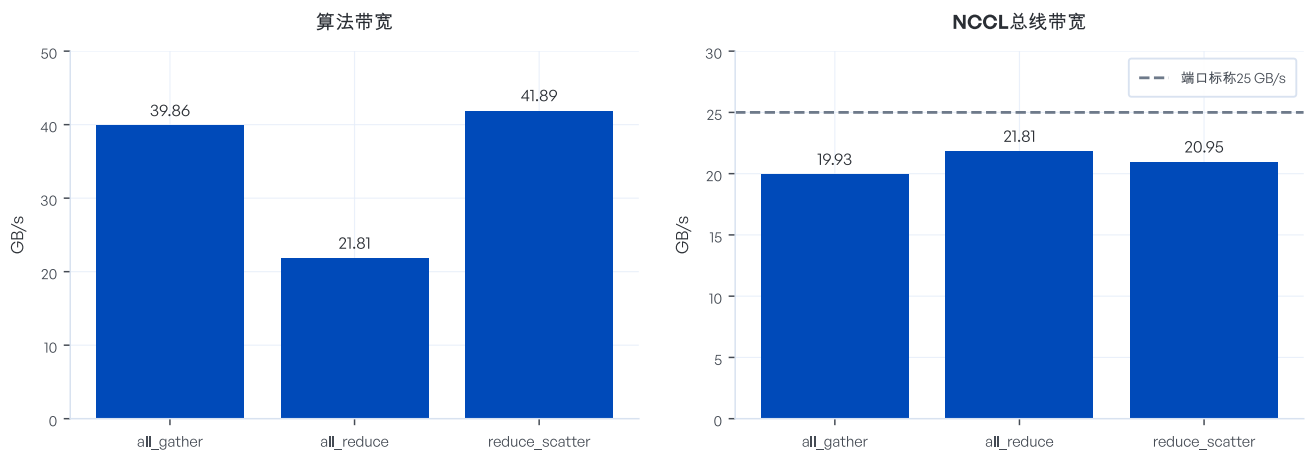


图 07-01 1 GiB集合通信

算法带宽按完整输入/输出张量计数；总线带宽按NCCL规则校正。两rank时AllReduce系数为1，AllGather与ReduceScatter为1/2，因此算法GB/s可以高于25而不代表物理端口超过200 Gb/s。总线带宽也不是网卡硬件计数器读数；虚线只作标称端口线速参考。

RDMA第一路径 · RDMA第二路径 · 本节固定条件与数据来源 · 官方规格快照索引。本批已归档840次双rank配对有效试验。两rank合为一次测量，采用较慢rank时间；算法带宽为规定消息字节数 / 时间，总线带宽按NCCL定义校正，不跨rank相加。AllReduce消息为完整输入，AllGather为完整输出，ReduceScatter为完整输入。原批434次配对记录单独保留，不混入本批重复分母。

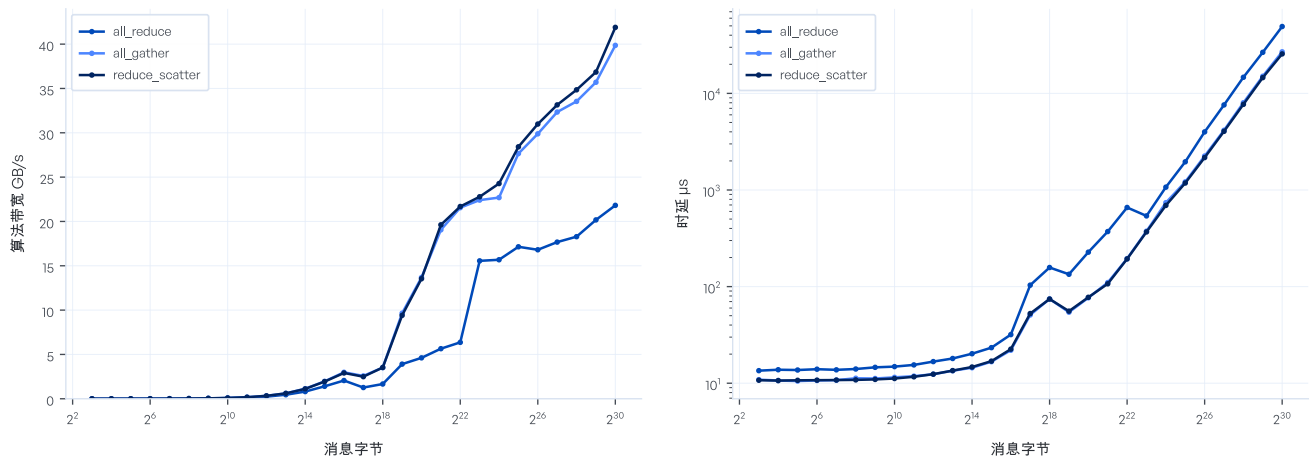


图 07–02　通信规模曲线

三种集合通信分别展示算法带宽和时延；实际覆盖受两节点内存保护共同约束。

表 07–02　设备间数据交换：端口、RDMA与集合通信

操作	消息字节	配对轮次	中位延迟 µs	算法GB/s	总线GB/s
all_gather	8	10	10.89	0.001	0.000
all_gather	8,192	10	13.46	0.608	0.304
all_gather	8,388,608	10	374.38	22.408	11.204
all_gather	67,108,864	10	2245.77	29.882	14.941
all_gather	1,073,741,824	10	26937.75	39.860	19.930
all_reduce	8	10	13.49	0.001	0.001
all_reduce	8,192	10	18.02	0.454	0.454
all_reduce	8,388,608	10	539.32	15.555	15.555
all_reduce	67,108,864	10	3993.42	16.805	16.805
all_reduce	1,073,741,824	10	49220.55	21.815	21.815
reduce_scatter	8	10	10.74	0.001	0.000
reduce_scatter	8,192	10	13.51	0.606	0.303
reduce_scatter	8,388,608	10	368.19	22.784	11.392
reduce_scatter	67,108,864	10	2165.91	30.984	15.492
reduce_scatter	1,073,741,824	10	25631.79	41.891	20.946

计算与通信的受控重叠

固定一项BF16矩阵计算和一次AllReduce，分别测计算单独、通信单独、串行组合和双流重叠。每个消息大小与矩阵规模保持相同工作量；串行时间 / 重叠时间大于1表示这组工作缩短，小于1表示重叠反而变慢。该比值只描述合成工作组合，不是模型双机加速倍数。

表 07–03 计算与通信的受控重叠

消息字节	方阵边长	配对轮次	串行 / 重叠	观测范围
8,192	2048	5	1.059	1.001—1.113
8,192	4096	5	1.020	1.011—1.029
8,388,608	2048	5	1.168	1.093—1.193
8,388,608	4096	5	1.035	1.020—1.094
67,108,864	2048	5	1.023	1.016—1.027
67,108,864	4096	5	1.096	1.071—1.122

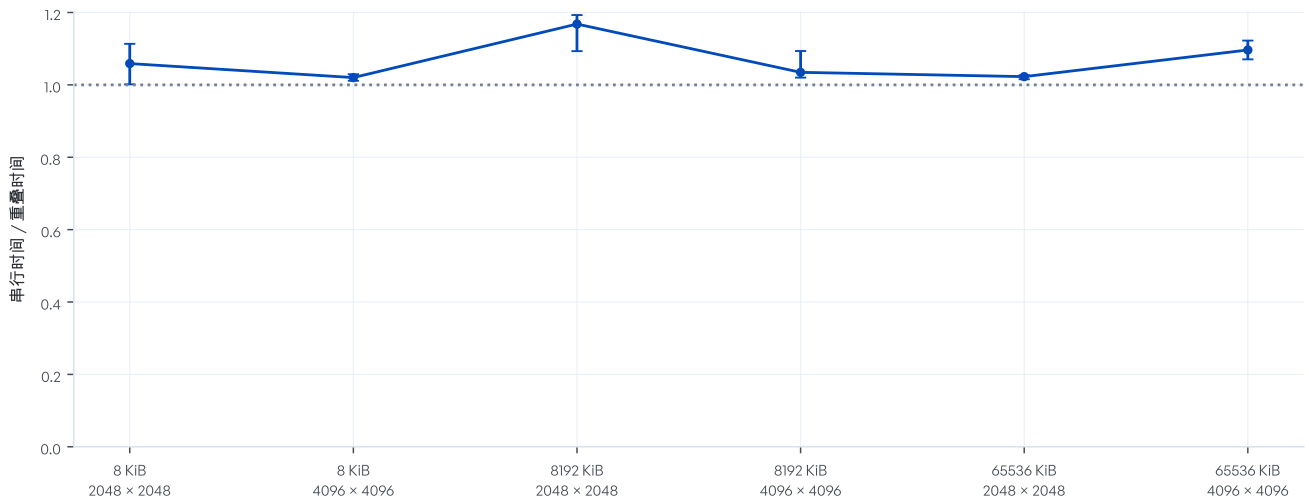


图 07–03 重叠收益

每点为同轮四臂配对比值的中位数，误差线为观测范围；高于1表示本组工作用时缩短。

本批统计及原始来源 · NCCL带宽定义。实际传输方式以本批NCCL日志核验，不以网卡名称直接证明GPU Direct路径。

08 · 从引擎阶段到服务表现

本节先定义并测量引擎处理阶段，再观察公网用户体验，最后分析输入结构与缓存。预填充处理输入；解码持续生成输出。两组请求的材料与计时边界不同，结果互作解释依据，不做跨实验耗时相减。

引擎内部预填充与解码：独立实验

本实验直接调用推理节点本机的SGLang原生接口，将公网、Cloudflare与Infron网关移出计时路径。使用相同权重与双节点张量并行配置，MTP保持开启。并发上限8；直接源站调用不计入Infron API账单。此实验不与前述公网请求合并统计。

表 08–01 引擎内部预填充与解码：独立实验

实验	工作量与重复	测量含义
预填充	1K / 8K / 32K / 64K / 128K / 250,000输入，输出1；并发1，并在较短输入增加并发4 / 8；每条件3轮	读取调度器预填充起止时间；分母含分块调度间隙，不称为纯GPU时间
解码	1K / 8K / 32K输入×并发1 / 2 / 4 / 8，另加64K / 128K单并发；输出固定256；每条件3轮	接口进程首词元到结束的生成速率、MTP接受长度与验证次数

实验	工作量与重复	测量含义
前缀复用对照	8K / 32K，各3组首次请求与立即重复，输出均为1	以实际缓存词元确认命中；不测长期保留
GPU时间线	8K输入、128输出、并发1；双节点分别捕获预填充与4个解码调度步	记录GPU活动区间、NCCL命名内核、MTP草稿 / 验证阶段；剖析数据与常规速度测量分开

清单共78组、231条正式请求，另有2条预检 / 剖析请求。并发×（输入＋输出）超过262,144的组合排除。使用固定种子的合成订单记录，经实际模型分词器生成精确长度的token ID；不经过聊天模板。温度为0，忽略结束词元以固定输出长度。因此这是可控的引擎负载，不代表自然对话的输出长度或MTP接受率。每轮随机化条件顺序；不同请求具有不同的早期前缀，是否命中仍以返回字段核验。

计时定义与核验

表 08-02 计时定义与核验

指标	定义与边界
调度器预填充耗时	同一调度器进程的prefill_finished_time − forward_entry_time；包括分块等待，不包括首次进入调度前的排队。
预填充处理速率	同一区组Σ（输入−已缓存词元） / （最后预填充结束−最早预填充开始）。多请求重叠区间不重复累加。
单请求解码速率	（实际输出−1） / （引擎总耗时−引擎首词元耗时），与原生decode_throughput交叉校验；包含引擎调度、结果传递和MTP路径。
并发解码窗口吞吐	Σ（实际输出−1） / （最后请求结束−最早首词元）；同一接口进程计时，并发请求的错峰预填充可能仍在此窗口内。
MTP接受长度与接受率	已安装实现的接受长度＝完成输出词元 / 验证次数；接受率＝正确草稿词元 / 提出的草稿词元。两者分母不同，接受长度不是加速倍数，也不是捕获的每一步实际输出计数。
GPU活动分解	分别求两节点内核 / 拷贝区间的并集，再区分NCCL独占、其他活动独占及重叠。不相加嵌套注释，不跨节点叠加时间。

调度器与接口进程的绝对时间戳转换存在偏移，因此只在同一进程的时间基准内计算区间。三个区组的中位数与最小 / 最大范围用于描述重复性，不据此报告尾部百分位或置信区间。发生重计算 / 回退的请求需单独分析，不进入当前时间拆分。

独立速率实测

当前归档可分析78组、231条正式请求；计时校验未通过0条。

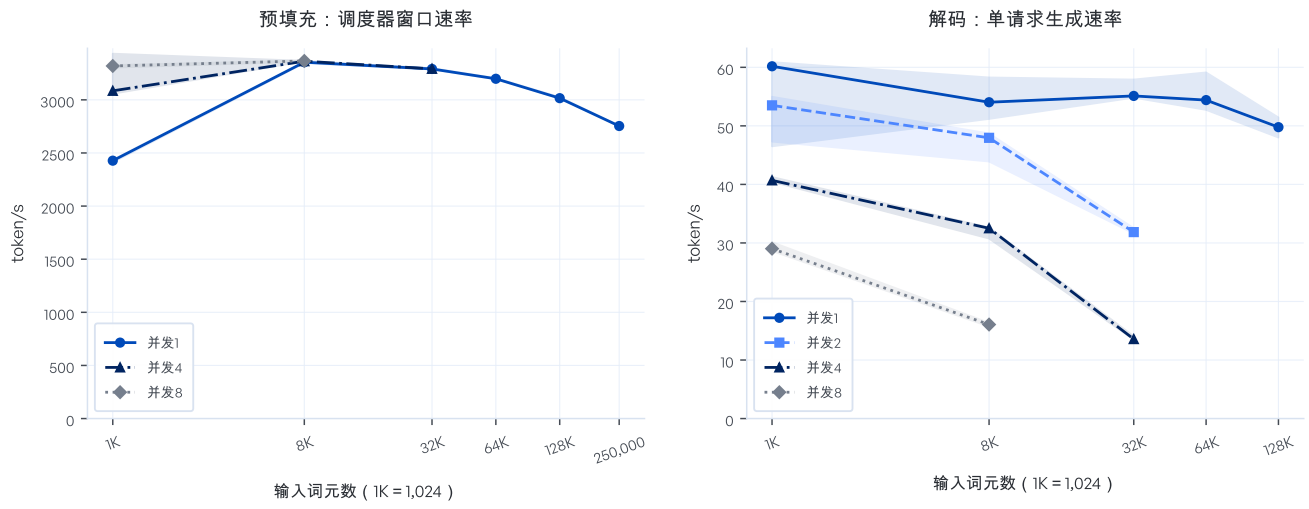


图 08–01　引擎阶段速率

左图为调度器预填充窗口速率；右图为单请求解码速率。阴影为区组观测范围，不是置信区间。

表 08–03　独立速率实测

输入词元	并发	区组 / 请求	预填充中位 s	窗口速率 token/s	缓存词元
1,024	1	3 / 3	0.422	2,427.4	0
1,024	4	3 / 12	0.915	3,084.9	0
1,024	8	3 / 24	2.059	3,318.9	0
8,192	1	3 / 3	2.442	3,354.2	0
8,192	4	3 / 12	4.837	3,363.7	0
8,192	8	3 / 24	4.861	3,366.1	0
32,768	1	3 / 3	9.957	3,290.8	0
32,768	4	3 / 12	12.351	3,291.9	0
65,536	1	3 / 3	20.491	3,198.3	0
131,072	1	3 / 3	43.462	3,015.8	0
250,000	1	3 / 3	90.787	2,753.7	0

表 08–04　独立速率实测

输入词元	并发	区组 / 请求	单请求 token/s	并发窗口 token/s	MTP接受长度中位
1,024	1	3 / 3	60.2	60.2	3.71
1,024	2	3 / 6	53.5	107.0	3.74
1,024	4	3 / 12	40.7	144.9	3.61
1,024	8	3 / 24	29.0	206.6	3.58
8,192	1	3 / 3	54.0	54.0	3.32
8,192	2	3 / 6	48.0	93.2	3.44

输入词元	并发	区组 / 请求	单请求 token/s	并发窗口 token/s	MTP接受长度中位
8,192	4	3 / 12	32.5	86.2	3.46
8,192	8	3 / 24	16.1	81.1	3.37
32,768	1	3 / 3	55.1	55.1	3.41
32,768	2	3 / 6	31.9	38.0	3.18
32,768	4	3 / 12	13.6	29.0	3.37
65,536	1	3 / 3	54.4	54.4	3.41
131,072	1	3 / 3	49.8	49.8	3.12

在已测单并发条件下，各输入长度的解码速率中位数为49.8—60.2 token/s。此范围来自合成记录与固定输出条件；不能直接替代公网端点容量或任意业务的生成速度。

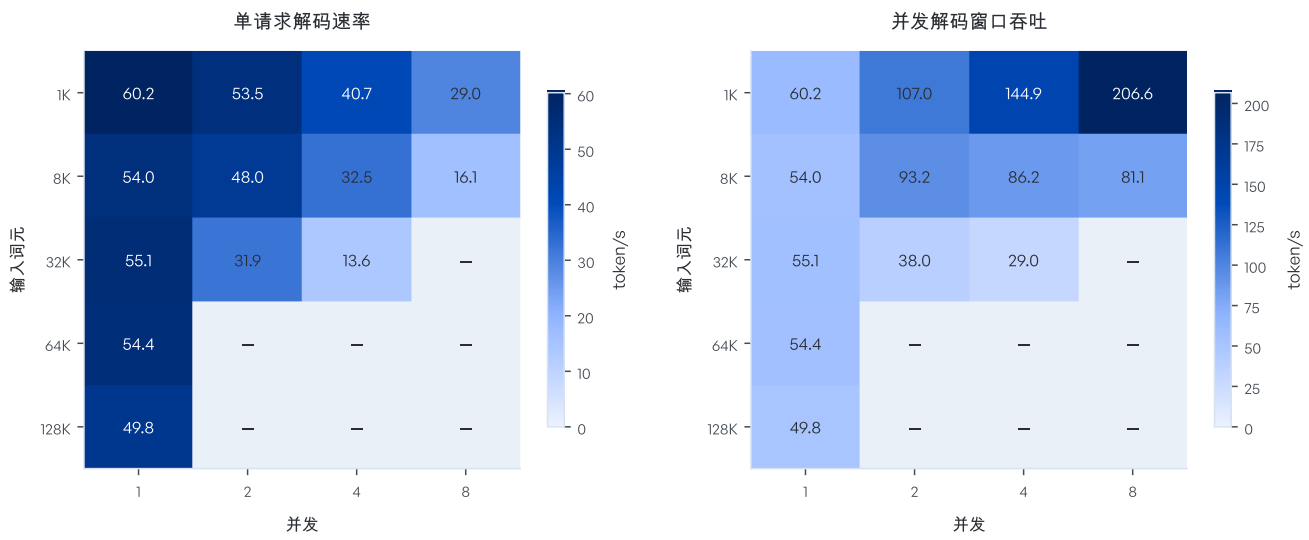


图 08–02 解码长度×并发

每格为三个区组的汇总速率；灰格未测，左、右面板色标独立。固定输出256词元，长输入下提高并发不保证提高合计吞吐。

同一前缀立即复用的预填充对照

表 08–05 同一前缀立即复用的预填充对照

输入	配对数	重复请求缓存词元比例	首次 / 重复预填充中位 s	配对耗时比中位
8,192	3	0.00%	2.4343 / 2.4507	0.99
32,768	3	75.00%	9.9719 / 2.5517	3.91

缓存比例分母为重复请求的实际输入词元总数；耗时比逐对计算后取中位数。固定先首次、后重复的顺序仍有顺序效应；三个立即重复样本不能证明长期缓存稳定性，也不应将此比值称为模型计算加速倍数。

本轮8K立即重复的报告缓存比例为0%，32K为75%。相同输入并不保证全量缓存命中；这些结果限定于本次输入长度、单词元输出和当前缓存状态，不能直接推断所有业务的缓存规则或保留时间。

GPU侧阶段与通信活动

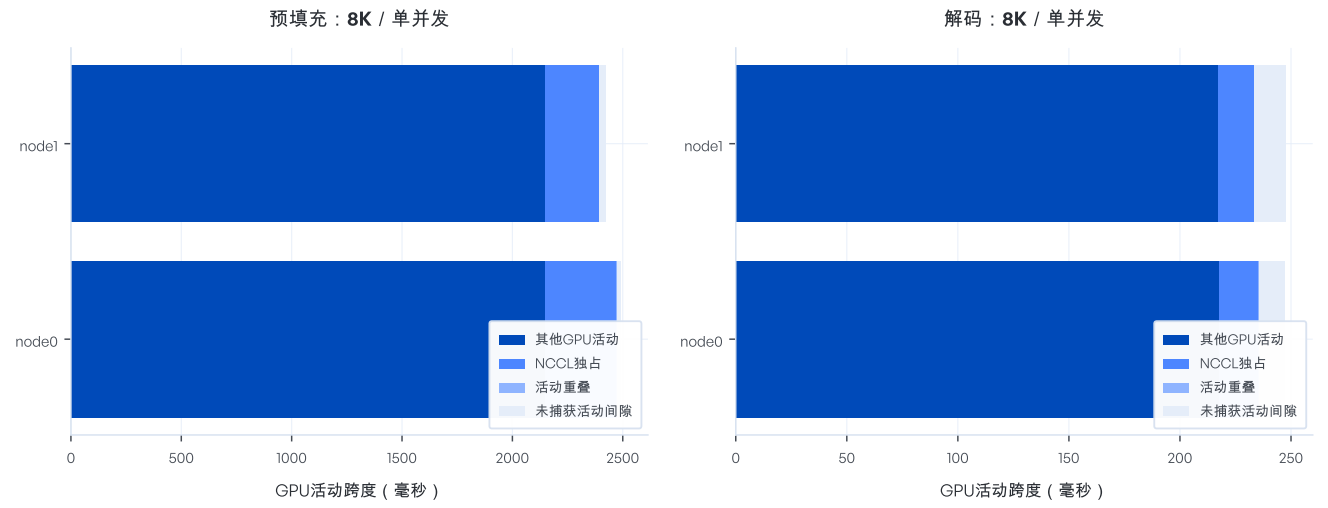


图 08–03 两节点GPU活动分解

各条分别归一到本节点捕获的活动跨度。剖析包含额外开销，仅用于解释路径；“其他活动”可能含未以NCCL命名的通信内核。

表 08–06 GPU侧阶段与通信活动

节点 / 阶段	活动跨度 ms	活动并集 ms	NCCL独占 ms	重叠 ms
node0 / decode	247.07	235.38	17.68	0.05
node0 / prefill	2,489.51	2,472.72	325.91	0.02
node1 / decode	247.42	233.38	15.80	0.03
node1 / prefill	2,423.98	2,395.04	246.97	0.00

表 08–07 GPU侧阶段与通信活动

节点 / 捕获阶段	内部阶段	匹配的执行次数	GPU关联范围均值 ms
node0 / decode	MTP草稿生成	4	10.575
node0 / decode	目标模型验证	4	44.100
node0 / decode	草稿状态扩展	4	6.150
node0 / prefill	目标模型预填充	1	2,401.288
node0 / prefill	草稿状态扩展	1	87.003
node1 / decode	MTP草稿生成	4	10.692
node1 / decode	目标模型验证	4	44.079
node1 / decode	草稿状态扩展	4	6.159
node1 / prefill	目标模型预填充	1	2,332.348
node1 / prefill	草稿状态扩展	1	87.009

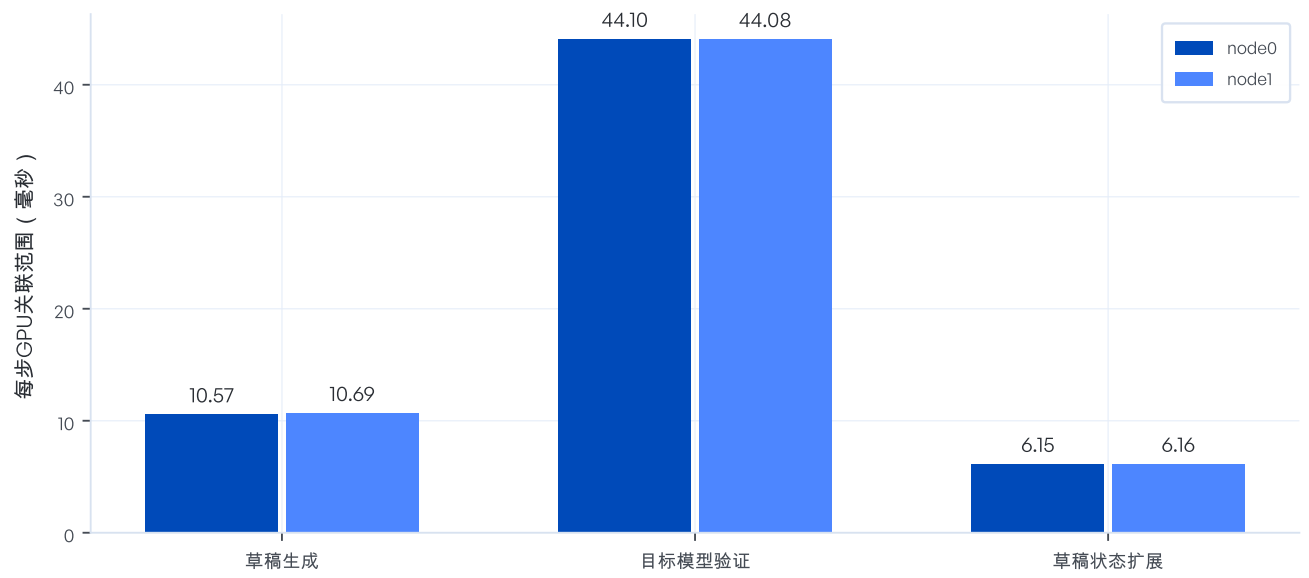


图 08-04 MTP阶段拆分

每节点4个捕获解码步；柱高为GPU关联范围的均值，不能相加当作端到端时延。

阶段范围通过CPU注释与GPU注释的同一External id关联；CUDA Graphs会在多个虚拟执行流上重复标注同一次验证，因此先按执行标识合并区间，再计算每次执行的范围。该范围包含设备等待与通信，不等同于内核忙碌时间；草稿、验证与状态扩展的范围不能不经重叠检查就相加。未获取每个捕获步实际接受的词元数，因此不以验证步数乘固定MTP长度来伪造GPU解码token/s。

双节点时间线均捕获到预填充与解码GPU内核，以及MTP草稿、验证和草稿状态扩展的阶段注释。GPU活动与通信存在重叠，因此相加每个算子或NCCL内核耗时会重复计算。基础剖析为8K单并发场景；下文补充三种输入 / 并发条件及配对开销。NCCL活动时间不能直接等同于可消除的通信等待。

逐请求指标 · 逐区组指标 · 源码及原始时间线目录

实现依据：SGLang profiling · SGLang observability · 已安装版本的计时源码；线上文档用于方法参考，字段含义以保存的已安装源码为准。

公网并发：吞吐与等待

表 08-08 公网并发：吞吐与等待

并发	区组 / 请求	生成词元/s	正文首字 中位 / 95分位 s	完成时间95分位 s
1	2 / 120	45.1	1.01 / 1.65	19.46
2	3 / 180	78.7	1.07 / 1.78	24.87
4	1 / 60	120.2	1.11 / 1.79	30.53
8	3 / 180	158.9	1.17 / 2.39	46.93

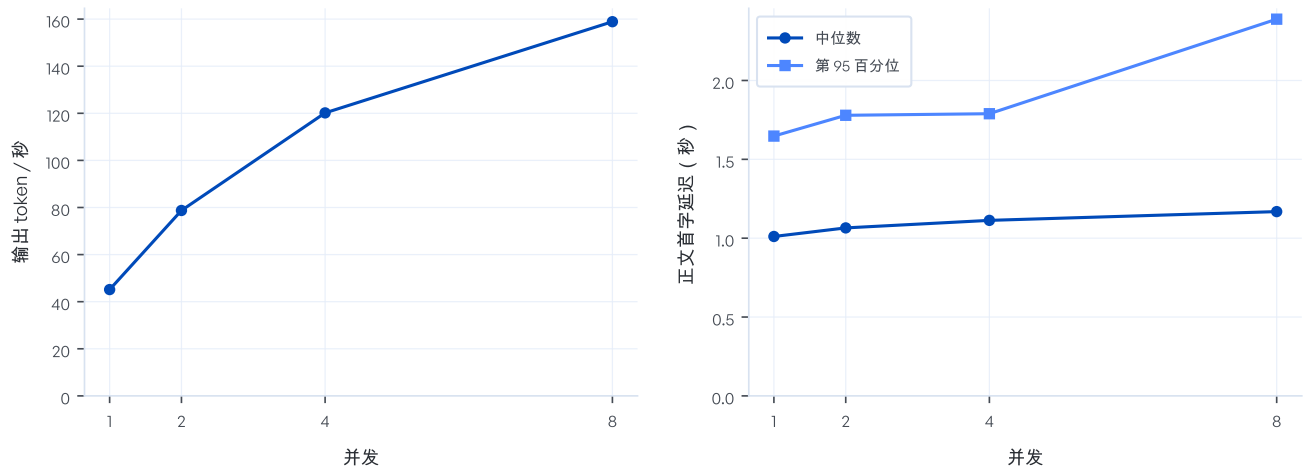


图 08–05　并发比较

同组的合计吞吐与正文首字延迟；提高并发时同时观察等待代价。

在本次短提示题库中，并发8的合计吞吐为 **158.9 词元/s**。该结果对应平均输出 **400.8 词元**，不能直接用于长文档业务的容量规划。

长度：输入处理与生成压力

以下热力图把输入长度、输出预算与并发拆成三个明确的变量。每个格子只纳入连续完整区组；深色表示数值较大，灰色表示该条件没有合格区组。输出预算是允许生成的上限，并不要求模型生成到上限。两图使用相同样本口径，分别回答“多久看到正文”和“整个系统每秒生成多少词元”。

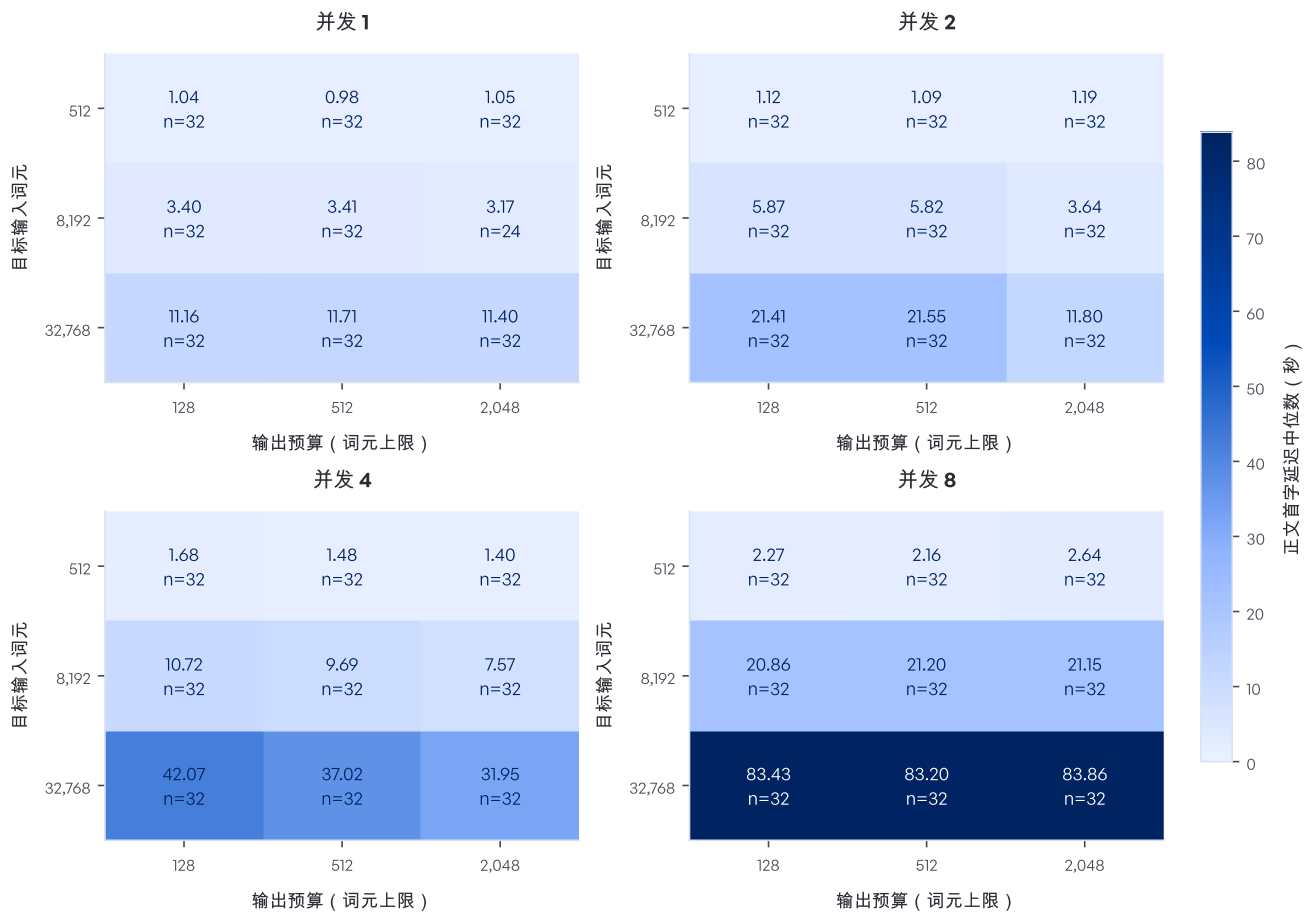


图 08–06　输入 / 输出长度与正文等待

每格标出正文首字延迟中位数和有效响应数 n；四个并发面板共用色标。不能用该时延直接计算纯 GPU 预填充速度。

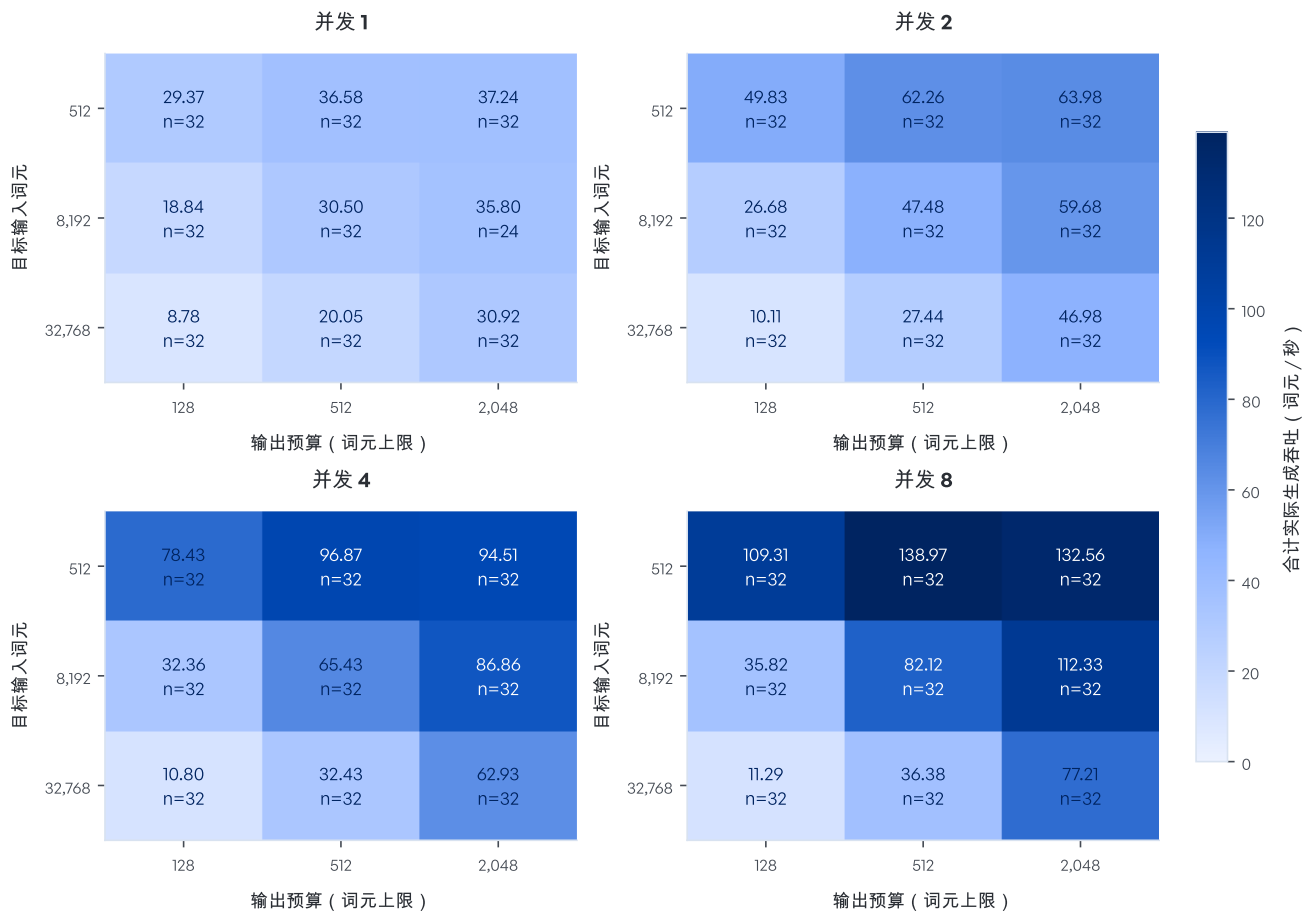


图 08–07　输入 / 输出长度与系统吞吐

每格为实际生成词元总数除以完整区组总时长；输出提前结束会改变实际工作量。较高的输出预算不等同于较高的有效业务产出。

固定输出预算下的可比切片

下表固定输出预算为 **512 词元**，保留输入长度和并发变化。实际输入包含聊天模板；实际输出均值用于检查各格是否真的完成了相近的生成工作量。

表 08–09　固定输出预算下的可比切片

目标输入 / 并发	区组 / 响应	实际输入 / 输出均值	正文首字中位数 s	总时延中位数 s	合计词元/s
512 / 1	4 / 32	513 / 512.0	0.98	13.97	36.6
512 / 2	4 / 32	513 / 512.0	1.09	16.12	62.3
512 / 4	4 / 32	513 / 512.0	1.48	20.53	96.9
512 / 8	4 / 32	513 / 512.0	2.16	28.51	139.0
8,192 / 1	4 / 32	8,193 / 512.0	3.41	16.78	30.5
8,192 / 2	4 / 32	8,193 / 512.0	5.82	21.24	47.5
8,192 / 4	4 / 32	8,193 / 512.0	9.69	30.69	65.4
8,192 / 8	4 / 32	8,193 / 512.0	21.20	48.44	82.1
32,768 / 1	4 / 32	32,769 / 512.0	11.71	24.89	20.0

目标输入 / 并发	区组 / 响应	实际输入 / 输出均值	正文首字中位数 s	总时延中位数 s	合计词元/s
32,768 / 2	4 / 32	32,769 / 512.0	21.55	37.09	27.4
32,768 / 4	4 / 32	32,769 / 512.0	37.02	62.01	32.4
32,768 / 8	4 / 32	32,769 / 512.0	83.20	111.55	36.4

长度效应。在并发 1、输出预算 512 的切片中，目标输入从 512 增至 **32,768 词元**，正文首字中位数由 **0.98 s** 变为 **11.71 s**；合计输出吞吐由 36.6 变为 **20.0 词元/s**。这是端到端的长度敏感性观测，包含当前前缀状态和服务链路的共同影响。

全部长度条件的可复算数据

表 08–10 固定输出预算下的可比切片

上下文或前缀条件	完整 / 失败	首生成中位数 s
长上下文与边界 · 上下文边界探针	0 / 1	—
长上下文与边界 · 目标输入 131,072 token · 并发 1 · 长输入后生成	3 / 0	48.34
长上下文与边界 · 目标输入 131,072 token · 并发 2 · 长输入后生成	3 / 0	90.65
长上下文与边界 · 目标输入 16,384 token · 并发 1 · 长输入后生成	3 / 0	6.77
长上下文与边界 · 目标输入 16,384 token · 并发 2 · 长输入后生成	3 / 0	11.28
长上下文与边界 · 目标输入 200,000 token · 并发 1 · 长输入后生成	3 / 0	74.05
长上下文与边界 · 目标输入 250,000 token · 并发 1 · 长输入后生成	3 / 0	94.08
长上下文与边界 · 目标输入 32,768 token · 并发 1 · 长输入后生成	3 / 0	12.55
长上下文与边界 · 目标输入 32,768 token · 并发 2 · 长输入后生成	3 / 0	22.01
长上下文与边界 · 目标输入 4,096 token · 并发 1 · 长输入后生成	3 / 0	2.54
长上下文与边界 · 目标输入 4,096 token · 并发 2 · 长输入后生成	3 / 0	2.41
长上下文与边界 · 目标输入 65,536 token · 并发 1 · 长输入后生成	3 / 0	24.49
长上下文与边界 · 目标输入 65,536 token · 并发 2 · 长输入后生成	3 / 2	42.67
前缀缓存 · 历史文本 0 token · 首次前缀	10 / 0	1.07
前缀缓存 · 历史文本 0 token · 重复前缀	10 / 0	0.96
前缀缓存 · 历史文本 0 token · 追加文本	10 / 0	1.06
前缀缓存 · 历史文本 32,768 token · 首次前缀	10 / 0	11.69
前缀缓存 · 历史文本 32,768 token · 重复前缀	10 / 0	1.55
前缀缓存 · 历史文本 32,768 token · 追加文本	10 / 0	1.61
前缀缓存 · 历史文本 8,192 token · 首次前缀	10 / 0	3.61
前缀缓存 · 历史文本 8,192 token · 重复前缀	10 / 0	1.08
前缀缓存 · 历史文本 8,192 token · 追加文本	10 / 0	1.17

思考预算：正文等待与输出形态

同题、同轮次、同并发比较 low 与 none，差值为 low 减 none。只分析性能变化，保留正文缺失和输出触顶情况。

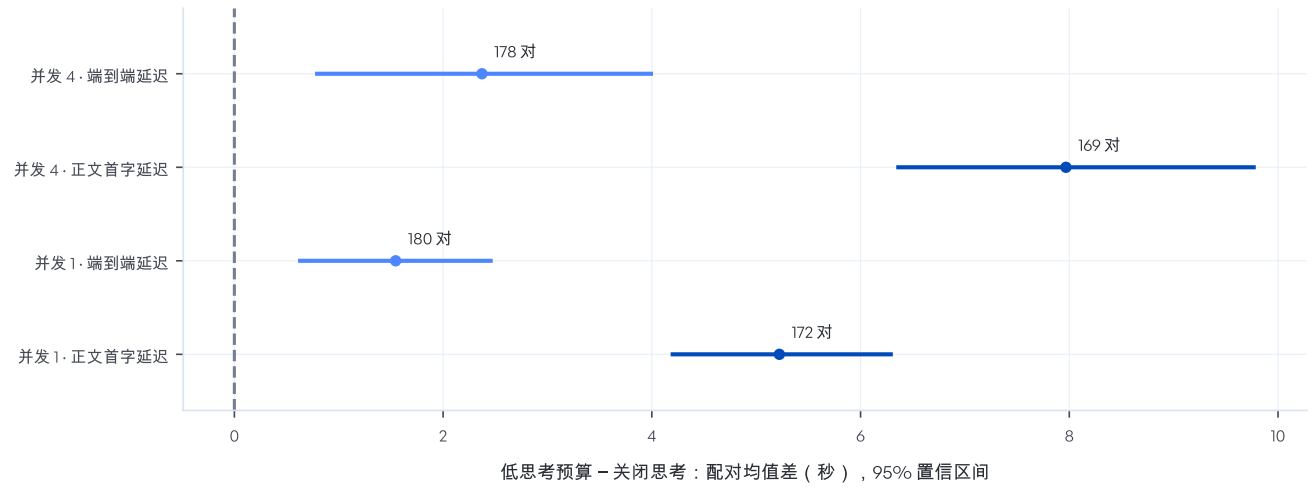


图 08–08　思考档位的配对延迟差

点为均值差，线为按题目重采样的95%区间；配对数和轮次敏感性见附录B。

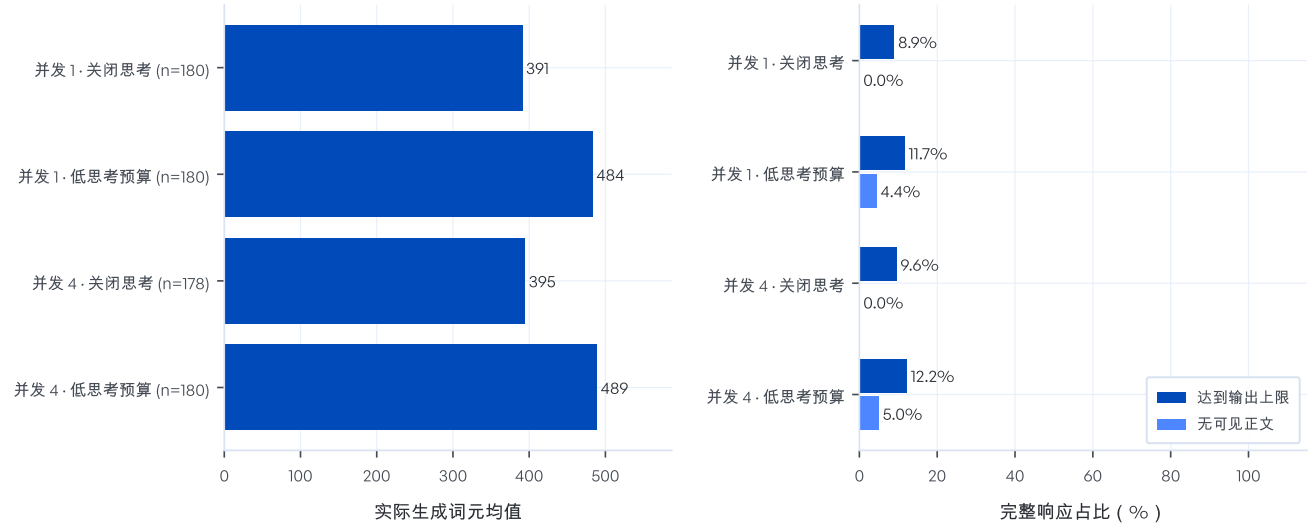


图 08–09　输出形态

实际输出量与触顶、无正文比例一起阅读；后两项可重叠，不能相加。

业务形态与缓存比例：实际覆盖

业务形态与缓存比例测试在本快照完成 347 / 352 次计划调用，其中正式测量完整响应 260 / 264。

表 08–11　业务形态与缓存比例：实际覆盖

业务 / 并发	完整数	实际输出中位数	实际输入输出比中位数	正文首字中位数 s	端到端中位数 s
长文档分析 / 1	12	2,048.0	16.0	11.92	49.73
长文档分析 / 4	12	2,048.0	16.0	42.59	101.32
代码修改 / 1	12	512.0	16.0	3.64	11.54
代码修改 / 4	12	512.0	16.0	11.73	22.86
多轮业务助理 / 1	12	499.5	16.4	3.49	13.26

业务 / 并发	完整数	实际输出中位数	实际输入输出比中位数	正文首字中位数 s	端到端中位数 s
多轮业务助理 / 4	12	505.0	16.2	11.63	26.16
短提示长生成 / 1	12	1,599.5	0.3	1.10	35.31
短提示长生成 / 4	8	1,566.5	0.3	2.04	51.05
结构化提取 / 1	12	43.0	47.7	1.49	2.15
结构化提取 / 4	12	43.0	47.7	3.80	4.61
等量改写 / 1	12	510.0	4.0	1.52	13.50
等量改写 / 4	12	486.0	4.2	3.83	20.04
长文档摘要 / 1	12	128.0	256.0	11.59	14.60
长文档摘要 / 4	12	128.0	256.0	42.35	46.74
工单分类 / 1	12	25.0	20.6	1.10	1.73
工单分类 / 4	12	25.0	20.5	2.03	2.80

表 08–12　业务形态与缓存比例：实际覆盖

业务 / 并发	连续完整区组 token/s	估算 TPOT 中位数 ms	触顶 / 完整数
长文档分析 / 1	36.1	21.88	7/12
长文档分析 / 4	73.1	28.85	7/12
代码修改 / 1	38.8	16.13	8/12
代码修改 / 4	74.9	22.54	9/12
多轮业务助理 / 1	31.4	23.95	6/12
多轮业务助理 / 4	63.5	32.48	6/12
短提示长生成 / 1	44.9	21.50	1/12
短提示长生成 / 4	117.9	31.08	0/8
结构化提取 / 1	19.0	15.04	0/12
结构化提取 / 4	36.8	19.41	0/12
等量改写 / 1	45.0	22.44	0/12
等量改写 / 4	98.8	32.49	0/12
长文档摘要 / 1	8.6	22.77	12/12
长文档摘要 / 4	10.9	35.22	12/12
工单分类 / 1	13.5	25.98	0/12
工单分类 / 4	34.2	32.41	0/12

表 08–13　业务形态与缓存比例：实际覆盖

输入 / 目标共享	完整数	实际共享 %	缓存字段覆盖	字段报告缓存 %	正文首字中位数 s
32,768 / 0%	6	0.0	0/6	—	12.44

输入 / 目标共享	完整数	实际共享 %	缓存字段覆盖	字段报告缓存 %	正文首字中位数 s
32,768 / 100%	6	100.0	0/6	—	1.91
32,768 / 25%	6	25.0	0/6	—	11.79
32,768 / 50%	6	50.0	0/6	—	9.18
32,768 / 75%	6	75.0	0/6	—	6.77
32,768 / 90%	6	90.0	0/6	—	4.56
8,192 / 0%	6	0.1	0/6	—	3.50
8,192 / 100%	6	100.0	0/6	—	1.14
8,192 / 25%	6	24.9	0/6	—	3.60
8,192 / 50%	6	49.9	0/6	—	3.47
8,192 / 75%	6	74.9	0/6	—	3.46
8,192 / 90%	6	89.9	0/6	—	3.55

解释顺序为：核对实际长度与输出触顶 → 对齐并发和样本组成 → 看首片段等待及生成耗时 → 核对缓存字段覆盖 → 结合同时段资源说明可能机制。没有完整区组、有效缓存字段或匹配输入时，只报告观察，保留替代解释。

上下文边界与请求复用

单词元输出探针观察输入处理等待，长上下文与越界请求检查可用范围，首次 / 重复 / 追加文本检查请求复用。各条件的实际长度、延迟与终态见附录B；配置上限不等于已经验证的可用容量。

缓存命中与稳定性

前缀缓存保存已处理输入的中间状态，使后续相同开头有机会减少输入计算。是否能复用，取决于前缀一致性、缓存驻留和调度；缓存占用率反映存储状态，本身不等于命中率。

缓存专项：覆盖范围与样本

原有两档长度、六档共享比例的144次对照保留，另增加以下160次诊断。箭头为目标输入→输出上限，均使用温度0、关闭思考；同一复用对的生成参数保持一致。

表 08–14 缓存专项：覆盖范围与样本

调用数	测试	条件与含义
72	业务 × 复用 × 并发	工单分类512→64、多轮助理8,192→512、摘要32,768→128；并发1 / 4；各4个独立前缀，每个首次、50%共享、100%重复。
36	空闲保留	8,192 / 32,768输入 × 名义等待0 / 30 / 300秒 × 3个独立前缀 × 首次与探测。每个前缀只做一次终点探测。
24	竞争与恢复	3个独立8,192词元锚点；首次→立即复测→4个独立32,768词元干扰请求→锚点复测→再次复测。
28	周期复用稳定性	4个8,192词元前缀；预热4次后，并发4，每120秒复测一轮，共6轮；计划跨度10分钟。
0	持续负载中的缓存变化	复用独立到达与持续运行测试，按约60秒有效窗口统计缓存比例、首字延迟和缓存占用，不额外发请求。

三类交叉业务覆盖短输入、中长会话和长文档；其余五类业务仍保留原有性能测量，不外推缓存结论。不同并发使用独立前缀，50% / 100%探测顺序交替；首次请求只是新前缀参照，不保证底层缓存为空。空闲实际间隔从首次响应完成到探测发送；0秒表示不主动等待，监控边界采样仍有开销。计划偏差、重试、监控缺口和计数不匹配单独标记，不纳入缓存归因。



图 08–10　缓存验证顺序

从输入复用到空闲保留、竞争恢复和时间变化；图示均为计划条件。

实际观测与证据覆盖

缓存专项已完成 160/160 次调用，获得 85 个可归因计数窗口。结论按业务、实际空闲间隔、竞争压力与周期分别阅读；未完成或计数不满足条件的格子仍无结论。 已有 30 对首次 / 重复观察，其中 26 对重复访问首字更快；这只支持等待差异观察，尚不能确认缓存因果收益。 节点计数的 358 个有效活动窗口记录到 20.3% 的词元加权缓存比例；这是该时段混合输入的观测值，不是逐请求命中率或长期稳定性结论。

表 08–15　实际观测与证据覆盖

负载组	完整响应	缓存字段有效 / 缺失
接口与测量校准	12	0 / 12
自然负载与并发扩展	718	0 / 718
输入 / 输出长度矩阵	1435	0 / 1435
思考预算配对	360	0 / 360
长上下文与边界	36	0 / 36
前缀缓存	90	0 / 90
业务形态与缓存比例扩展	507	0 / 507
开放到达与混合负载	783	0 / 783
长度扩展与持续运行	925	0 / 925

已有首次 / 完全重复序列的配对等待结果如下。这里“首次”是序列内的首次访问，不能保证系统此前没有相同前缀；表中差值先逐对计算，再取中位数。

表 08–16 实际观测与证据覆盖

附加历史词元	配对数	实际输入中位	首次首字 s	重复首字 s	配对减少 s	重复更快
0	10	107	1.07	0.96	0.08	6/10
8192	10	8,298	3.61	1.08	2.49	10/10
32768	10	32,875	11.69	1.55	10.04	10/10

覆盖表只将原始源站用量中的缓存字段视为有效；网关标准化响应中的零值若尚未与源站字段核对，保留为待核验，不进入命中率分母。

已保存的SGLang配置为 `enable_cache_report=false`，同时前缀缓存开启。因此，缺少逐请求字段不能解释为没有命中。SparkDash提供累计输入与缓存计数；专项测试使用隔离区组前后的新鲜增量，并与同区组请求量核对。接口字段、节点累计量及其观测覆盖分别保存。 SGLang v0.5.21 · SparkDash 计数实现

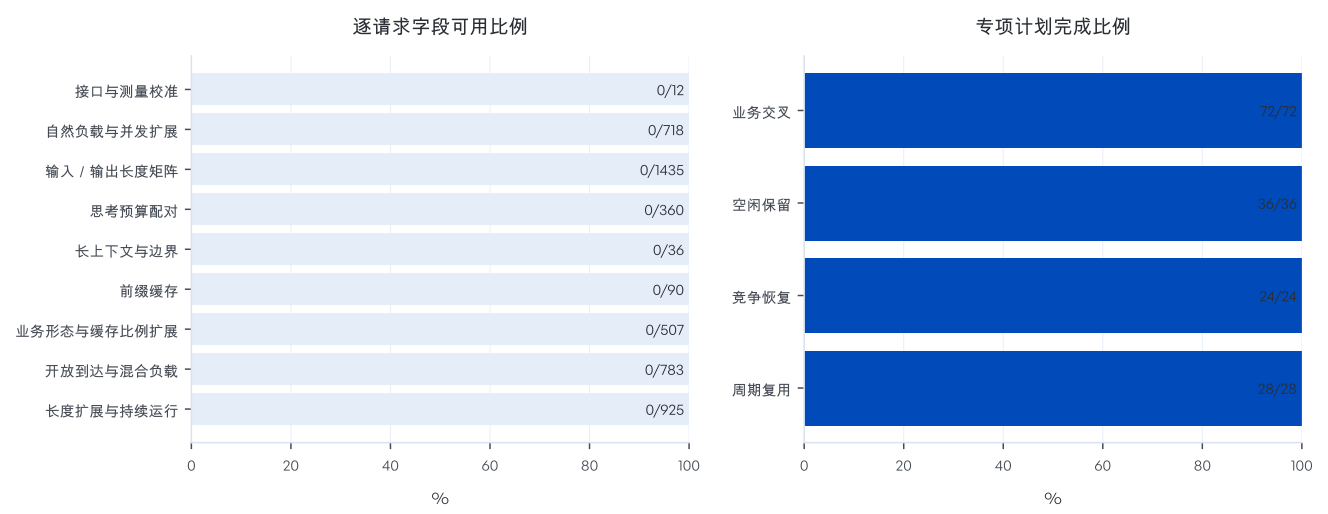


图 08–11 证据覆盖

左侧为逐请求缓存字段可用比例，右侧为专项调用完成比例；均不是缓存命中率。

表 08–17 实际观测与证据覆盖

条件	并发	n	首字中位 s	配对减少 s	有效窗口 / 缓存%
业务 / triage / 首次	4	4	2.48	0.00	1 / 0.0%
业务 / triage / 50%	4	4	2.59	−0.09	1 / 0.0%
业务 / triage / 100%	4	4	1.62	0.88	1 / 99.8%
业务 / dialogue / 首次	1	4	3.44	0.00	1 / 0.0%
业务 / dialogue / 100%	1	4	3.76	−0.16	1 / 0.0%
业务 / dialogue / 50%	1	4	3.35	−0.06	1 / 0.0%
业务 / summary / 首次	1	4	13.58	0.00	1 / 0.0%
业务 / summary / 50%	1	4	9.72	3.83	1 / 25.0%
业务 / summary / 100%	1	4	1.78	11.62	1 / 100.0%
业务 / triage / 首次	1	4	1.19	0.00	1 / 0.0%

条件	并发	n	首字中位 s	配对减少 s	有效窗口 / 缓存%
业务 / triage / 100%	1	4	0.91	0.29	1 / 99.8%
业务 / triage / 50%	1	4	1.17	0.08	1 / 0.0%
业务 / summary / 首次	4	4	43.15	0.00	1 / 0.0%
业务 / summary / 50%	4	4	25.90	17.25	1 / 43.5%
业务 / summary / 100%	4	4	2.91	40.25	1 / 99.8%
业务 / dialogue / 首次	4	4	11.22	0.00	1 / 0.0%
业务 / dialogue / 100%	4	4	9.89	1.34	1 / 24.8%
业务 / dialogue / 50%	4	4	12.10	−0.88	1 / 0.0%
空闲 / 32768 / 首次 / 30 s	1	3	13.63	—	3 / 0.0%
空闲 / 32768 / 复测 / 30 s	1	3	2.22	10.53	3 / 100.0%
空闲 / 32768 / 首次 / 0 s	1	3	13.26	—	3 / 0.0%
空闲 / 32768 / 复测 / 0 s	1	3	2.79	10.67	3 / 100.0%
空闲 / 32768 / 首次 / 300 s	1	3	12.89	—	3 / 0.0%
空闲 / 32768 / 复测 / 300 s	1	3	3.69	9.96	3 / 91.7%
空闲 / 8192 / 首次 / 0 s	1	3	4.75	—	3 / 0.0%
空闲 / 8192 / 复测 / 0 s	1	3	2.03	3.08	3 / 100.0%
空闲 / 8192 / 首次 / 300 s	1	3	4.84	—	3 / 0.0%
空闲 / 8192 / 复测 / 300 s	1	3	2.67	2.13	3 / 100.0%
空闲 / 8192 / 首次 / 30 s	1	3	4.39	—	3 / 0.0%
空闲 / 8192 / 复测 / 30 s	1	3	1.71	2.43	3 / 100.0%
竞争 / 8192 / 首次	1	3	4.33	0.00	3 / 0.0%
竞争 / 8192 / 立即复测	1	3	1.76	2.50	3 / 100.0%
竞争 / 8192 / 竞争后	1	3	1.70	2.63	3 / 100.0%
竞争 / 8192 / 再次复测	1	3	1.76	2.52	3 / 100.0%
周期 / 8192 / 首次	4	4	11.42	—	1 / 0.0%
周期 / 8192 / 复测 / 1	4	4	2.02	9.38	1 / 100.0%
周期 / 8192 / 复测 / 2	4	4	2.16	9.25	1 / 100.0%
周期 / 8192 / 复测 / 3	4	4	2.18	9.26	1 / 100.0%
周期 / 8192 / 复测 / 4	4	4	2.26	9.15	1 / 100.0%
周期 / 8192 / 复测 / 5	4	4	2.39	9.03	1 / 100.0%
周期 / 8192 / 复测 / 6	4	4	2.33	9.08	1 / 100.0%

运行期间的缓存变化

已获得 358 个有输入量的有效计数窗口，词元加权缓存比例为 20.29%，窗口范围 0.00%–100.00%。这些窗口可能包含不同测试负载，只用于描述时间变化，不作为缓存保留或稳定命中的证明。 窗口比例标准差为 25.77 个百分点。

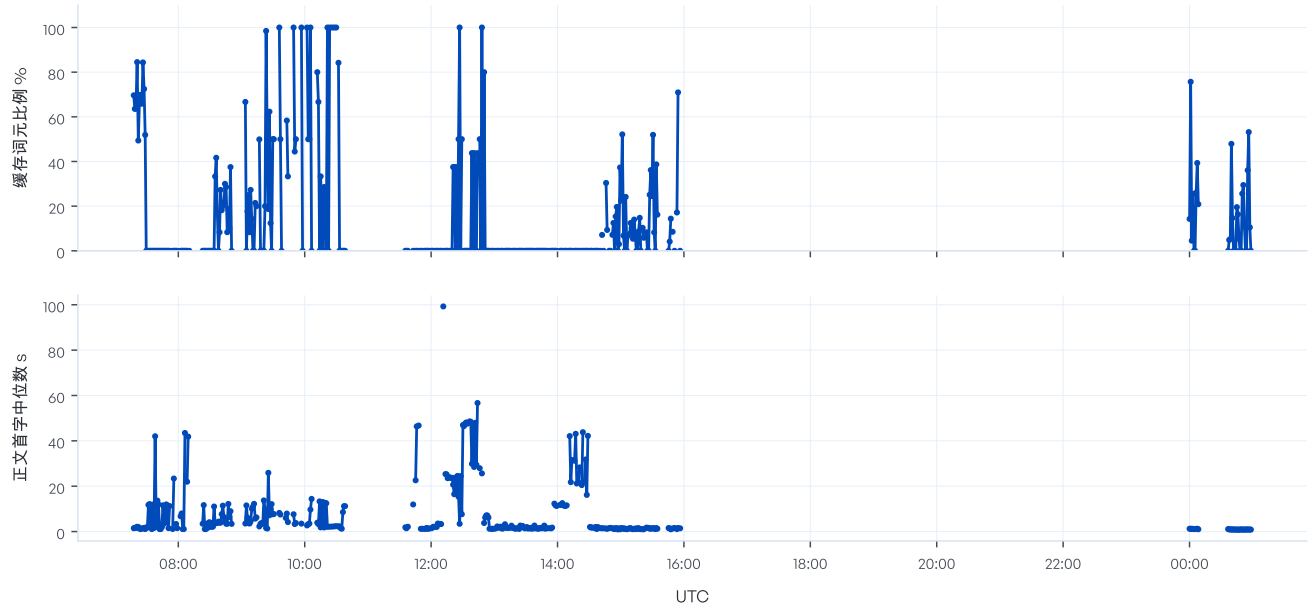


图 08–12 时间观察

约60秒窗口的计数增量比例与同期首字延迟；不同工作负载的变化不能直接归因于缓存。

判定与后续验证

只有同一参数、完整响应、无重试且计数核对通过的区组，才给出区组缓存词元比例；并发区组无法拆成逐请求命中率。空闲组每个前缀只探测一次，避免探测本身刷新保留状态；竞争实验只覆盖约131,072个干扰输入词元，不声称达到缓存容量上限。周期实验只有10分钟计划跨度，连续负载按实际执行时长报告。下一步以真实业务热度分布、更多独立时段及不同竞争强度验证可重复性；容量与成本模型暂不加入未经验证的缓存收益。

扩展长度：覆盖、实际生成与重复性

长度扩展完成 290/299 次，205 次实际输出达到上限的98%–100%。已完成且达到目标的最大输出为 4,096 词元；仅适用于对应输入和单次条件。

公网长度扩展采用自然结束，控制方式见第03节；以下同时报告生成上限与实际生成量。 执行模式与证据

表 08–18 扩展长度：覆盖、实际生成与重复性

负载	完整 / 计划	源站计数数	实际输出范围	达成率中位数	实际长度达成数
输出参数校准	2/2	2	2–2	0.2%	0
输入轴线	24/24	24	1,024–1,024	100.0%	24
输出轴线	9/13	9	1,826–4,955	100.0%	5
平衡长度	9/12	9	2,048–5,943	100.0%	6
近边界	1/2	1	1,024–1,024	100.0%	1
长前缀	36/36	36	1,024–1,024	100.0%	36

负载	完整 / 计划	源站计数数	实际输出范围	达成率中位数	实际长度达成数
业务锚点	31/32	31	25–4,096	16.9%	自然结束
代表条件预热	10/10	10	1,024–4,096	100.0%	7
重复区组	168/168	168	1,024–4,096	100.0%	124

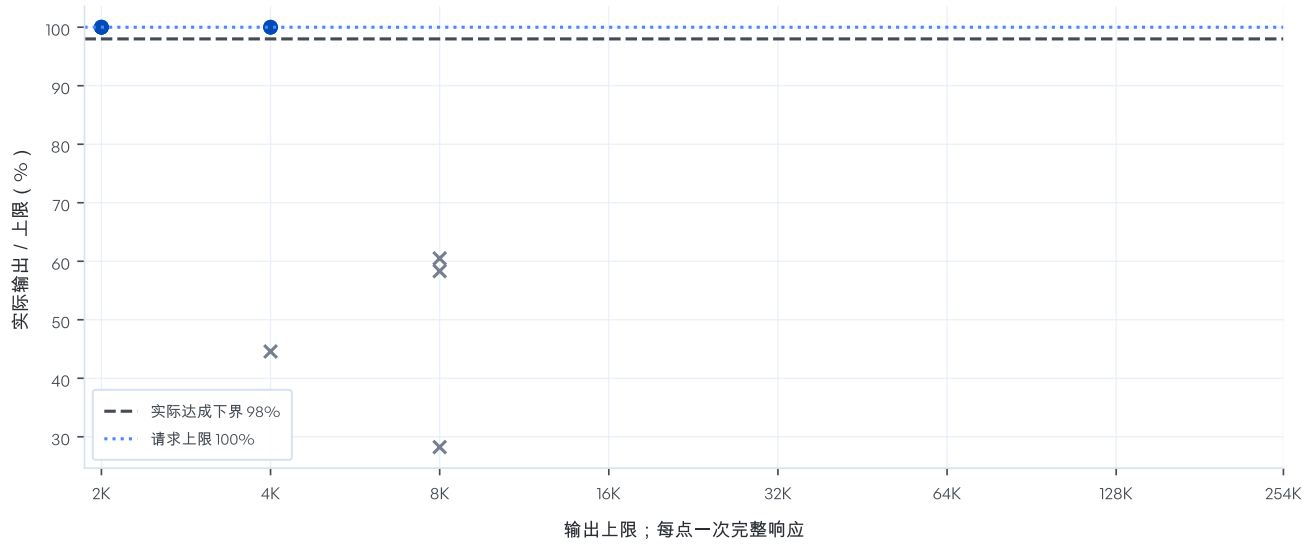


图 08–13　输出达成

逐档比较源站实际生成与请求上限；空白表示没有原始计数，不能按零处理。

以下仅纳入实际输入误差≤1%、实际输出达成98%–100%的完整请求。数值为中位数；单样本格就是该次观测，不输出尾分位。

表 08–19　扩展长度：覆盖、实际生成与重复性

输入→输出上限	合格 / 完整	实际输出	首字 s	完成 s	每词元 ms（估算）
1K → 1K	3/3	1,024	1.20	25.14	23.2
2K → 1K	3/3	1,024	1.45	23.38	21.5
4K → 1K	3/3	1,024	2.12	25.90	23.2
8K → 1K	3/3	1,024	3.60	25.49	21.6
16K → 1K	3/3	1,024	5.91	26.80	20.0
32K → 1K	3/3	1,024	12.00	33.21	20.8
64K → 1K	3/3	1,024	23.33	45.91	21.8
128K → 1K	3/3	1,024	46.47	68.05	21.1
1K → 2K	3/3	2,048	1.30	47.45	22.6
1K → 4K	2/3	4,096	1.20	88.58	21.3
2K → 2K	3/3	2,048	1.46	45.56	21.4
4K → 4K	3/3	4,096	2.08	88.44	21.1
254K → 1K	1/1	1,024	99.27	121.45	21.7

当前 6 个重复区组满足容量比较条件；单次边界探针不混入稳态容量。

表 08–20 扩展长度：覆盖、实际生成与重复性

输入→输出 / 并发	有效区组数	合计吞吐 词元/s	区组吞吐范围
32K → 1K / 1	3	33.0	31.0—34.8
32K → 1K / 4	3	55.5	54.9—55.9

64K / 128K前缀诊断目前有 17/18 个有效复测窗口；命中比例与目标重合分别报告。

表 08–21 扩展长度：覆盖、实际生成与重复性

输入 / 目标重合	有效 / 计划对	窗口缓存比例 中位 / 范围
64K / 0%	2/3	0.0% / 0.0%—0.0%
64K / 50%	3/3	37.5% / 37.5%—37.5%
64K / 100%	3/3	100.0% / 100.0%—100.0%
128K / 0%	3/3	0.0% / 0.0%—0.0%
128K / 50%	3/3	43.7% / 43.7%—43.7%
128K / 100%	3/3	100.0% / 100.0%—100.0%

提前结束、参数拒绝、时间不足与未开始均保留原状态。新增长度结果不外推到未测并发或年度收益。 CSV · JSON

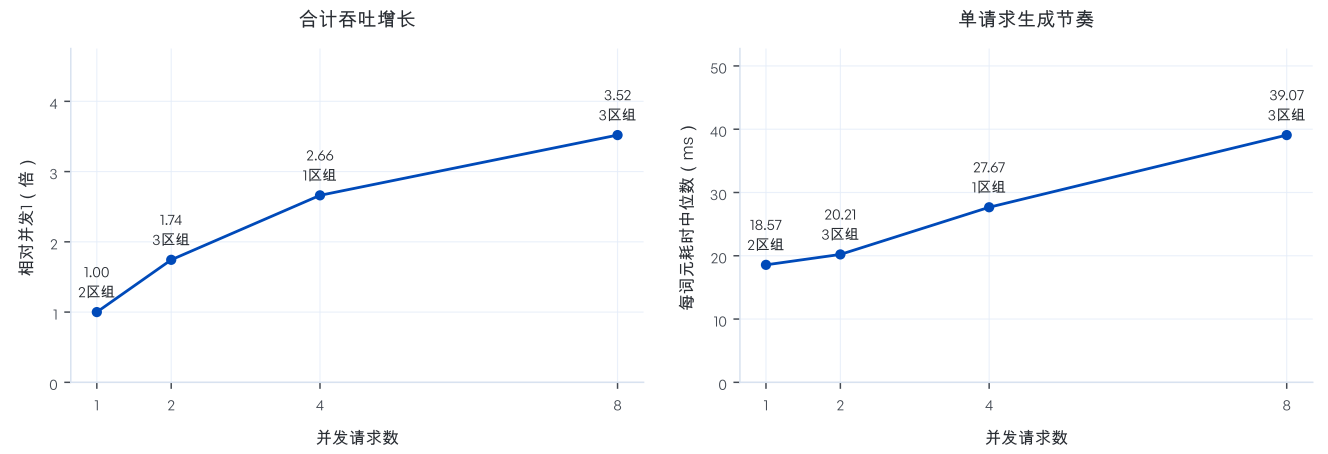


图 08–14 并发扩展的收益与代价

左侧为同题库合计吞吐相对并发1的倍数；右侧为每请求平均词元耗时的中位数。各条件保留实际完整区组数；曲线是描述性比较，不是配对因果效应。

固定长输出：原生引擎的可达范围

本组以本地认证的原生生成接口发送精确词元输入，温度为0，忽略结束词元并固定生成数；流式间隔设为128词元。解码速率使用引擎同一进程的生成计数与时间，不能与公网正文首字延迟混为同一指标。输入加输出不超过262,144；1,024输入＋260,096输出保留1,024词元余量，因此这里的最长目标是254K输出。

表 08–22 固定长输出：原生引擎的可达范围

输入→输出词元	完整 / 计划	解码词元/s，中位数［范围］	请求耗时中位数s	草稿接受比例
1,024 → 1,024	1/1	62.24 [62.24–62.24]	16.91	0.940
1,024 → 8,192	3/3	55.64 [54.17–59.24]	147.62	0.832
1,024 → 16,384	3/3	61.35 [54.15–61.51]	267.46	0.931
1,024 → 32,768	3/3	60.50 [56.93–61.17]	541.80	0.918
1,024 → 65,536	1/1	60.32 [60.32–60.32]	1,086.82	0.924
1,024 → 131,072	1/1	61.96 [61.96–61.96]	2,115.69	0.959
1,024 → 260,096	1/1	61.61 [61.61–61.61]	4,222.17	0.961
16,384 → 16,384	1/1	62.10 [62.10–62.10]	270.54	0.963
32,768 → 32,768	1/1	60.88 [60.88–60.88]	548.28	0.938
65,536 → 65,536	1/1	60.27 [60.27–60.27]	1,109.63	0.926

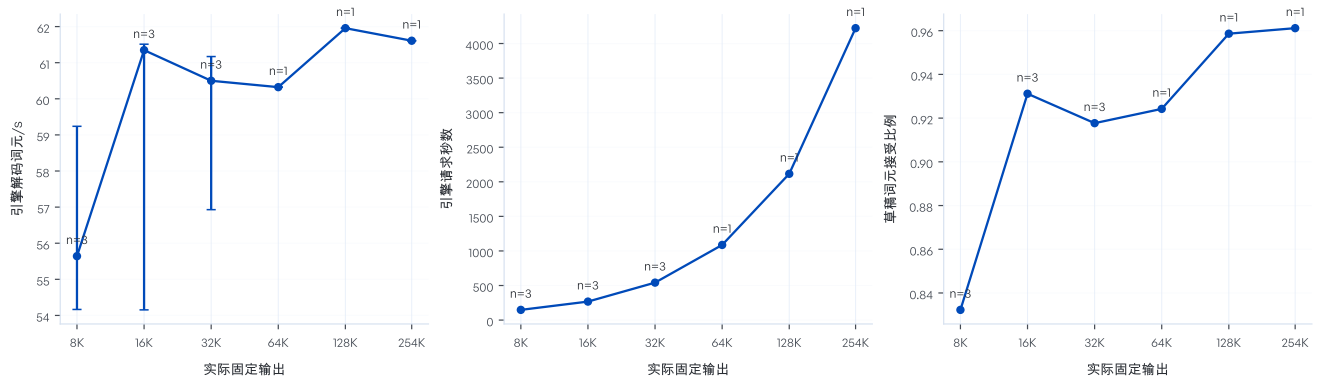


图 08–15 长输出的生成速率与工作量

输入固定1K；误差线为已完成独立请求的观测范围，n=1只是一个样本。草稿接受比例按原生引擎字段展示。未完成目标没有性能点。

强制长度可能产生重复文本、空白或特殊词元；计数达成只证明计算负载执行到该长度，不证明正文有用性。MTP接受情况与具体生成序列有关，不能将此速率直接用于所有业务或年度产能估算。每格三次的条件报告范围；更长单次探针不提供尾分位或总体置信区间。

可见文本检查中，8条完整请求出现连续至少256个相同字符；该标记随原始输出保留，不作为答案能力评分。

新增请求与计时CSV

多场景GPU剖析与测量开销

每对使用相同输入与256输出词元，交替执行顺序；每臂发送前在空闲服务清空前缀缓存。剖析只捕获预填充和四个解码步骤，完整请求耗时比衡量这项诊断对该请求的影响，不用于修正所有历史样本。

表 08–23 多场景GPU剖析与测量开销

输入 / 并发	配对数	剖析 / 无剖析耗时比	两臂缓存词元总数
1,024 / 1	3	1.162 [1.124–1.220]	0

输入 / 并发	配对数	剖析 / 无剖析耗时比	两臂缓存词元总数
8,192 / 4	3	1.236 [1.182–1.263]	0
32,768 / 1	3	1.084 [0.931–1.186]	0

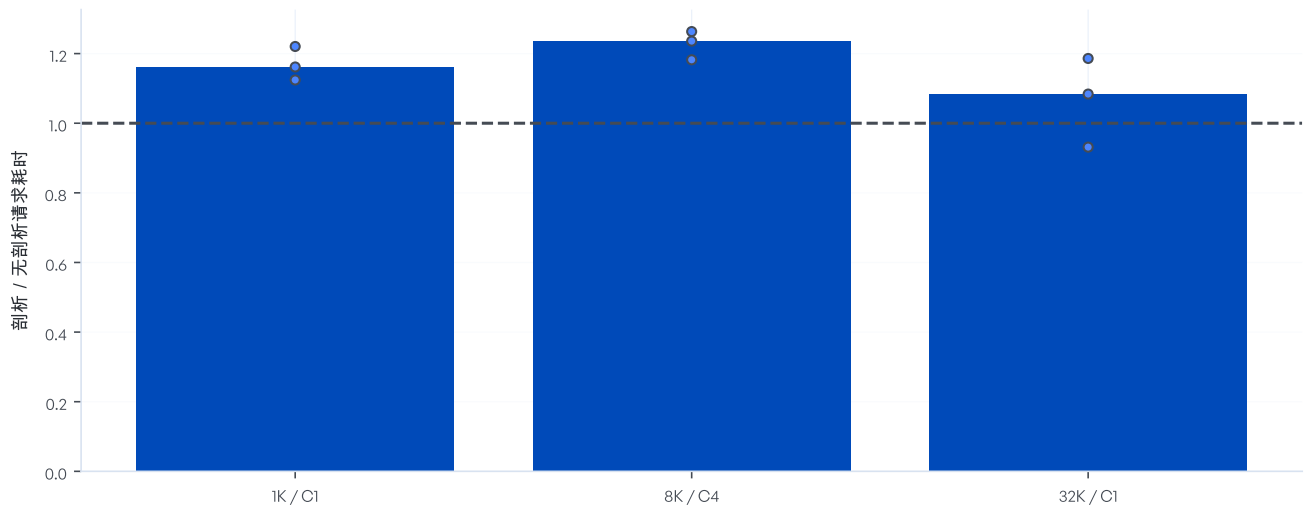


图 08–16 剖析开销的配对分布

柱为中位数，点为独立配对；1表示两臂请求耗时相同。

64K前缀复用的独立核验

表 08–24 64K前缀复用的独立核验

独立前缀	首次 / 复用	实际缓存词元	缓存比例	引擎首词元秒数
2	首次	0	0.000	20.564
2	复用	57344	0.875	2.766
3	首次	0	0.000	20.746
3	复用	57344	0.875	2.682
1	首次	0	0.000	20.457
1	复用	57344	0.875	2.664

每个前缀在清空缓存后首次发送，再立即复用；本表核验即时复用，不新增长期保留或缓存容量结论。

09 · 持续性能、热状态与资源

独立到达与持续运行

表 09–01 独立到达与持续运行

区组	到达 / 发送 / 完成	本地拒绝	观测秒数
开放到达与混合负载 · 参考速率的 0.5 倍	120 / 120 / 120	0	624.9

区组	到达 / 发送 / 完成	本地拒绝	观测秒数
开放到达与混合负载 · 参考速率的 0.25 倍	57 / 57 / 57	0	607.9
开放到达与混合负载 · 参考速率的 1.25 倍	296 / 243 / 243	53	617.4
历史分段观测（5段，包含中断）	638 / 638 / 635	0	34,580.3
开放到达与混合负载 · 参考速率的 1 倍	226 / 203 / 203	23	616.4
开放到达与混合负载 · 参考速率的 0.75 倍	160 / 160 / 160	0	612.3

分析阈值：正文首字延迟阈值分别为 1、2、5、**10 秒**，估算平均每词元耗时阈值分别为 20、50、100 毫秒；这些是敏感性分析条件，不是对外承诺的服务等级协议。全局并发上限 8；队列最多 32，等待最多 **5 秒**。持续稳定性测试以 **1 小时**、**2,701 次**或预算 / 截止任一先到为止。 达标吞吐逐条件数据表

下表选取三组分析阈值；每格为达标请求/s及其占全部正式到达的比例。其余阈值组合见逐条件数据表。混合负载只统计配对短请求。

表 09–02 **独立到达与持续运行**

条件	1 s / 20 ms	2 s / 50 ms	5 s / 100 ms
开放到达与混合负载 · 参考速率的 0.25 倍	0.012 / 12.2%	0.058 / 61.0%	0.096 / 100.0%
开放到达与混合负载 · 参考速率的 0.5 倍	0.013 / 6.7%	0.150 / 77.9%	0.185 / 96.2%
开放到达与混合负载 · 参考速率的 0.75 倍	0.009 / 3.5%	0.212 / 81.2%	0.253 / 97.2%
开放到达与混合负载 · 参考速率的 1 倍	0.000 / 0.0%	0.208 / 57.1%	0.304 / 83.8%
开放到达与混合负载 · 参考速率的 1.25 倍	0.000 / 0.0%	0.154 / 31.8%	0.326 / 67.5%

节点资源

先查看与同一并发区组对齐的均值，再看整个观测时段的变化。监控有空档时不插值。

与自然负载区组对齐的资源表现

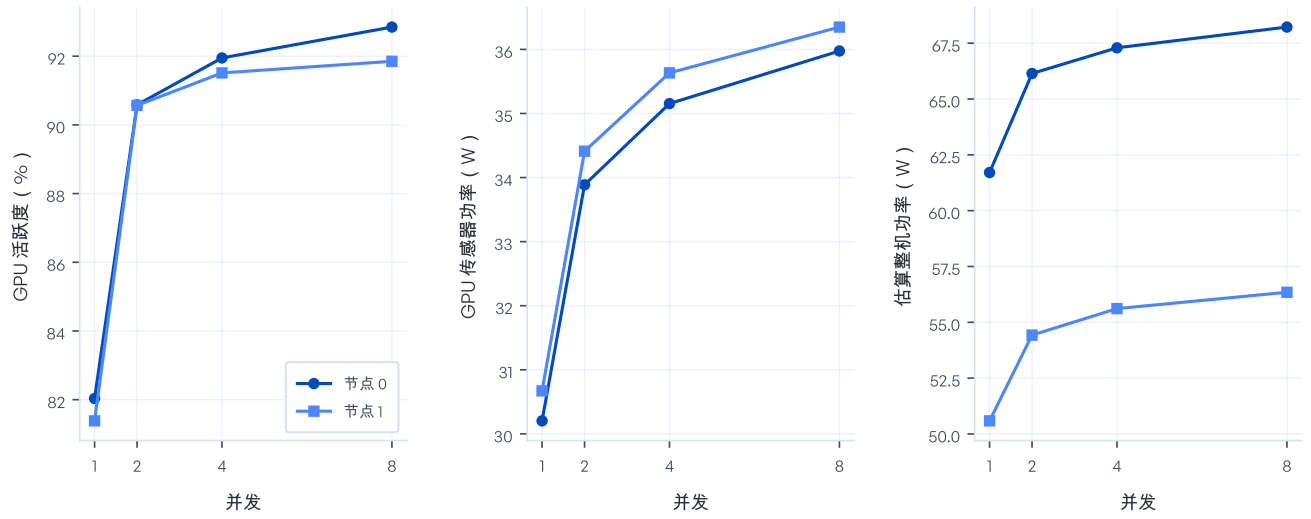


图 09-01 并发与双节点资源

与吞吐比较使用相同的自然负载区组，按有效采样覆盖时间加权。相邻采样超过 20 秒或字段缺失的区间不插值。GPU 传感器功率与估算整机功率是不同视图，不相加。

表 09-03 与自然负载区组对齐的资源表现

并发 / 节点	GPU 活跃度均值	GPU / 整机估算 W	温度峰值 °C	活跃度 / 功率覆盖
1 / 0	82.0%	30.2 / 61.7	65.0	100.0% / 100.0%
1 / 1	81.4%	30.7 / 50.6	66.0	100.0% / 100.0%
2 / 0	90.6%	33.9 / 66.1	70.0	100.0% / 100.0%
2 / 1	90.6%	34.4 / 54.4	70.0	100.0% / 100.0%
4 / 0	91.9%	35.2 / 67.3	70.0	100.0% / 100.0%
4 / 1	91.5%	35.6 / 55.6	70.0	100.0% / 100.0%
8 / 0	92.8%	36.0 / 68.2	68.0	100.0% / 100.0%
8 / 1	91.9%	36.3 / 56.3	69.0	100.0% / 100.0%

读法：覆盖率是该条件全部区组时长中，具有有效相邻采样的时间占比；均值只在覆盖部分计算。即使 GPU 活跃度接近 100%，也不能仅凭这一字段认定计算单元或内存带宽已经饱和。跨节点功率差异还需要结合频率、任务分工和采样字段语义解释。

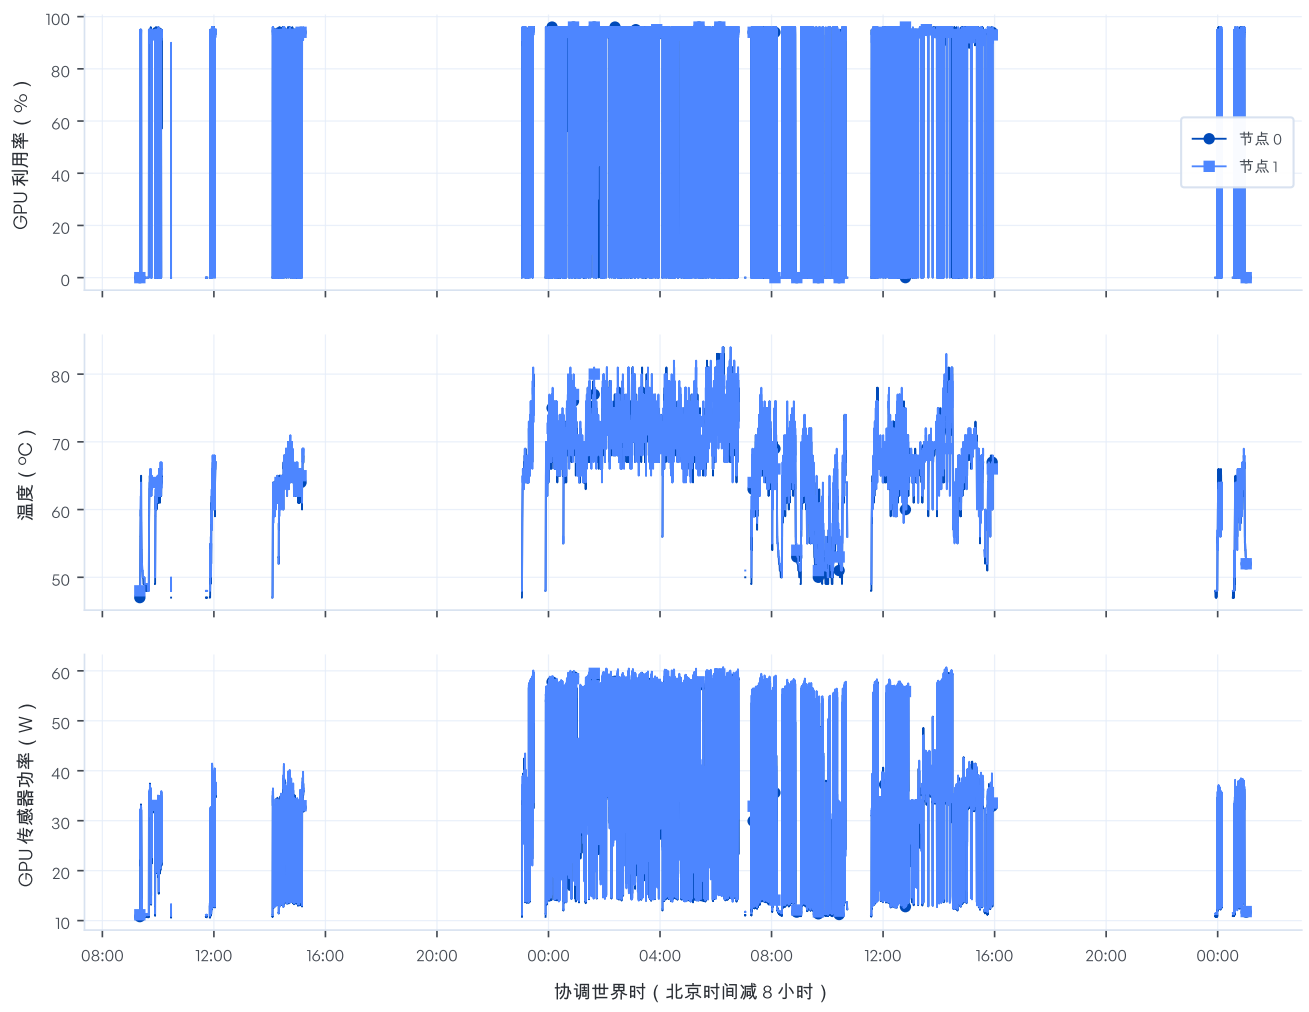


图 09-02　双节点资源时序

包含预热和空闲；负载比较采用上表对齐后的统计。

原始引擎与内存时序见附录B。独立网络微基准约**109 Gb/s**，只反映该传输测试；现有证据不足以把模型瓶颈归因于互联、内存或计算中的单一因素。

本节首先展示模型服务窗口监控；独立GPU持续负载在下文按实际覆盖列出。两类持续测试的工作量与基线不同，不能合并为一段稳定性时长。传感器、估算整机与插座电量的边界分别保留；缺少插座电量时，后续成本仍为情景估算。

独立硬件持续负载：性能保持与热状态

计划依次执行计算**60分钟**、带宽**60分钟**、混合**120分钟**。每阶段先采集该负载**5分钟**基线，再开始正式时长；混合阶段交替执行计算与带宽任务，分别统计两类速率。每**10分钟**窗口的中位速率除以同负载基线中位数，得到保持率。窗口、阶段和服务测试时长分别统计，不能相加为同一连续业务稳定性试验。

混合负载采用独立预热和基线；温度达到**85°C**时暂停提交GPU工作，低于**75°C**持续**30秒**后恢复。只汇总本次执行的计时和退避，先前中断尝试独立保存。计算、带宽两阶段保留原测量时的**85°C**停止规则，不能视为完全相同的热控制条件。

表 09-04　独立硬件持续负载：性能保持与热状态

节点	负载	实测 / 计划分钟	校验样本	温度中位 / 最大°C	SM中位MHz	传感器kWh	积分时间覆盖
0	计算	60.0 / 60	3359	81.0 / 82.0	2262	0.0888	100.0%
0	带宽	60.0 / 60	3485	65.0 / 66.0	2522	0.0318	100.0%

节点	负载	实测 / 计划分钟	校验样本	温度中位 / 最大°C	SM中位MHz	传感器kWh	积分时间覆盖
0	交替混合	120.0 / 120	5832	75.0 / 86.0	2405	0.1082	100.0%
1	计算	60.0 / 60	3405	83.0 / 84.0	2249	0.0888	100.0%
1	带宽	60.0 / 60	3490	67.0 / 67.0	2515	0.0324	100.0%
1	交替混合	120.0 / 120	6527	74.0 / 86.0	2431	0.1178	100.0%

混合负载的温度控制与吞吐口径

表 09-05 混合负载的温度控制与吞吐口径

控制项	规则
触发退避	温度≥85°C或读数缺失，暂停提交GPU工作
自动恢复	温度低于75°C连续稳定30秒
最长单次退避	600秒；超时结束本轮并恢复服务
时间与停止边界	不自动延长固定截止；退避期间继续响应手动停止、租约和内存保护

混合负载采用该策略；计算和带宽阶段保留各自测量时的温控条件。退避发生在CUDA提交边界，冷却时间不进入CUDA事件计算速率；实际吞吐另按计量工作量 / 整个阶段墙钟时长统计，包含退避、校验和混合阶段另一类工作。退避事件独立留档；未完成计时单元不计为有效性能样本。

驱动限制原因 | Active为驱动报告该限制原因生效，Not Active为该次采样未生效；不支持或缺失不计作未生效。下表统计采样数，不能直接换算限速持续时间或性能损失。

表 09-06 混合负载的温度控制与吞吐口径

节点	阶段	驱动原因标志	Active采样数	已知状态采样数
0	mixed	sw_thermal_slowdown	0	7196
0	mixed	hw_thermal_slowdown	0	7196
0	mixed	hw_slowdown	0	7196
0	mixed	sw_power_cap	0	7196
1	mixed	sw_thermal_slowdown	0	7197
1	mixed	hw_thermal_slowdown	0	7197
1	mixed	hw_slowdown	0	7197
1	mixed	sw_power_cap	0	7197

混合负载：执行速率与包含退避的实际吞吐

表 09-07 混合负载：执行速率与包含退避的实际吞吐

节点	正常执行速率中位数	阶段墙钟吞吐	完整计时单元内退避秒数	退避 / 阶段时长	含退避计时单元数
0	gemm: 87.57 TFLOP/s; triad: 221.62 GB/s	gemm: 36.39 TFLOP/s; triad: 91.72 GB/s	1178.8	16.4%	38

节点	正常执行速率中位数	阶段墙钟吞吐	完整计时单元内退避秒数	退避 / 阶段时长	含退避计时单元数
1	gemm: 86.99 TFLOP/s; triad: 217.28 GB/s	gemm: 40.63 TFLOP/s; triad: 100.93 GB/s	434.4	6.0%	14

阶段墙钟吞吐以该类已计量工作量除以整个混合阶段时间，包含另一类工作、数值校验和冷却等待。因此它与正常执行速率的差值不能全部归因为退避。退避秒数只汇总已完成的计时单元；中断单元的退避仍保留在原始事件记录中。

本轮冷却由测试程序的温度阈值触发；两节点的有效驱动采样均未记录热降频、硬件限速或功率限制标志为Active。该结果描述约1秒间隔的采样证据，不能排除采样间的短暂事件。部署容量评估应同时观察正常执行速率和包含等待的墙钟吞吐。

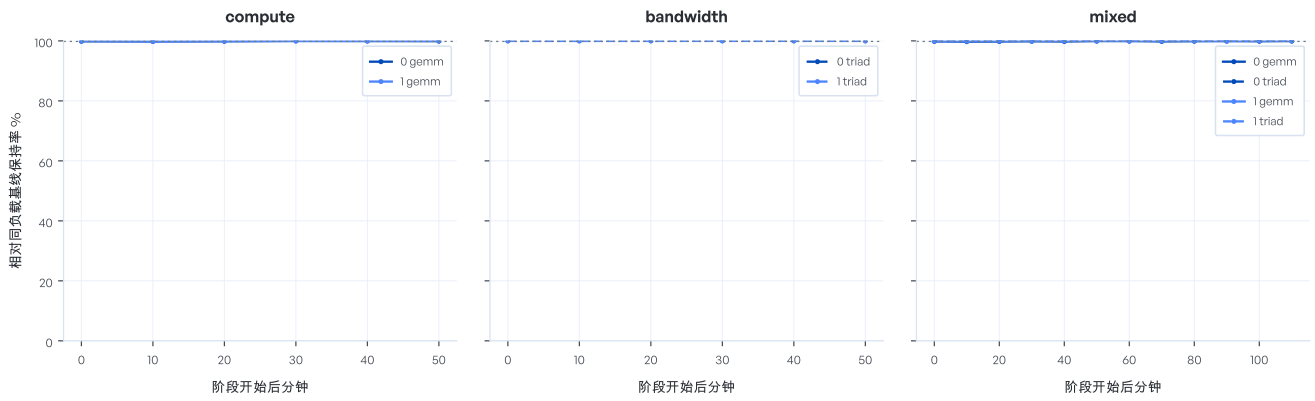


图 09–03 分窗性能保持

仅显示完整10分钟窗口；末尾不足10分钟的样本仍保留于统计文件。相同节点、负载、阶段相互比较；100%为该阶段5分钟基线，不是硬件理论峰值。

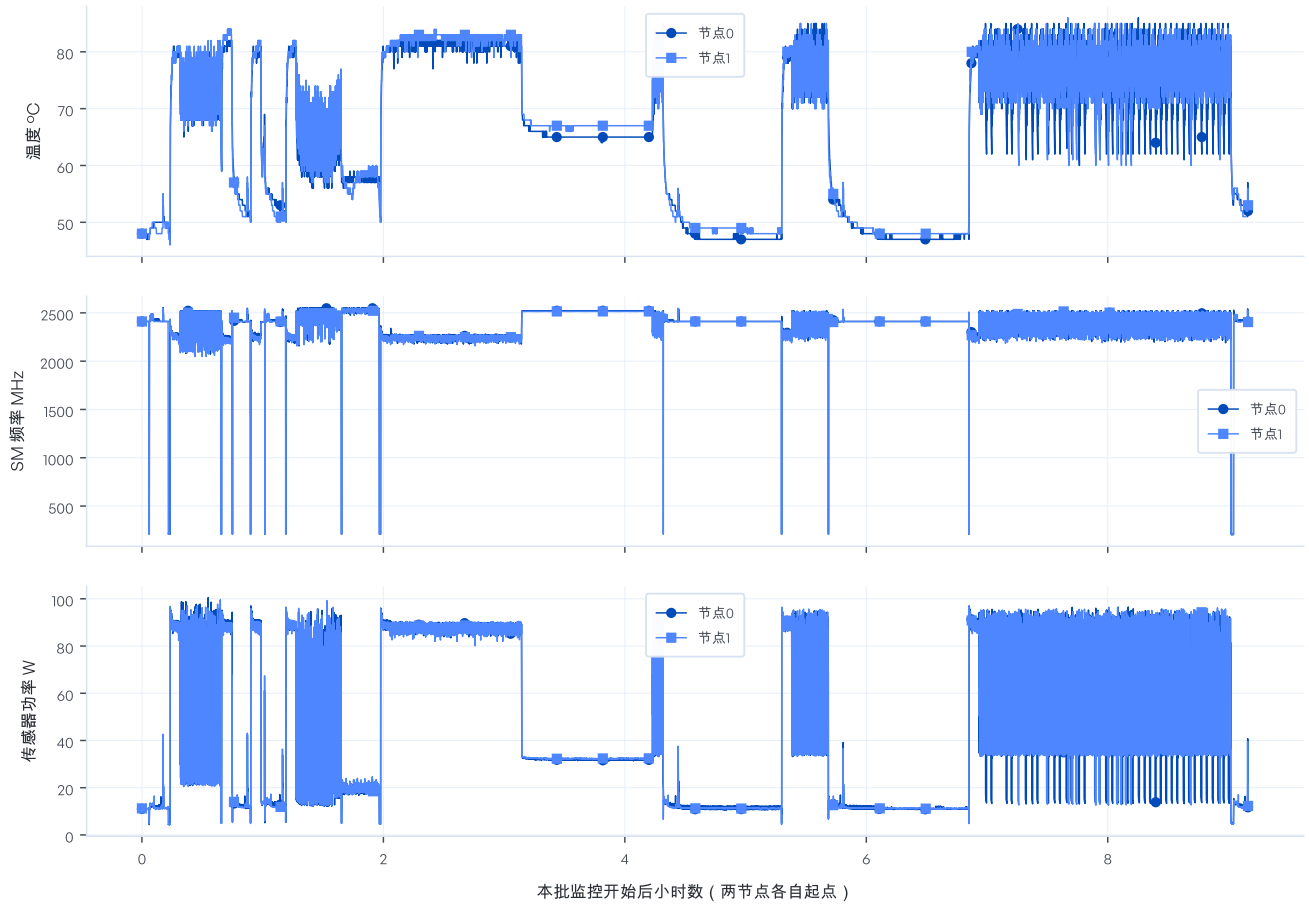


图 09–04　本批节点资源时间线

包含预热、单项扫描和持续负载，以原始阶段回执确定各时间窗；超过5秒的采样间隔不连线。传感器功率不等同整机插座功耗。

能量以相邻有效功率采样作梯形积分，只纳入间隔不超过**5秒**的片段，并报告覆盖比例；缺测片段不补零或外推。当前没有插座电表证据，采购折旧与**1 / 3 / 5年**投资回报仍使用第11节明示的整机用电情景，不能用传感器能量替换整机电费。

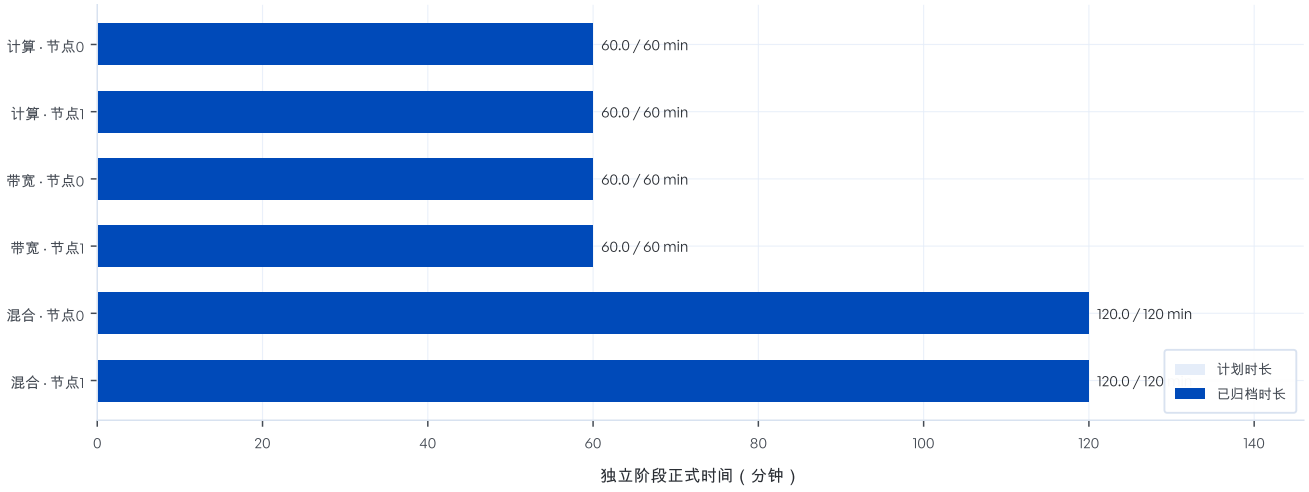


图 09–05　持续负载覆盖

实色为本次有效正式时长，浅色为计划剩余时长；各阶段独立，不累计为连续稳定性。

原638次到达的持续阶段分为五段，34,580.3秒为含中断的跨度，不用于判断连续稳定性或连续达标吞吐。下列独立窗口若已完成，则单独报告，不能与前述五段相接。

独立公网区组、混合干扰与连续窗口

表 09-08 独立公网区组、混合干扰与连续窗口

测试条件	发送 / 完整	窗口秒数	源站输出词元/s	正文首字中位 / 95分位s
业务 / 长度补充区组	4/4	62.3	108.44	1.67 / 1.68
干扰配对4 孤立	32/32	145.1	42.11	0.85 / 1.20
干扰配对0 孤立	32/32	151.2	42.99	0.97 / 1.58
干扰配对4 混合	36/36	154.2	42.07	6.49 / 12.77
业务 / 长度补充区组	8/8	398.5	35.26	3.28 / 4.03
干扰配对2 孤立	32/32	171.3	35.39	0.90 / 1.15
连续运行	599/599	3,600.2	64.77	1.01 / 1.49
短题库并发4参考组	60/60	196.4	117.65	0.90 / 1.15
干扰配对2 混合	39/39	173.2	39.46	1.92 / 12.57
短题库并发4参考组	60/60	194.8	118.45	0.94 / 1.45
业务 / 长度补充区组	4/4	255.7	38.53	11.95 / 13.75
短题库并发4参考组	60/60	201.1	118.35	0.90 / 1.24
干扰配对0 混合	33/33	159.3	39.01	4.32 / 13.88

吞吐仅在源站词元计数覆盖全部完整响应时计算；开放到达保留本地拒绝。干扰效应必须比较同一配对中的短请求，整体混合吞吐不能替代短请求时延变化。

长请求对短请求的等待影响

每对复用相同短请求及到达序列；混合臂另外加入长请求。等待从预定到达时刻开始，包含本地排队和已确认重试。只有两臂全部32条短请求均有正文首字时才计算比值；1表示相同等待，越大表示短请求等待越长。

表 09-09 长请求对短请求的等待影响

配对	完整/到达：孤立→混合	短请求首字中位数s	混合/孤立比值
1	32/32 → 25/32	0.98 → 1.40	—
3	32/32 → 31/32	0.91 → 2.16	—
5	32/32 → 28/32	0.87 → 5.17	—

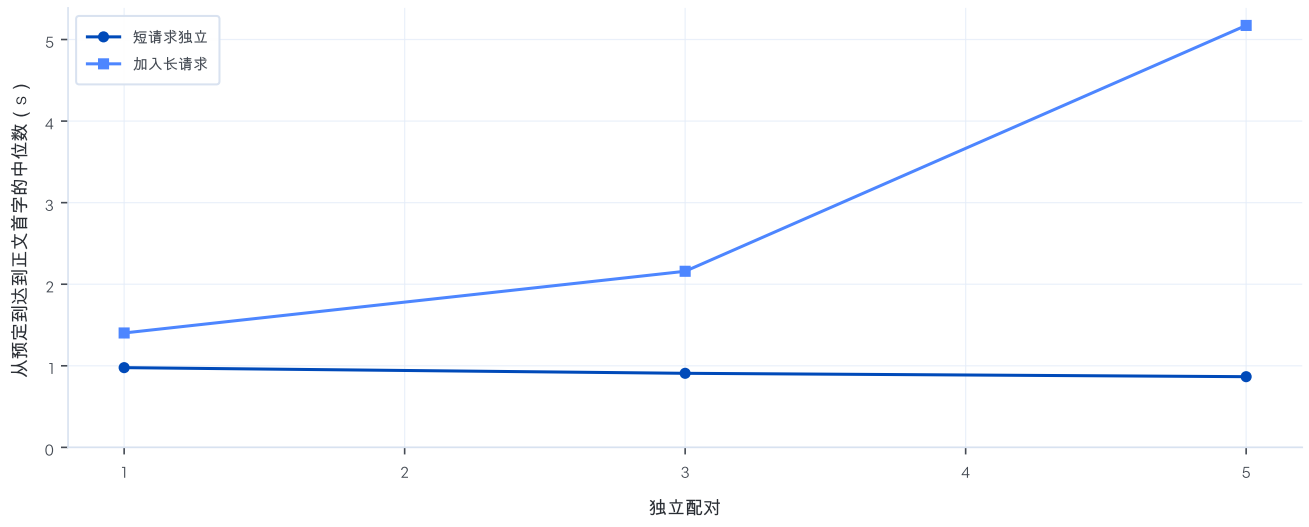


图 09–06　短请求等待的配对比较

逐对保留样本和完整性；比值只在完整配对间比较。

连续服务的五分钟窗口

表 09–10　连续服务的五分钟窗口

独立尝试/分钟	到达/完整	首字中位/95分位s	完成响应产出词元/s
1 / 0–5	55/54	1.03 / 1.67	71.63
1 / 5–10	45/45	0.99 / 1.27	48.54
1 / 10–15	50/50	1.08 / 1.63	67.85
1 / 15–20	59/59	0.99 / 1.56	76.47
1 / 20–25	58/58	1.07 / 1.65	69.37
1 / 25–30	40/40	0.98 / 1.36	55.57
1 / 30–35	55/55	0.97 / 1.38	72.35
1 / 35–40	51/51	1.08 / 1.43	65.93
1 / 40–45	55/55	1.04 / 1.49	67.71
1 / 45–50	33/33	1.04 / 1.65	50.93
1 / 50–55	53/53	1.14 / 1.35	70.85
1 / 55–60	46/46	1.12 / 1.58	60.13

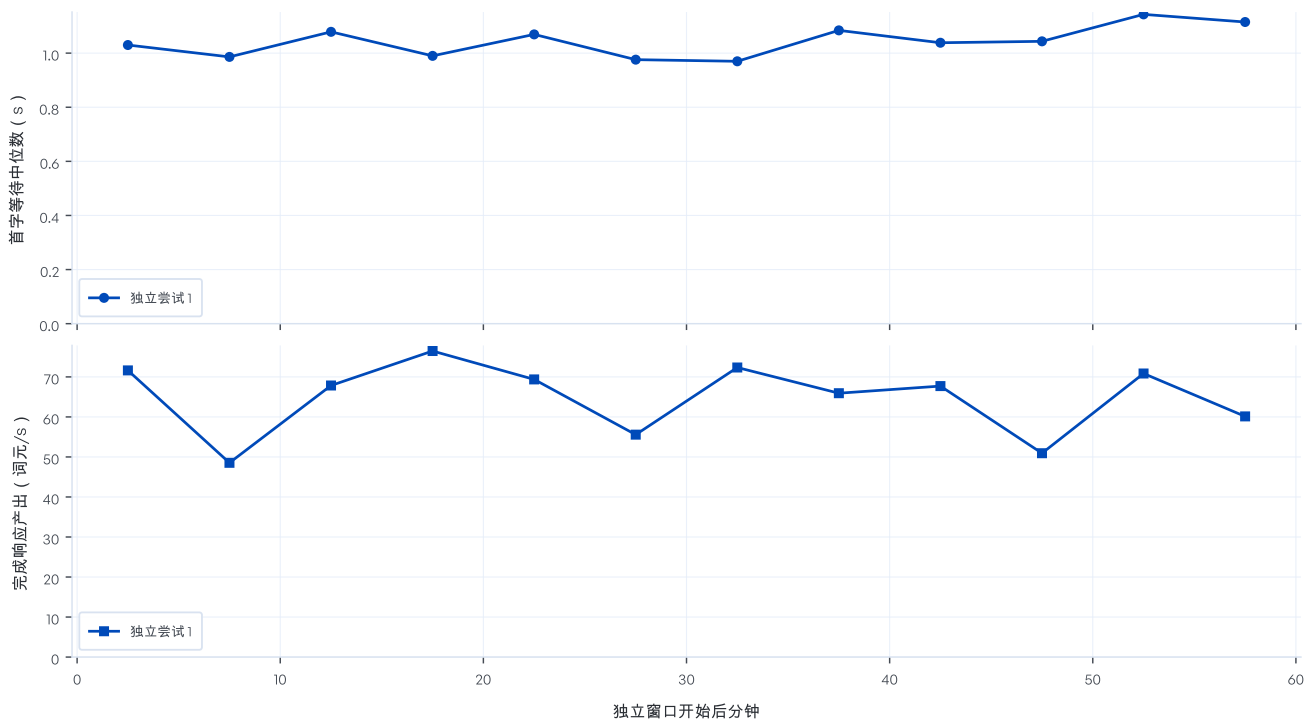


图 09–07　连续窗口中的等待与完成产出

延迟按预定到达窗口归组；词元在响应完成时计入相应窗口，因此不是引擎逐秒生成速率。原始预热标记保留，早期窗口包含启动过渡。

10 · 跨层解释与H200技术对照

前面的实验分别给出资源上限、执行效率和用户体验。本节把这些观测联系起来：同一现象可以由多个机制产生，只有匹配工作量的对照才能缩小解释范围。下表将已建立的结论与仍需验证的机制分开。

表 10-01 跨层解释与H200技术对照

维度	联合观测	可支持的解释
计算与形状	矩阵规模 / 精度扫描、独立算子与引擎GPU轨迹。	实际速率依赖规模与实现；最高TFLOP/s不等于模型词元吞吐。缺少计算管线计数，不能确定唯一计算瓶颈。
内存与协作	8 GiB复制约223–227 GB/s；1 GiB AllReduce总线口径约21.81 GB/s。	本地读写与跨节点同步有不同资源预算；各自字节口径不同，不能用两者比值推算模型加速。
并发与等待	短题库并发1→8，合计吞吐45.1→158.9词元/s；单请求词元耗时随之增加。	并发提升系统处理量，需同时检查用户等待；未建立无限扩展或长期容量。
缓存与上下文	公网复用诊断、节点词元计数和原生引擎立即复用分别计量。	重复输入、实际缓存量和等待收益是三个量；短时复用不能证明任意业务的保留期限。
温度与保持率	计算、带宽与混合负载分别完成60 / 60 / 120分钟；驱动原因字段按采样覆盖解释。	可评价已测分段的性能保持；温度阈值、驱动限速和性能损失不能互相替代。

统计解释采用四类证据：直接观测、匹配对照、官方规格、经济情景。仅前两类来自本次性能实验；对照存在顺序效应、样本量或资源状态限制时随表注明。 硬件计数器仅覆盖单核函数诊断探针；尚缺代表性硬件与模型工作负载的计数，不能据此推导模型Roofline。

GB10与H200：按资源功能对齐的架构参照

比较单位首先固定为单颗GB10（位于一台DGX Spark）与单颗H200 SXM；多设备协作另注明拓扑。指标按“存放数据、向计算核心供数、执行运算、交换分片、跨服务器扩展”的功能对齐，不要求底层技术同名。DGX Spark为完整计算机，H200 SXM为服务器加速器，容量归属、功耗边界与互连范围需随数值一起阅读。

表 10-02 GB10与H200：按资源功能对齐的架构参照

技术功能	DGX Spark / GB10	H200 SXM / 指定服务器	对齐方式与解释
容纳权重、KV与工作空间	128 GB LPDDR5x CPU/GPU共享统一内存	141 GB HBM3e GPU本地内存	容量接近；Spark系统与CPU也占用同一内存池。双Spark的256 GB为分布式容量。
向GPU供给本地数据	273 GB/s LPDDR5x标称	4,800 GB/s HBM3e标称	同属本地内存数据供给；H200规格比值17.58倍，仅是带宽比，不是推理加速比。
CPU与GPU交换数据	共享内存与芯片内NVLink-C2C；本报告不赋予未核验的C2C峰值。	PCIe Gen5:128 GB/s 双向合计；主机与HBM分离	比较协同路径与迁移需求；C2C不充当两台Spark之间的互连。
同一模型分片间协作	双Spark经RoCE；启用200 Gb/s端口＝25 GB/s单向标称。	H200 SXM经NVLink；每GPU900 GB/s双向合计，折算发送方向总和450 GB/s。	功能相同但拓扑不同：网卡端口对GPU全部链路；不是单链路或单对GPU性能比。
向更多服务器扩展	每台本次启用1×200 Gb/s＝25 GB/s；两个逻辑接口不相加。	DGX H200示例：每网卡400 Gb/s＝50 GB/s；8 GPU整机8张，合计3.2 Tb/s。	归一到单网卡时规格为2倍；整机聚合依赖拓扑、并发与网络。
低精度矩阵加速	Blackwell支持FP8与NVFP4；本轮8192^3稠密实测见下表。	Hopper原生FP8；稠密约1,979 TFLOP/s、2:4稀疏3,958 TFLOP/s（规格）。	FP4与FP8承担低精度加速功能，但数值格式、库路径与误差不同，不相除作加速倍数。

技术功能	DGX Spark / GB10	H200 SXM / 指定服务器	对齐方式与解释
功率与供电约束	GB10 SoC TDP140 W；Spark电源额定240 W。	H200 SXM最高700 W可配置TDP；主机功耗另计。	都是设计规格，边界不同；不用于直接计算词元/J或整机电费。

DGX Spark · H200 SXM · Spark ConnectX-7 · DGX H200 · Hopper NVLink

表中H200全部为官方规格，未在本次执行H200实测。下文GB10为卸载模型后的测量。相同功能使架构对照有意义，但只有相同模型、精度、工作量及计时边界的双平台实测才能建立推理性能比。



图 10–01 数据路径对照

两种系统都要供给本地数据并交换模型分片，但使用不同内存与互连。连线表示功能路径，不按带宽缩放。

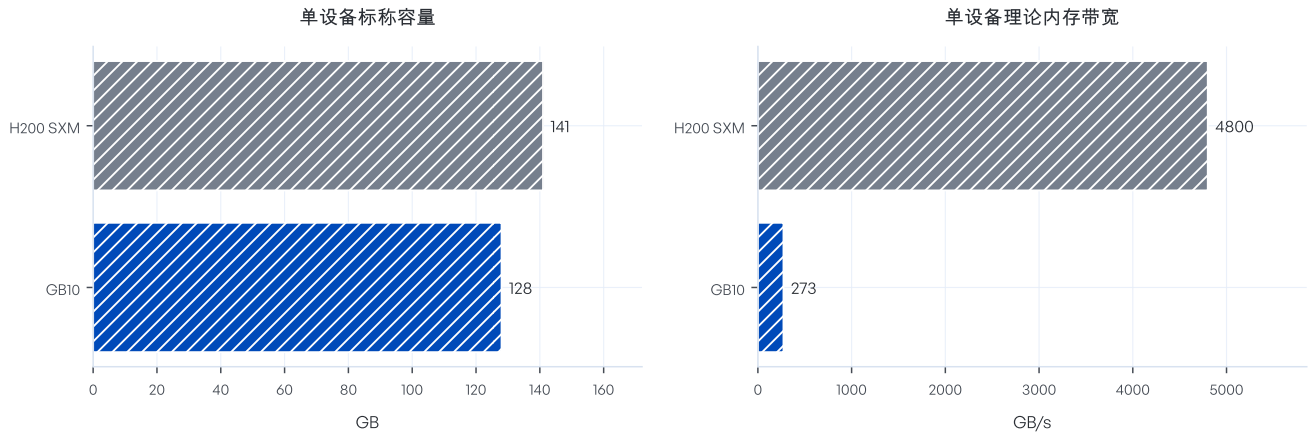


图 10–02 容量与数据供给

均为单设备官方规格；相近容量不等于相近带宽。两个面板从零起轴。

本机内存速率：固定8 GiB工作集

表 10–03 本机内存速率：固定8 GiB工作集

操作	节点0 GB/s：中位 [范围]；轮次	节点1 GB/s：中位 [范围]；轮次	H200 HBM3e参照
连续复制：读＋写	223.41 [222.75–223.74]; n=10	226.95 [226.31–227.88]; n=10	4,800 GB/s标称；本操作未测
三元运算：两读＋一写	214.88 [213.76–215.27]; n=10	217.66 [217.07–218.13]; n=10	4,800 GB/s标称；本操作未测
原生读取	110.04 [109.88–110.21]; n=5	110.09 [108.89–110.79]; n=5	4,800 GB/s标称；本操作未测
原生写入	192.63 [191.81–193.07]; n=5	192.87 [191.51–193.06]; n=5	4,800 GB/s标称；本操作未测

工作集使用二进制GiB，速率使用十进制GB/s。数值按程序请求的逻辑字节计数，不能标为硬件计数器测得的物理DRAM带宽。原生读取包含线程内依赖累加，反映该访问内核而非理论读取上限；三元运算按元素对齐后的实际字节计数。

不同精度的核心计算速率

TFLOP/s表示每秒10^{12}次浮点运算，乘加计**2次**。下表GEMM固定M=N=K=8192，使用2MNK/时间，不从各规模中挑选最高值；FP32通用乘加单独列出。H200稠密Tensor Core值以官方带稀疏值除2近似换算，保留原表舍入；不是本研究实测。2:4稀疏指每4个权重中2个非零，表中稀疏速率采用稠密等效运算量。

状态说明：**原生不支持**表示硬件没有该格式的原生运算路径；**不适用**表示该行运算不采用该列的稠密或2:4稀疏口径；**未测**表示本研究尚无有效实测结果。三者均不表示算力为零。

表 10–04 不同精度的核心计算速率

运算 / 精度	GB10节点0实测TFLOP/s	GB10节点1实测TFLOP/s	H200稠密理论TFLOP/s	H200 2:4理论TFLOP/s
FP32通用乘加	28.01 [27.97–28.04]; n=5	27.98 [27.94–28.06]; n=5	67	不适用
FP32 GEMM	18.39 [18.16–18.48]; n=10	18.22 [17.94–18.30]; n=10	67	不适用
TF32 allowed	33.10 [24.01–38.59]; n=10	37.17 [33.21–38.53]; n=10	≈494.5	989
FP16	93.24 [91.83–93.95]; n=10	92.67 [91.59–92.99]; n=10	≈989.5	1,979
BF16	94.34 [93.50–94.78]; n=10	94.08 [93.63–94.42]; n=10	≈989.5	1,979
FP8 E4M3	192.64 [192.07–195.62]; n=5	191.88 [191.38–193.22]; n=5	≈1,979	3,958
NVFP4	157.38 [148.49–160.44]; n=5	148.02 [143.42–161.21]; n=5	原生不支持	原生不支持
FP16 2:4	39.33 [39.25–39.45]; n=5	39.48 [39.38–39.65]; n=5	不适用	1,979
BF16 2:4	39.28 [39.03–39.69]; n=5	39.41 [38.82–40.02]; n=5	不适用	1,979
FP64	0.4280 [0.4280–0.4281]; n=5	0.4276 [0.4276–0.4277]; n=5	34 通用；67 Tensor Core	—

GB10通用乘加条件为256线程/块、**8条**独立链、线程块数为SM数的**4倍**。TF32 allowed表示允许库使用TF32，不能仅凭该开关确认每次调用的实际指令。NVFP4使用受控、可精确表示的数据分布，不能代表生产权重误差或MoE内核性能。GB10官方“最高**1 PFLOP/s**”采用FP4稀疏口径，不与本表稠密NVFP4实测直接计算达成率。

NVFP4的架构差异：GB10属于Blackwell，具有原生FP4矩阵运算支持；H200属于Hopper，没有原生NVFP4 Tensor Core运算，因此没有可填入的原生稠密或稀疏峰值。软件可通过兼容内核把FP4权重反量化为BF16后计算，但这属于不同运算路径，不能用H200的FP8或INT8规格代填。本研究也未在H200上实测这种软件路径。 NVIDIA NVFP4 · NVIDIA NIM NVFP4 Emulation

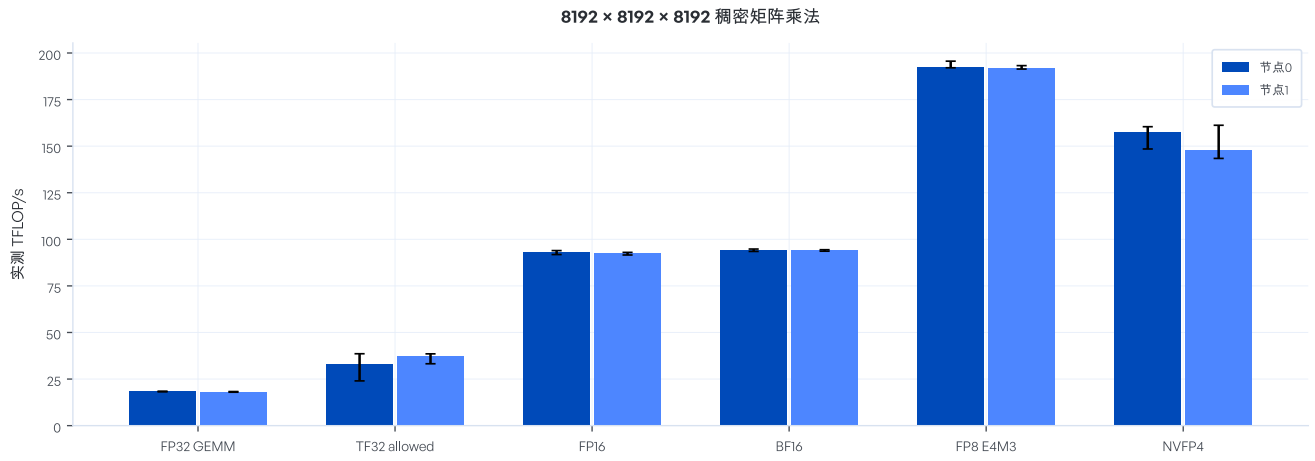


图 10–03　固定规模计算实测

仅绘制两颗GB10实测，误差线为轮次观测范围。H200理论上限保留在表中，避免呈现为同场实测。

对部署选择的意义

本次8 GiB连续复制达到223–227 GB/s，两节点1 GiB AllReduce总线带宽约21.81 GB/s；跨节点同步与本地内存访问处于不同速率层级。H200的HBM和NVLink规格显示其具备更高的内存及GPU互连上限，但实际收益仍取决于模型分片、计算密度、批量与通信重叠。现有证据支持识别这些资源差异，不支持给出H200相对本机的词元速率、时延、能效或回本倍数。后续对照需要同一模型、量化/精度、输入输出、并发、缓存条件及墙上功耗测量。

11 · 费用、持有成本与投资回报

实际 API 费用

费用按同组请求标识核对到账单。下表的每百万生成词元费用包含输入收费，适用于本次输入 / 输出组合，不是单独的输出目录价格。

表 11–01　实际 API 费用

并发条件	账单覆盖	实付 USD	USD/千次响应	USD/百万生成词元
并发 1 · 关闭思考	120/120	0.0244	0.204	0.519
并发 2 · 关闭思考	180/180	0.0375	0.208	0.517
并发 4 · 关闭思考	60/60	0.0124	0.206	0.518
并发 8 · 关闭思考	180/180	0.0373	0.207	0.517

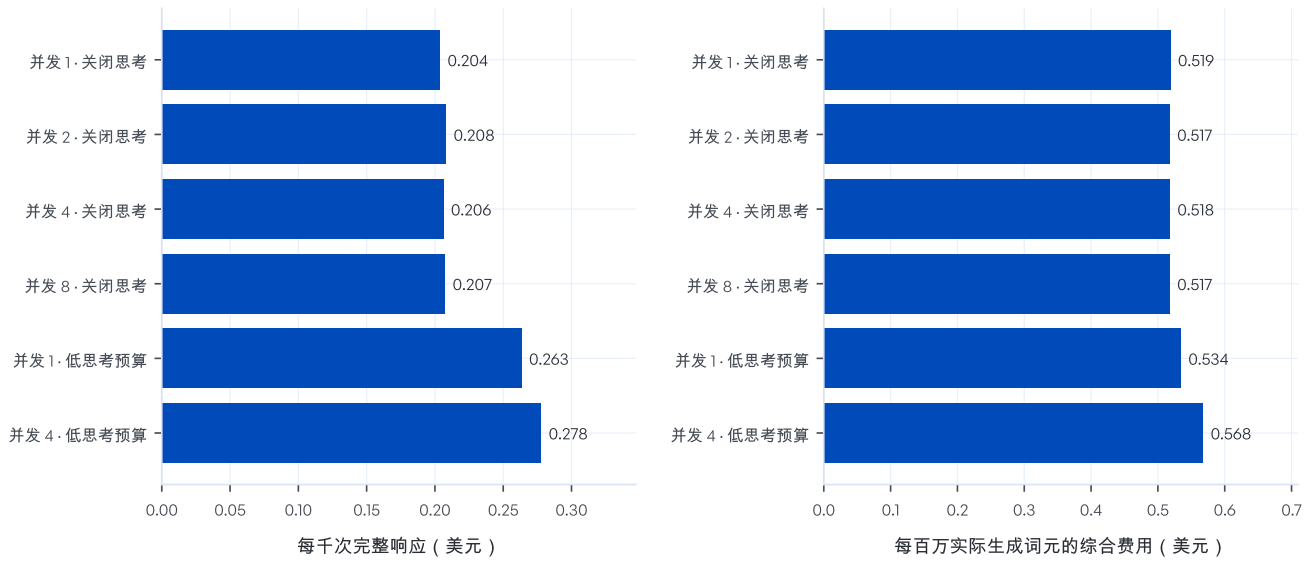


图 11–01　费用归一化

按响应次数和生成词元分别计价；两种口径都含该组输入费用。

双机持有成本：采购与电费

采购价按每台 **US$5,000**，双机合计 **US$10,000**。电价采用中国商业用电公开参考 **US$0.109/kWh（2026年第三季度）**，作为可复算代理值，并非部署地点合同电价或官方用电量加权均价。 GlobalPetrolPrices

单位成本按直线折旧加估算电费计算：年费用 = 采购价 ÷ 折旧年限 + 双机功率(kW) × **8,760小时** × 电价；再除以年有效生成量。功率采用对应负载采样的估算整机功率之和，并假设全年保持该水平。有效生产比例表示有用任务产出时间，不是GPU活跃度。未计人工、机房、冷却、维修及融资。

表 11–02　双机持有成本：采购与电费

并发	双机估算 W	年电费 USD	50% · USD/1M	75% · USD/1M	100% · USD/1M
1	112.3	107	4.833	3.222	2.417
2	120.6	115	2.778	1.852	1.389
4	122.9	117	1.821	1.214	0.911
8	124.6	119	1.378	0.919	0.689

上表统一按三年折旧；后三列是对应有效生产比例下的每百万生成词元成本。

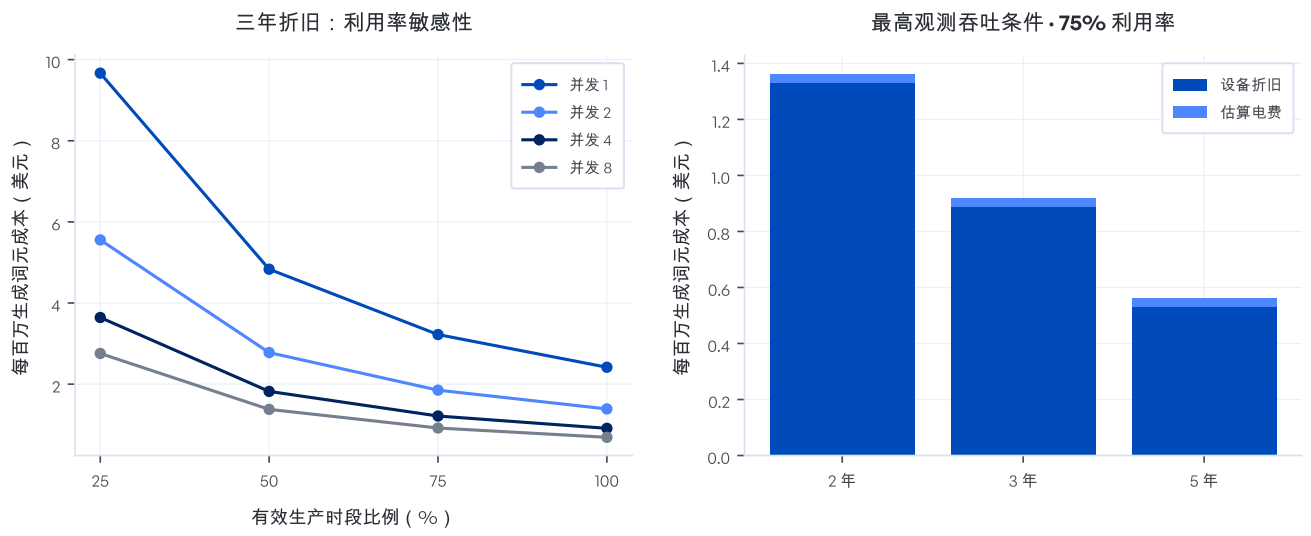


图 11–02　成本敏感性

左：三年折旧下的利用率变化；右：75%利用率下不同折旧年限。

1 / 3 / 5 年回本与投资回报：自用和对外售卖

本节回答投入两台设备之后，现金节省或销售收入何时覆盖初始投资。折旧只用于前面的单位成本分摊；这里在购机时一次扣除采购支出，之后只扣现金运营费用，不再重复扣除折旧。所有金额均为美元，以下是基于已测吞吐的条件测算，不是已经实现的多年收益。

表 11–03　1 / 3 / 5 年回本与投资回报：自用和对外售卖

用途	年度收益如何定义	价格与工作量口径
自用：减少外购 API 支出	完成同等工作原本需支付的 API 费用	沿用同一输入 / 输出组合的账户实付综合单价；只计算实际需要的工作量
售卖：推理服务销售收入	实际售出量 × 综合售价，再扣销售扣费	展示参考价的 **0.5 / 1 / 2 倍**；有效售出利用率是产生可收款工作量的时间占比

固定测算依据。采用自然题库并发 8 的观测吞吐 **158.90 词元/s**、双机估算功率 **124.57 W**、全年配置 **8,760 小时**和采购价 **US$10,000**。对应账户实付综合 API 价格为 **US$0.51739/百万生成词元**，已包含这一输入 / 输出组合的输入费用。售卖部分仅将其用作假设报价的参照，不把账户支出视为节点收入，也不把它视为通用输出词元单价。

表 11–04　1 / 3 / 5 年回本与投资回报：自用和对外售卖

指标	定义与计算
年有效产出 Q	Q = R × 3,600 × H × u ÷ 1,000,000，单位：百万生成词元
年现金运营费 O	O = 双机功率/1,000 × 年配置小时 × 电价 + 其他年度费用；销售扣费单列
年净现金收益 S	自用：S = Q × API 参考价 − O；售卖：S = Q × 售价 × (1 − 扣费比例) − O
第 T 年累计净收益	T × S − K；K 为初始采购投入，负值表示尚未收回全部投入
累计简单投资回报率	(T × S − K) ÷ K；分母为初始采购投入，不是营业收入，也不是年化收益率
简单回本周期	K ÷ S，仅在 S > 0 时有有限值；回本超过 5 年表示五年内未回本
T 年回本所需最低综合售价	(K/T + O) ÷ [Q × (1 − 扣费比例)]；覆盖本节计入的现金费用

固定情景假设吞吐、价格和电价在各年保持不变，忽略资金时间价值；不计残值、换机、融资、税务、人工、冷却、机房及其他运维费用。销售扣费基准设为 0，仅用于展示未扣渠道等费用的上界情景，不代表实际免费。自用和售卖各自假设对应的工作需求能够持续实现；有效利用率不是 GPU 活跃度。五年结果还要求设备与服务可持续使用五年。

自用：75% 有效生产比例下的 1 / 3 / 5 年现金账

年有效生成量约 3,758.2 百万词元；年避免 API 支出 **US$1,944**，估算年电费 **US$119**，年净节省 **US$1,826**。

表 11–05 **自用：75% 有效生产比例下的 1 / 3 / 5 年现金账**

持有时长	累计避免 API 支出	累计估算电费	初始采购	累计净收益	累计 ROI
1 年	US$1,944	US$119	US$10,000	US$−8,174	−81.7%
3 年	US$5,833	US$357	US$10,000	US$−4,523	−45.2%
5 年	US$9,722	US$595	US$10,000	US$−872	−8.7%

利用率敏感性：相同的购机与全年用电假设下，只有实际需要的产出才能形成节省。

表 11–06 **自用：75% 有效生产比例下的 1 / 3 / 5 年现金账**

有效生产比例	年净节省	简单回本	1 年 ROI	3 年 ROI	5 年 ROI
25%	US$529	18.90 年	−94.7%	−84.1%	−73.5%
50%	US$1,177	8.49 年	−88.2%	−64.7%	−41.1%
75%	US$1,826	5.48 年	−81.7%	−45.2%	−8.7%
100%	US$2,474	4.04 年	−75.3%	−25.8%	+23.7%

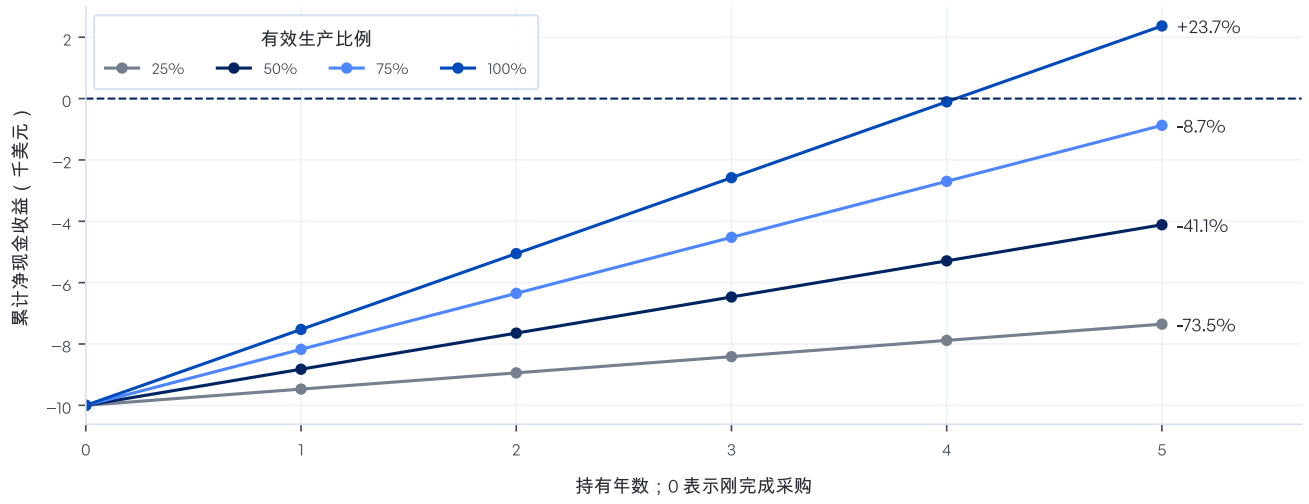


图 11–03 **自用累计现金流与回本**

各线从购机支出 −US$10,000 起算，跨越零线才表示全部收回初始投入。线末百分比为第 5 年累计 ROI。不同线只改变有效生产比例；使用固定短时实测速率外推，线条不是多年实测轨迹。

自用结论。75% 生产比例下，简单回本约 **5.48 年**，五年累计 ROI 为 **−8.7%**；100% 生产比例下，回本约 **4.04 年**，五年 ROI 为 **+23.7%**。其中超过五年的回本值只是同一假设继续成立时的数学外推，不能据此认定设备能持续运营到该年限。

对外售卖：售价与有效售出比例共同决定回报

下表固定有效售出比例为 **75%**，以参考价的 **0.5 / 1 / 2 倍**展示报价敏感性。销售额扣除估算电费后为本节年净现金收益；尚未扣除的费用须在实际经营模型中补齐。同价、同工作量且不收销售扣费时，售卖和自用的数值相同，但前者依赖付费客户需求，后者依赖自身真实需求，两种收益不能相加。

表 11–07　对外售卖：售价与有效售出比例共同决定回报

售价 USD/百万生成词元	年销售额	年净现金收益	简单回本	1 年 ROI	3 年 ROI	5 年 ROI
0.259 (0.5×)	US$972	US$853	11.72 年	−91.5%	−74.4%	−57.3%
0.517 (1×)	US$1,944	US$1,826	5.48 年	−81.7%	−45.2%	−8.7%
1.035 (2×)	US$3,889	US$3,770	2.65 年	−62.3%	+13.1%	+88.5%

售卖情景结论。在 **75%** 有效售出利用率下，按参考价售卖的回本周期仍为 **5.48 年**；若综合售价为参考价的两倍（**US$1.035**/百万生成词元），回本约 **2.65 年**，**1 / 3 / 5 年**累计净收益分别为 **US$−6,230** / **US$1,310** / US$8,850。这说明本情景的回报同时依赖售价与可持续售出量；提高报价本身不能证明市场能够维持该销量。

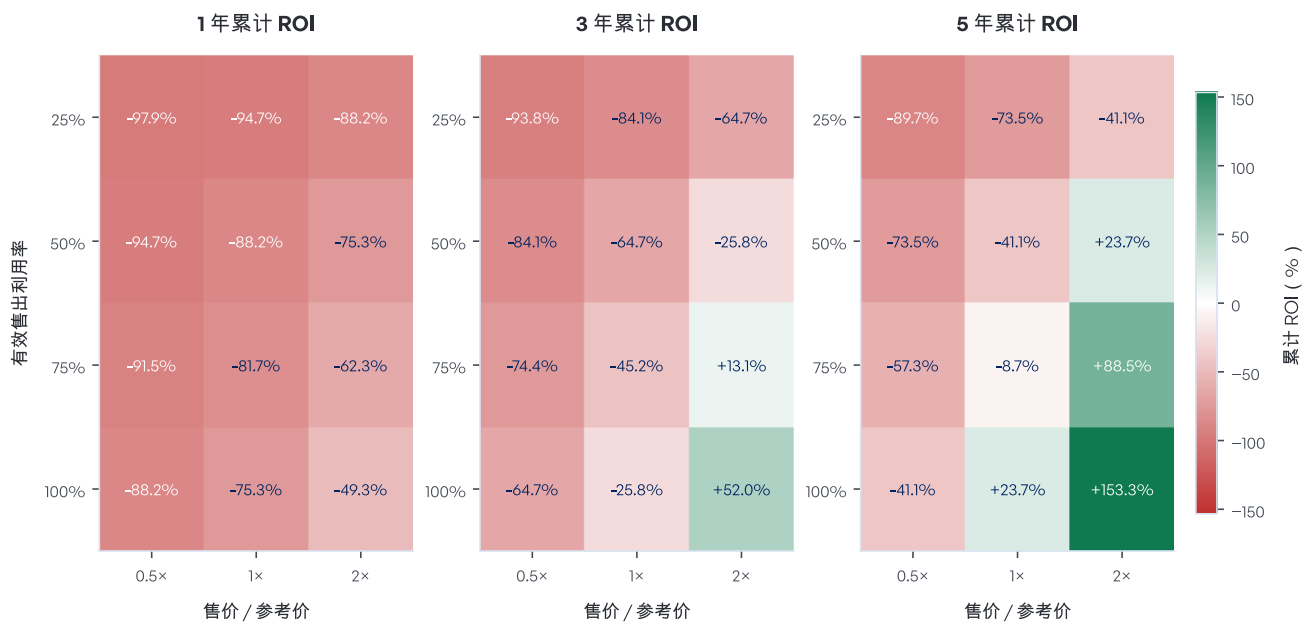


图 11–04　售卖投资回报的价格与利用率敏感性

三个面板分别是第 1、3、5 年累计简单 ROI；格内为百分比，负值表示尚未收回初始投入。所有面板同一色标，售价是含固定输入配比的综合价，销售扣费与其他运营费均未计入。

指定期限内回本需要多高的综合售价：

表 11–08　对外售卖：售价与有效售出比例共同决定回报

有效售出比例	1 年回本最低价	3 年回本最低价	5 年回本最低价
25%	US$8.078	US$2.756	US$1.691
50%	US$4.039	US$1.378	US$0.846
75%	US$2.693	US$0.919	US$0.564
100%	US$2.019	US$0.689	US$0.423

价格单位均为每百万实际生成词元的综合美元金额，并假设输入 / 输出配比不变；改变长输入占比、思考长度或缓存条件时，应替换对应负载的吞吐与综合单价再计算。最低售价只覆盖已计入的费用，不等于商业报价建议。

下载全部投资回报情景与计算参数

按负载核对的账单数据 · 全部设备成本情景

补充实验的实际API费用

表 11-09 补充实验的实际API费用

范围	USD
历史已核对费用	8.561299
独立补充批次	0.376474
累计已核对	8.937773

新增费用不回填早期工作负载的单位成本或投资回报；那些情景仍使用其原有配对费用与吞吐。

12 · 整体结论与后续工作

本次测评建立了双DGX Spark在当前模型、引擎配置和已测负载下的分层性能基线。部署判断应同时满足容量、等待、处理量和成本要求；以下结论分别对应前文可复核的数据。

表 12–01 整体结论与后续工作

维度	结论	适用范围
数据供给与通信	8 GiB连续复制223–227 GB/s；1 GiB AllReduce约21.81 GB/s。	用于相同条件的资源基线；不是模型吞吐预测。
引擎阶段	单并发、固定256输出的解码中位速率49.8–60.2词元/s，随已测输入长度变化。	原生合成负载；阶段时间含引擎调度边界。
公网并发	并发8合计158.9词元/s，正文首字95分位2.39 s；相对并发1合计吞吐约3.52倍。	60条短提示库、实际完整区组；不是服务承诺。
长输入与长输出	并发4、输出上限512时，输入512→32,768对应正文首字中位1.48→37.02 s；长度扩展中达到目标的最大输出为4,096。	256K是配置边界；未建立256K实际输出能力。
前缀复用	节点有效活动窗口的词元加权缓存比例为20.3%；原生复用结果按输入长度分别报告。	混合窗口统计不是逐请求命中率，不能外推长期保留。
持续与热状态	两节点计算、带宽各完成60分钟；混合负载两节点共同覆盖120.0分钟。	分段证据，不构成连续4小时可靠性验证。
H200技术参照	单设备容量相近，H200标称本地内存带宽更高；设备协作路径与功耗边界不同。	无H200同负载实测，不能给出推理性价比排名。

表 12–02 整体结论与后续工作

经济用途	情景结果	关键条件
自用经济性	75%生产比例的简单回本 5.48 年，五年ROI −8.7%。	依赖固定需求和价格；加入运维费用会降低回报。
售卖经济性	75%售出比例、参考API综合价的2倍售价情景：回本 2.65 年，五年ROI +88.5%。	是假设情景；未计渠道扣费及其他运营费，不代表实际收入。

局限与后续工作

表 12–03 局限与后续工作

优先级	待解决的不确定性	后续实验与验收依据
1	跨时段持续性	在独立日期与环境温度下复验持续负载，检查性能保持与退避频率是否可重复。
2	长输出的真实可达范围	用固定生成条件验证更长输出，并分别报告自然结束与强制长度；不把输出上限当完成量。
3	缓存保留与业务服务目标	固定真实业务分布，增加独立时间段和竞争请求，关联逐请求缓存量、等待与达标吞吐。
4	硬件机制与H200可比收益	在同模型、精度、长度、并发及缓存条件下对照；补齐计数器、通信路径和同轨迹分析。
5	实际持有成本	用插座电表、真实利用率、采购报价及运营费用替换情景输入，再复算1 / 3 / 5年回报。

最终覆盖与后续补测优先项

覆盖边界：本轮执行与归档已结束。公网长度清单仍有8次未发送、1次未完整；混合干扰5组候选仅执行3组，0组满足完整配对条件。硬件、原生长输出、剖析、即时缓存复用与连续一小时窗口分别报告其已完成清单，不能据此宣称所有设想均已验证。

后续优先补齐公网长度的未覆盖组合，并为混合干扰重新设计能完整容纳固定到达序列的观察窗口；同时保留过载拒绝作为服务结果。新实验需独立区组与新的生产资源安排，不能将本轮未准入或不完整配对填为成功。

原生引擎固定输出补充结果：已完整验证最高 260,096词元输出。公网自然结束数据仍为独立样本，不能用原生结果替代其端到端测量。

连续服务新增了独立一小时的完整观察，五分钟窗口展示等待和完成产出的变化。该证据扩展了本次固定速率下的持续性范围；不外推全天服务等级、峰值容量或全年可用性。

13 · 附录A：完整指标与统计定义

本附录集中列出指标公式、数据来源与解释范围。秒用 s、毫秒用 ms；token/s 表示每秒词元数。每项统计都要说明请求集合、预热处理、时间窗口和缺失数量。以下“已采集”指原始记录中具备该类字段，不代表每个请求或整个测试期间均有有效值。

方法参考 NVIDIA GenAI-Perf 与 SGLang 服务基准对首响应、请求总延迟、输出吞吐和并发 / 速率的区分。本报告使用自有采集器，并按实际可观察的流片段明确时间边界；没有声称执行这些工具的官方认证测试。来源使用实验前保存的文档快照，滚动文档不证明当前安装版本的全部行为。 NVIDIA GenAI-Perf · SGLang bench_serving · 文档快照与散列

公式读法：t 表示某个事件发生的时间点，两时间点相减得到耗时；N_in、N_out 分别表示输入与输出 token 数，cap 表示上限，target 表示目标值；Σ 表示对指定样本求和。所有比例都需使用同一组有效样本作分子与分母。

请求时间与流式体验

表 13-01 请求时间与流式体验

指标	定义、单位与解释边界	来源 / 可用状态
响应头等待	t_headers − t_send；s。包含建立连接、服务等待和传输。	headers_s；逐请求已采集
首个生成片段延迟	t_generated − t_send；思考、正文或工具内容最先出现者。常称 TTFT，但这里不是逐 token 计时。	first_generated_s；已采集
正文首字延迟	t_visible − t_send；只有正文 content 才计入，没有正文则缺失。	first_visible_s；已采集
首个思考片段	t_reasoning − t_send；没有思考片段时缺失，不视为零。	first_reasoning_s；出现时采集
端到端延迟	t_end − t_send；包括响应流收尾。开放到达另加发出前等待，得到从计划到达开始的用户延迟。	e2e_s；已采集
平均每输出词元耗时	(E2E − 首个生成片段延迟)/(N_out − 1)，N_out>1；ms/token。使用源站输出计数；这是兼容估算。	tpot_compat_s × 1,000；可派生
片段生成窗口与结束延迟	(t_last − t_generated)/(N_out−1) 是另一种解码估算；t_end−t_last 为收尾时间。首片段 token 数未知。	decode_tpot_approx_s / terminal_delay_s；已采集与复算
流式间隔与停顿	相邻非空生成事件到达间隔的中位数、95 分位、最大值；记录超过 200 ms / 1 s 的次数与总时间。不能称为精确逐 token 间隔。	events.jsonl / chunk_intervals；已采集

词元、长度与缓存

表 13-02 词元、长度与缓存

指标	定义、单位与解释边界	来源 / 可用状态
输入与输出计数	输入含聊天模板；输出包括源站记录的生成部分。保留接口计数、源站计数及来源，不将计费归一化计数当作真实生成速度分母。	prompt_tokens / completion_tokens / api_completion_tokens；已采集
思考计数	使用明确报告的字段；不可由彼此口径不同的总数和正文数相减补造。	reasoning_tokens；字段可用时报告
计划与实际输入输出比	计划=N_in,target / N_out,cap；实际=N_in,observed / N_out,observed。输出为零或缺失时实际比例缺失。	计划清单与 requests.csv；可派生
输出触顶率	finish_reason=length 的完整响应数 / 完整响应数；不等于质量失败率。	truncated / finish_reason；已采集
共享前缀比例	完整模板 token 序列最长公共前缀长度 / 测量输入 token 数；与目标档位分开记录。	业务清单 matched_prefix_tokens；离线已核验

指标	定义、单位与解释边界	来源 / 可用状态
缓存 token 比例	Σ已报告缓存 token / Σ对应输入 token；只对字段有效样本计数，同时报告覆盖数。逐请求比例可另给分布。	cached_tokens；有字段才报告，缺失不补零
缓存命中请求比例	缓存 token>0 的请求数 / 缓存字段有效请求数；不能与 token 加权比例混用。	由有效缓存字段派生；并非设计目标

系统吞吐、到达与可靠性

表 13-03 系统吞吐、到达与可靠性

指标	定义、单位与解释边界	来源 / 可用状态
区组合计输出吞吐	Σ输出 token / (区组排空时刻−启动时刻)，token/s；乘 60 得 token/min。不能把每请求 token/s 相加替代。	连续完整区组主图；全墙钟值另存
请求吞吐与到达速率	完成请求数 / 窗口秒数；计划到达数 / 窗口秒数；发送数与完成数分别计数。	区组回执与 arrivals；后者在开放阶段产生
并发、队列与调度迟滞	active 为实际在途数；client_queue_s 为本地等待；scheduler_delay_s 为计划时刻到实际入队的偏差。	客户端监控；开放到达排队字段来自对应阶段
达标吞吐与达标比例	同时满足正文首字与估算 TPOT 阈值、流完整且无完整性标记的请求数 / 从首个测量到达到排空的窗口。达标比例另除以全部测量到达数，含本地拒绝。	阈值 1/2/5/10 s × 20/50/100 ms；使用开放阶段数据
完整率与失败分母	完整尝试 / 有终态尝试；逻辑任务首次完成率与至少一次完成率另算。在途任务不能先计为失败；重试失败不删除。	state / retry_summary / HTTP 状态；已采集
完整性标记与边界拒绝	空正文、异常重复等只作为候选标记。故意超出上下文并按预期返回 400 单列，不计正常生成成功。	integrity_flags / expected_context_rejection；按阶段
单位响应与生成成本	同一连续完整区组内：实付费用/完整响应数×1,000；实付费用/原始生成词元数×1,000,000。均包含输入收费。	逐请求账单精确关联；缺失账单不补零
设备与电费情景	采购成本/使用年限 + 平均功率(kW)×年度配置小时×电价；再除以预计生成量。有效生产时间比例不是 GPU 活跃度。	用户采购价、公开电价、采样估算功率及显式假设；非实测总拥有成本
费用与预算占用	实际费用以同请求账单核对；预留是保守上界，不是实付，也不等于硬件总拥有成本。	billing_latest.json / ledger.json；已采集

推理节点与运行机制

表 13-04 推理节点与运行机制

指标	定义、单位与解释边界	来源 / 可用状态
GPU 活跃度、时钟、温度	% / MHz / °C；按节点与负载窗口分析。GPU 活跃百分比不是算力效率或内存带宽利用率。	SparkDash；持续采集，存在采样空档
功率与降频	GPU 传感器功率 W；systemDraw 为估算整机功率；thermal / hwSlowdown 区分热限制和硬件减速。不能据此给插座侧 token/J。	SparkDash；已采集
统一内存与交换	可用内存、页缓存、已用交换区；MiB=2^{20} 字节、GiB=2^{30}。CPU/GPU 共享内存视图不能相加。	SparkDash 内存字段；meminfo 按有效采样窗口统计
键值缓存与状态槽	已用、可用、可回收 token / 槽位。可回收不等于立即空闲；不同类型状态池单位不能混算。	SparkDash 可用字段；SGLang 原始指标覆盖不完整
引擎执行与排队	num_running_reqs / num_queue_reqs；按时间窗观察堆积。图表不对缺失阶段补零。	SparkDash 快照及原始时序；按有效时间窗分析

指标	定义、单位与解释边界	来源 / 可用状态
引擎延迟直方图与计数器	用区组前后差值计算请求、输入、生成和缓存量；直方图只给桶边界支持的范围。计数器重置或序列消失则缺失；跨并行副本不盲目求和。	Prometheus 存档覆盖不完整；SparkDash 未提供原始直方图与计数器
多词元预测接受情况	窗口接受比例 / 平均接受长度是引擎指标，分母由实现定义；累计接受数缺失时不能推算全程接受率或加速倍数。	原始 gauge 存档；SparkDash 接受字段为空
内存压力与缺页	PSI 表示任务因资源等待而停顿的时间比例；交换进入 / 退出及重大缺页计数按有效窗口求差除以时长。	vmstat / PSI 存档覆盖不完整，按有效窗口统计
错误与互联	Xid 为驱动错误记录、OOM 为内存不足杀进程计数，报告基线后的增量；RoCE 传输 / 错误按接口可用字段观察。独立 RDMA 微基准不能替代模型通信指标。	SparkDash 原始节点快照；RDMA 独立结果

测量质量与统计量

表 13–05 测量质量与统计量

指标	定义、单位与解释边界	来源 / 可用状态
监控覆盖与采集成本	有效采样数、采样间隔、最后成功时间、采集耗时；按实际数据判断哪些负载窗口可对齐。	monitor/status、时间戳及 collection_seconds；已采集
客户端资源与事件循环迟滞	CPU 用户 / 系统时间、最大驻留内存、每秒心跳迟滞；用于排除测量端饱和这一替代解释。	monitor/client.jsonl；已采集
中位数、尾分位与区间	p50 为中位数；p95 为约 95% 观测不超过的值。均值差的 95% 置信区间来自成簇重采样，不是 95% 请求落入的范围。	固定种子 10,000 次 bootstrap；小样本不报稳健 p99

本次仍缺少真正逐词元的客户端间隔、全阶段完整原始引擎计数器、插座侧能耗及物理DRAM事务计数。独立集合通信和逻辑内存带宽已另行实测，见第06–07节；它们不等于同一模型请求内部的通信开销或物理总线利用率。

表 13–06 测量质量与统计量

缓存指标	定义与判定
输入前缀重合比例	完整聊天模板的最长公共词元前缀长度 / 探测输入长度。属于受控输入结构。
逐请求缓存词元比例	仅在字段有效的请求中，已缓存输入词元总数 / 输入词元总数；同时给出字段覆盖数 / 完整请求数。
有命中的请求比例	有效字段中缓存词元>0的请求数 / 有效字段请求数；模板少量命中也计入，不代表整段输入复用。
窗口缓存词元比例	同一服务窗口的累计缓存量增量 / 累计输入量增量；检查新鲜度、计数复位、服务标识及与请求计数的一致性，只取头节点一次。
配对等待收益	首次正文首字延迟−重复请求正文首字延迟，正值表示重复请求更快；另列相对变化。网络、执行顺序和负载可能共同影响，不直接称为缓存因果加速。
保留、竞争与恢复	按实际空闲间隔比较缓存比例；竞争后与立即复测相比，观察比例下降和等待增加；再次重复观察恢复。只对已施加的压力与时长成立。
时间稳定性与覆盖	报告有效窗口数 / 全部窗口数、实际跨度、词元加权平均、范围及至少3个有效窗口时的标准差；监控缺失、复位不补零或跨段相连。

分析单位、纳入规则与分母

主要单位是固定工作负载条件下的请求和连续区组。容量曲线仅纳入全部计划请求完整结束、无暂停分段、无额外客户端尝试且输出计数可用的区组；吞吐与延迟使用相同区组。全部尝试另保留，报告完整率与费用。连续区组选择可能偏向较好运行时段，因此图中速率是已完成条件下的描述性容量，不能代替实际服务可用率。预热从正式业务和开放到达统计中排除；缓存预热保留配对身份与时间间隔。

重复、配对与不确定性

自然题库的 60 条提示在多个条件下重复，不把请求总数当作独立语义样本数。思考对照按同题、同轮次、同并发配对，以 low 减 none 定义效应；用固定随机种子执行 10,000 次自助重采样，分别按题目和轮次成簇，保留重复观测依赖。仅三轮时，轮次层面区间很不稳定；不因区间较窄便宣称普遍有效。图表中的比较属于探索性分析，未做多重比较显著性声明。

业务形态每格仅 12 次正式调用、缓存每格仅 6 对，结果以样本数、中位数和范围为主，不报告稳健 p99，不宣称覆盖真实业务总体。业务并发条件使用配对材料和独立前缀标识；三个区组提供有限的重复信息，仍不作为精确总体估计。输出提前结束时，同时给实际输出、触顶率与吞吐，避免把少生成内容误当作更强能力。

缺失、阶段性结果与因果边界

接口用量、源站原始用量、账单计数保留独立来源。低思考档缺少源站计数时不估算 token 速度；缓存缺失不补零，未测条件不插值。监控数据按来源及有效时间窗分别对齐，关联分析保留时间覆盖限制。长度、内容、缓存驻留、生成形态及服务路径都可能共同影响结果；除非干预隔离且条件匹配，不把相关变化写成单一机制的因果收益。所有结论标明数据快照、完成数量与适用条件。

GPU与系统指标字典

表 13-07 GPU与系统指标字典

指标	定义、单位与边界
计算吞吐	稠密GEMM约2MNK/t；TFLOP/s=FLOP/s÷10[12]。注明输入 / 累加精度与是否计入转换。稀疏另列有效运算口径。
内存带宽	有效带宽=(读字节+写字节)/t；复制的有效流量通常为2N字节。工具的单向载荷带宽保留原定义。物理流量以有效计数器为准。
内存访问与缓存	依赖访问延迟=链式访问时间/次数；明确缓存、地址转换缓存与时钟状态。L1/L2命中率按计数器原定义和访问分母报告。
执行与启动	CUDA事件记录设备端时间；主机单调时钟记录提交及含同步的总时间。Graph实例化、首次执行与重放分别报告。
并发与重叠	并发收益=总工作量相同条件下的吞吐比；重叠收益=(串行耗时−重叠耗时)/串行耗时。保留每任务延迟。
通信	algbw=工具定义的消息字节/t；AllReduce busbw=algbw×2(n−1)/n，其他操作使用各自公式。单位GB/s和Gb/s不混用。
持续性能	每阶段10分钟窗口吞吐/同阶段预热后基线；分别报告计算、带宽和混合负载。不同工作量的速度不可混合求保持率。
能量与能效	能量E=∫P(t)dt，单位J；能效=工作量/E。芯片、估算整机、插座实测三种边界分开；动态能量另减同边界空闲基线。
数值与可靠性	校验误差、有效 / 无效轮次、实际观测时长、新出现的驱动异常、内存分配失败及降频原因。短时无错误不外推平均故障间隔。
性能上限图	运算强度I=运算量/同层级字节流量；参考上限min(P,B×I)。P、B来自相同精度与状态的实测或明确标注的规格；接近上限需结合执行轨迹解释。

NVIDIA DGX Spark 硬件规格 · 统一内存与监控限制 · CUTLASS架构与精度支持 · nvbandwidth测量方法 · NCCL通信指标定义 · Nsight计时、计数器与Roofline

14 · 附录B：补充图表与统计明细

以下补充图表用于检查分布、区组变化与采样覆盖；主结果的定义和结论见正文。

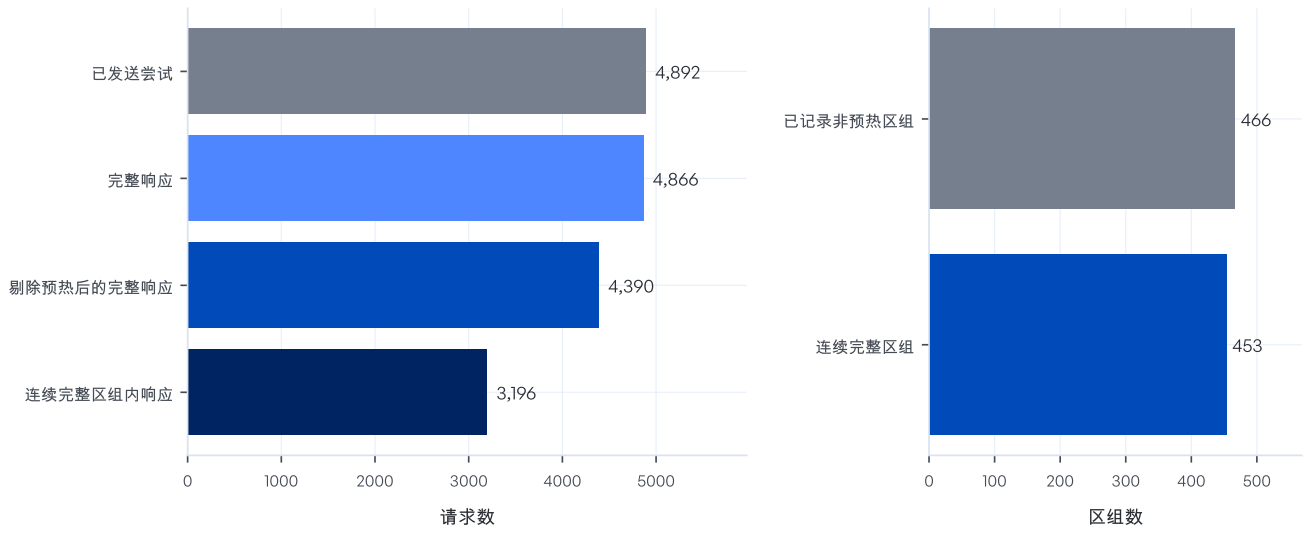


图 14–01　样本纳入

从全部尝试到连续完整区组；请求和区组分开计数。

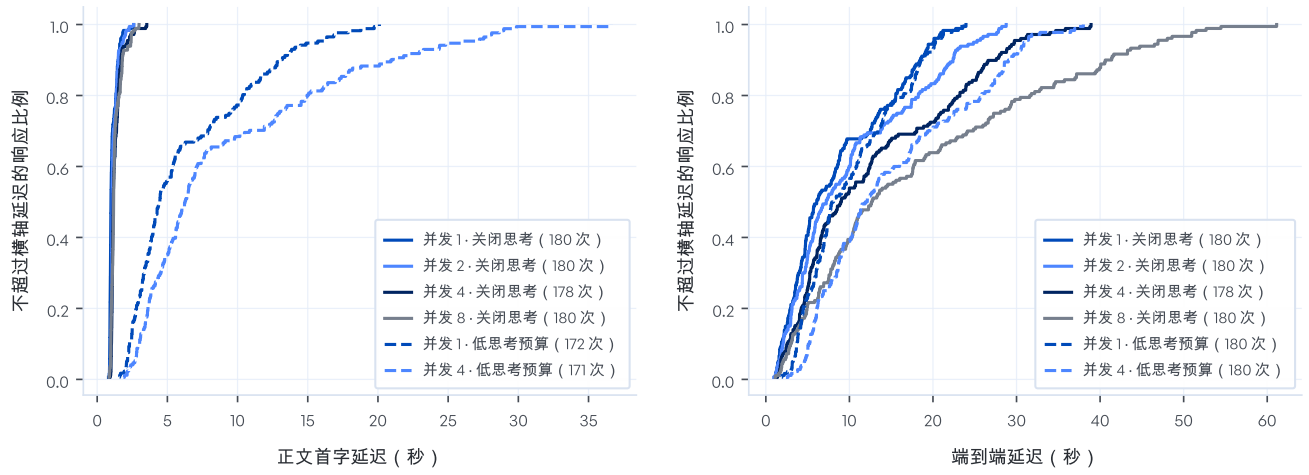


图 14–02　响应分布

全部非预热完整响应，可能包含未完成区组；与主容量曲线的分母不同。

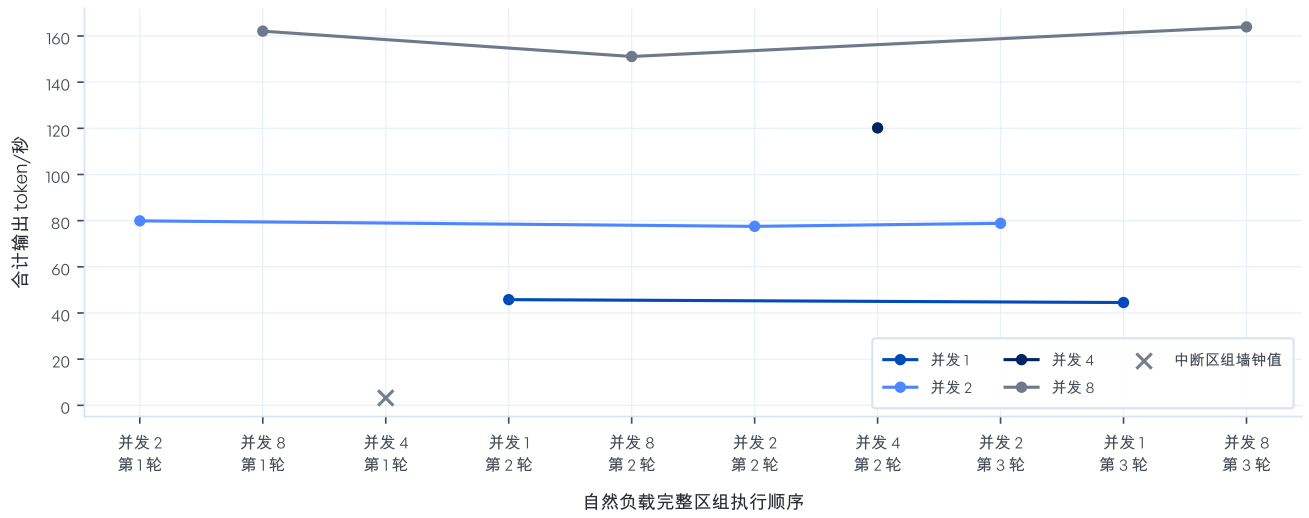


图 14-03　区组变化

实心点为连续区组，叉号仅保留中断区组的完整墙钟值。

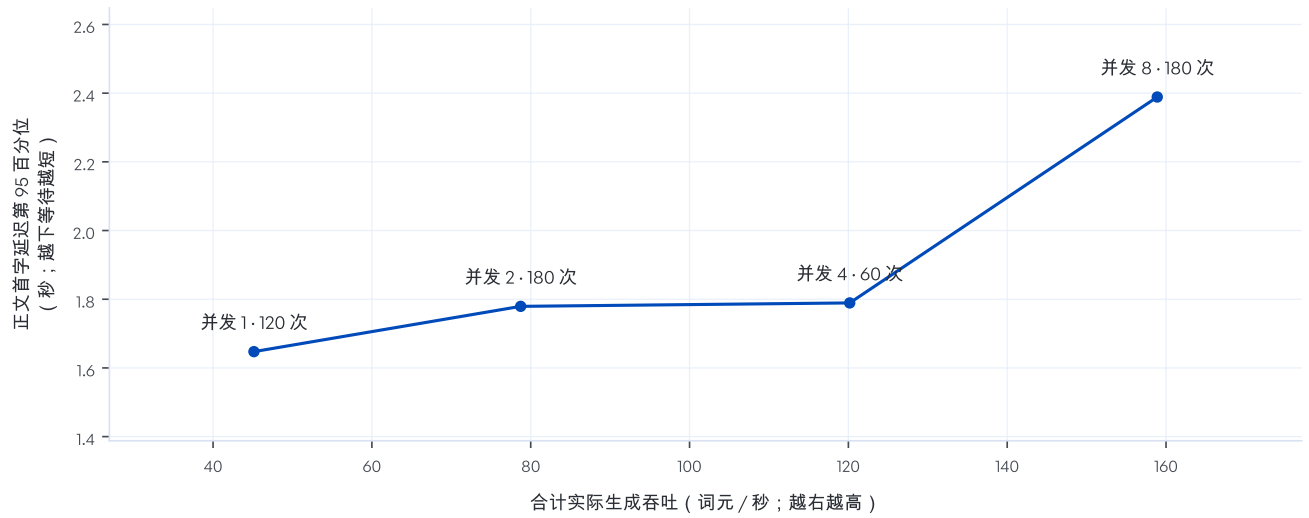


图 14-04　吞吐与等待

每点一个并发条件，连线仅引导阅读。

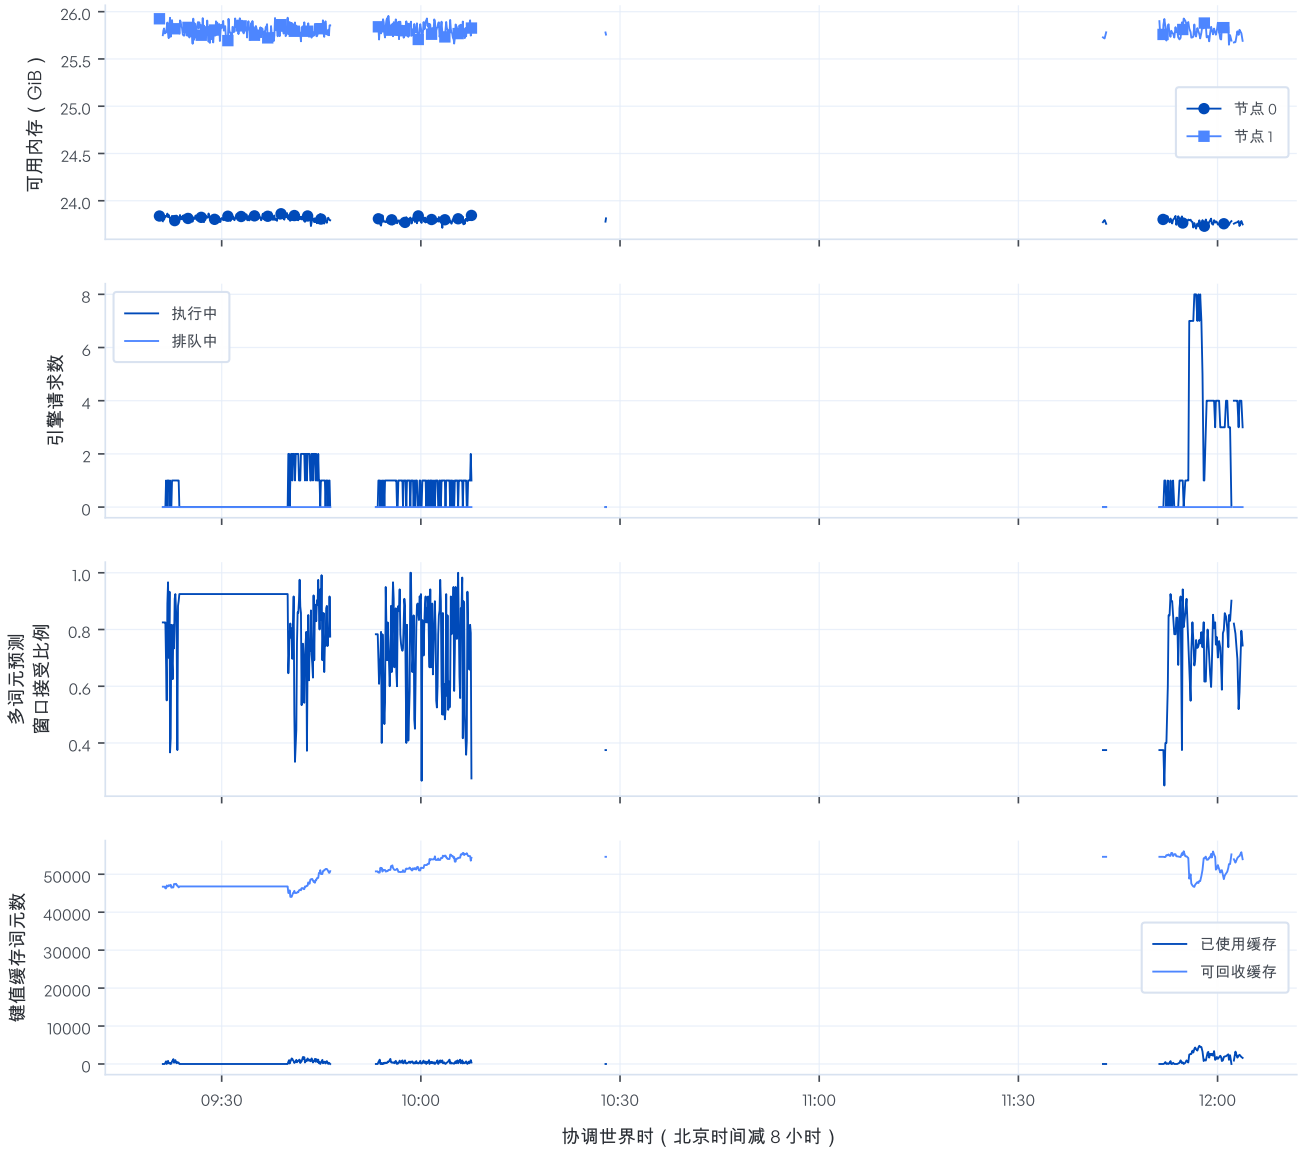


图 14–05　原始引擎与内存采样

缺失区间保留为空白，接受率为采样窗口字段。

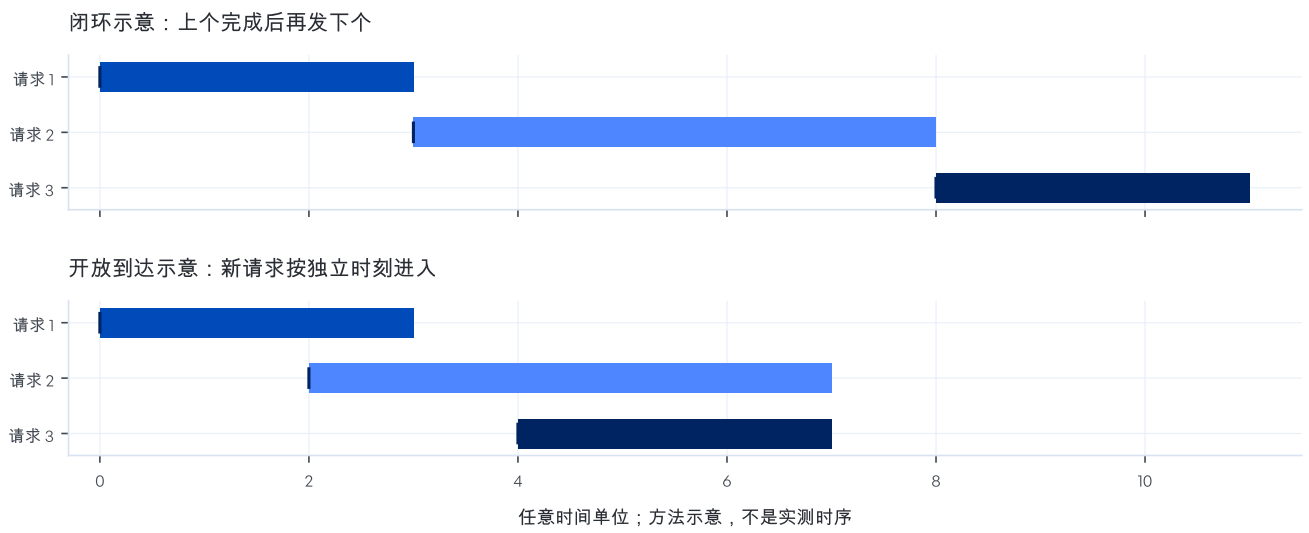


图 14–06　到达方式示意

独立到达可形成排队；图示不表示测试已完成。

思考预算的完整配对统计

表 14–01　思考预算的完整配对统计

条件	完整响应	正文首字延迟中位数 秒	端到端延迟中位数 秒	输出均值	触顶 / 完整性标记
并发 1 · 低思考预算	180	4.42	8.00	483.6	21 / 8
并发 4 · 低思考预算	180	6.26	12.01	489.3	22 / 9

表 14–02　思考预算的完整配对统计

并发 / 指标	配对数	均值差 秒	按题目重采样的 95% 置信区间	按轮次重采样的 95% 置信区间
1 / 首个生成片段延迟	180	0.042	−0.017–0.098	−0.057–0.125
1 / 正文首字延迟	172	5.222	4.180–6.309	4.774–5.462
1 / 端到端延迟	180	1.546	0.610–2.475	1.165–1.779
4 / 首个生成片段延迟	178	−0.128	−0.197–−0.058	−0.371–0.173
4 / 正文首字延迟	169	7.968	6.342–9.787	7.368–8.776
4 / 端到端延迟	178	2.372	0.773–4.011	1.968–3.010

输入处理、上下文与请求复用明细

表 14–03　输入处理、上下文与请求复用明细

条件	尝试数	输入 / 输出均值	首生成中位数 s	完整流 / 其他终态
长上下文与边界 · 上下文边界探针	1	— / —	—	0 / 1
长上下文与边界 · 目标输入 131,072 token · 并发 1 · 长输入后生成	3	131,073.0 / 1,024.0	48.34	3 / 0
长上下文与边界 · 目标输入 131,072 token · 并发 2 · 长输入后生成	3	131,073.0 / 1,024.0	90.65	3 / 0

条件	尝试数	输入 / 输出均值	首生成中位数 s	完整流 / 其他终态
长上下文与边界 · 目标输入 16,384 token · 并发 1 · 长输入后生成	3	16,385.0 / 1,024.0	6.77	3 / 0
长上下文与边界 · 目标输入 16,384 token · 并发 2 · 长输入后生成	3	16,384.7 / 1,024.0	11.28	3 / 0
长上下文与边界 · 目标输入 200,000 token · 并发 1 · 长输入后生成	3	200,000.3 / 1,024.0	74.05	3 / 0
长上下文与边界 · 目标输入 250,000 token · 并发 1 · 长输入后生成	3	250,000.7 / 1,024.0	94.08	3 / 0
长上下文与边界 · 目标输入 32,768 token · 并发 1 · 长输入后生成	3	32,769.0 / 1,024.0	12.55	3 / 0
长上下文与边界 · 目标输入 32,768 token · 并发 2 · 长输入后生成	3	32,769.0 / 1,024.0	22.01	3 / 0
长上下文与边界 · 目标输入 4,096 token · 并发 1 · 长输入后生成	3	4,096.7 / 1,024.0	2.54	3 / 0
长上下文与边界 · 目标输入 4,096 token · 并发 2 · 长输入后生成	3	4,097.0 / 1,024.0	2.41	3 / 0
长上下文与边界 · 目标输入 65,536 token · 并发 1 · 长输入后生成	3	65,536.3 / 1,024.0	24.49	3 / 0
长上下文与边界 · 目标输入 65,536 token · 并发 2 · 长输入后生成	5	65,537.0 / 1,024.0	42.67	3 / 2
前缀缓存 · 历史文本 0 token · 首次前缀	10	148.0 / 210.8	1.07	10 / 0
前缀缓存 · 历史文本 0 token · 重复前缀	10	148.0 / 213.8	0.96	10 / 0
前缀缓存 · 历史文本 0 token · 追加文本	10	404.7 / 206.9	1.06	10 / 0
前缀缓存 · 历史文本 32,768 token · 首次前缀	10	32,917.2 / 229.3	11.69	10 / 0
前缀缓存 · 历史文本 32,768 token · 重复前缀	10	32,917.2 / 262.2	1.55	10 / 0
前缀缓存 · 历史文本 32,768 token · 追加文本	10	33,174.1 / 193.6	1.61	10 / 0
前缀缓存 · 历史文本 8,192 token · 首次前缀	10	8,340.8 / 222.1	3.61	10 / 0
前缀缓存 · 历史文本 8,192 token · 重复前缀	10	8,340.8 / 234.5	1.08	10 / 0
前缀缓存 · 历史文本 8,192 token · 追加文本	10	8,597.6 / 222.3	1.17	10 / 0

长度和延迟只统计完整流；其他终态包括预期越界拒绝，不能统一解释为正常请求失败。缓存字段明细保存在逐请求数据，响应加快本身不证明实际命中或保留时间。

关键矩阵形状的完整统计

表 14–04 关键矩阵形状的完整统计

节点	精度	M×N×K	轮次	中位TFLOP/s	观测范围
0	fp32	128×4096×4096	10	13.127	12.758–13.267
0	fp32	4096×4096×4096	10	16.762	16.628–16.861
0	fp16	1×4096×4096	10	0.276	0.227–0.304
0	fp16	4096×4096×4096	10	87.556	86.791–88.325
0	tf32_allowed	128×4096×4096	10	15.154	14.365–15.389
0	fp32	1×4096×4096	10	0.123	0.119–0.126
0	bf16	1×4096×4096	10	0.284	0.265–0.292
0	bf16	128×4096×4096	10	33.110	31.757–34.217

节点	精度	M×N×K	轮次	中位TFLOP/s	观测范围
0	bf16	4096×4096×4096	10	88.641	86.682–89.490
0	fp16	128×4096×4096	10	32.312	30.924–34.355
0	tf32_allowed	1×4096×4096	10	0.125	0.119–0.127
0	tf32_allowed	4096×4096×4096	10	39.380	38.995–39.802
1	fp32	128×4096×4096	10	12.992	12.576–13.150
1	fp32	4096×4096×4096	10	16.579	16.470–16.726
1	fp16	1×4096×4096	10	0.281	0.255–0.297
1	fp16	4096×4096×4096	10	87.287	85.604–87.888
1	tf32_allowed	128×4096×4096	10	14.387	13.757–15.252
1	fp32	1×4096×4096	10	0.121	0.118–0.124
1	bf16	1×4096×4096	10	0.283	0.260–0.303
1	bf16	128×4096×4096	10	32.418	31.179–33.816
1	bf16	4096×4096×4096	10	87.727	87.410–88.985
1	fp16	128×4096×4096	10	32.275	30.953–34.407
1	tf32_allowed	1×4096×4096	10	0.122	0.119–0.128
1	tf32_allowed	4096×4096×4096	10	39.194	38.901–39.687
0	bf16_sparse_2of4	4096×4096×4096	10	34.292	33.662–35.655
0	nvfp4	1×4096×4096	10	0.767	0.766–0.772
0	nvfp4	128×4096×4096	10	98.417	97.847–98.677
0	bf16_sparse_2of4	1×4096×4096	10	0.010	0.010–0.011
0	nvfp4	4096×4096×4096	10	318.537	311.189–322.891
0	fp16_sparse_2of4	1×4096×4096	10	0.010	0.010–0.010
0	bf16_sparse_2of4	128×4096×4096	10	1.307	1.271–1.340
0	fp8_e4m3	4096×4096×4096	10	176.414	175.105–177.438
0	fp16_sparse_2of4	128×4096×4096	10	1.320	1.297–1.330
0	fp16_sparse_2of4	4096×4096×4096	10	33.755	33.070–34.757
0	fp8_e4m3	1×4096×4096	10	0.467	0.465–0.468
0	fp8_e4m3	128×4096×4096	10	118.961	116.431–120.597
1	bf16_sparse_2of4	4096×4096×4096	10	34.179	32.971–35.480
1	nvfp4	1×4096×4096	10	0.771	0.766–0.776
1	nvfp4	128×4096×4096	10	98.541	97.539–98.784
1	bf16_sparse_2of4	1×4096×4096	10	0.010	0.010–0.011
1	nvfp4	4096×4096×4096	10	317.672	308.915–320.311

节点	精度	M×N×K	轮次	中位TFLOP/s	观测范围
1	fp16_sparse_2of4	1×4096×4096	10	0.010	0.010—0.010
1	bf16_sparse_2of4	128×4096×4096	10	1.285	1.245—1.312
1	fp8_e4m3	4096×4096×4096	10	175.027	170.906—176.635
1	fp16_sparse_2of4	128×4096×4096	10	1.305	1.271—1.314
1	fp16_sparse_2of4	4096×4096×4096	10	33.868	32.344—34.901
1	fp8_e4m3	1×4096×4096	10	0.464	0.463—0.465
1	fp8_e4m3	128×4096×4096	10	116.633	115.258—117.238

15 · 附录C：测试代码与数据归档索引

本附录保留原研究的代码与数据归档索引。GitHub项目发布了主要算法、测量表、方案与完整报告；原始HTTP载荷、大型轨迹、生产控制器和完整本机文件目录不随仓库分发。归档路径是研究来源索引，不是本HTML的可点击附件。

文件索引共 **50,430 项**；扫描完成时间（UTC）：2026-10-17T08:58:51.005978+00:00

表 15-01 附录C：测试代码与数据归档索引

内容	归档路径
本轮测试根目录	export/qwen38_perf_p3_20261014_0905/
模型、题库与方案来源根目录	export/qwen38_abliterated_eval_20261014_mtp/
当前执行测试计划	export/qwen38_perf_p3_20261014_0905/test_plan/test-plan.zh.html
可搜索的完整文件清单	export/qwen38_perf_p3_20261014_0905/reports/artifact-index.zh.html
完整路径清单（CSV）	export/qwen38_perf_p3_20261014_0905/reports/artifact-index.csv
完整路径与元数据（JSON）	export/qwen38_perf_p3_20261014_0905/reports/artifact-index.json

测试代码

负载构造与请求执行

表 15-02 负载构造与请求执行

内容	归档路径
length_plan.py	export/qwen38_perf_p3_20261014_0905/length_plan.py
length_runner.py	export/qwen38_perf_p3_20261014_0905/length_runner.py
length_rejections.py	export/qwen38_perf_p3_20261014_0905/length_rejections.py
prepare_performance.py	export/qwen38_perf_p3_20261014_0905/prepare_performance.py
business_plan.py	export/qwen38_perf_p3_20261014_0905/business_plan.py
refine_business_plan.py	export/qwen38_perf_p3_20261014_0905/refine_business_plan.py
runner.py	export/qwen38_perf_p3_20261014_0905/runner.py
driver.py	export/qwen38_perf_p3_20261014_0905/driver.py
business_runner.py	export/qwen38_perf_p3_20261014_0905/business_runner.py
extended.py	export/qwen38_perf_p3_20261014_0905/extended.py
arrival.py	export/qwen38_perf_p3_20261014_0905/arrival.py

监控与运行管理

表 15-03 监控与运行管理

内容	归档路径
cache_runner.py	export/qwen38_perf_p3_20261014_0905/cache_runner.py
cache_counters.py	export/qwen38_perf_p3_20261014_0905/cache_counters.py
collector.py	export/qwen38_perf_p3_20261014_0905/collector.py
public_monitor.py	export/qwen38_perf_p3_20261014_0905/public_monitor.py
hardware_diag.py	export/qwen38_perf_p3_20261014_0905/hardware_diag.py
observe_tunnel.py	export/qwen38_perf_p3_20261014_0905/observe_tunnel.py
supervise.py	export/qwen38_perf_p3_20261014_0905/supervise.py
recover.py	export/qwen38_perf_p3_20261014_0905/recover.py
continuation.py	export/qwen38_perf_p3_20261014_0905/continuation.py
cf_retry.py	export/qwen38_perf_p3_20261014_0905/cf_retry.py
terminal_review.py	export/qwen38_perf_p3_20261014_0905/terminal_review.py
incident_report.py	export/qwen38_perf_p3_20261014_0905/incident_report.py
common.py	export/qwen38_perf_p3_20261014_0905/common.py

统计、计数与费用核对

表 15-04 统计、计数与费用核对

内容	归档路径
cache_analysis.py	export/qwen38_perf_p3_20261014_0905/cache_analysis.py
analyze.py	export/qwen38_perf_p3_20261014_0905/analyze.py
metrics.py	export/qwen38_perf_p3_20261014_0905/metrics.py
origin.py	export/qwen38_perf_p3_20261014_0905/origin.py
reconcile.py	export/qwen38_perf_p3_20261014_0905/reconcile.py
business_results.py	export/qwen38_perf_p3_20261014_0905/business_results.py
report_model.py	export/qwen38_perf_p3_20261014_0905/report_model.py
report_diagnostics.py	export/qwen38_perf_p3_20261014_0905/report_diagnostics.py
report_cost_model.py	export/qwen38_perf_p3_20261014_0905/report_cost_model.py

报告与可视化

表 15-05 报告与可视化

内容	归档路径
report_benchmarks.py	export/qwen38_perf_p3_20261014_0905/report_benchmarks.py

内容	归档路径
report_gpu_system.py	export/qwen38_perf_p3_20261014_0905/report_gpu_system.py
system_figures.py	export/qwen38_perf_p3_20261014_0905/system_figures.py
integrate_system_plan.py	export/qwen38_perf_p3_20261014_0905/integrate_system_plan.py
length_analysis.py	export/qwen38_perf_p3_20261014_0905/length_analysis.py
report_length.py	export/qwen38_perf_p3_20261014_0905/report_length.py
length_figures.py	export/qwen38_perf_p3_20261014_0905/length_figures.py
cache_plan.py	export/qwen38_perf_p3_20261014_0905/cache_plan.py
report_cache.py	export/qwen38_perf_p3_20261014_0905/report_cache.py
cache_figures.py	export/qwen38_perf_p3_20261014_0905/cache_figures.py
report_endpoint_details.py	export/qwen38_perf_p3_20261014_0905/report_endpoint_details.py
report_emphasis.py	export/qwen38_perf_p3_20261014_0905/report_emphasis.py
build_report.py	export/qwen38_perf_p3_20261014_0905/build_report.py
plots.py	export/qwen38_perf_p3_20261014_0905/plots.py
research_figures.py	export/qwen38_perf_p3_20261014_0905/research_figures.py
diagnostic_figures.py	export/qwen38_perf_p3_20261014_0905/diagnostic_figures.py
report_foundations.py	export/qwen38_perf_p3_20261014_0905/report_foundations.py
report_measurements.py	export/qwen38_perf_p3_20261014_0905/report_measurements.py
report_narrative.py	export/qwen38_perf_p3_20261014_0905/report_narrative.py
report_results_expansion.py	export/qwen38_perf_p3_20261014_0905/report_results_expansion.py
report_returns.py	export/qwen38_perf_p3_20261014_0905/report_returns.py
report_editorial.py	export/qwen38_perf_p3_20261014_0905/report_editorial.py
build_reviewed_plan.py	export/qwen38_perf_p3_20261014_0905/build_reviewed_plan.py
report_labels.py	export/qwen38_perf_p3_20261014_0905/report_labels.py
report_chart_catalog.py	export/qwen38_perf_p3_20261014_0905/report_chart_catalog.py
report_cost_widget.py	export/qwen38_perf_p3_20261014_0905/report_cost_widget.py
report_appendix.py	export/qwen38_perf_p3_20261014_0905/report_appendix.py

离线验证与其他脚本

表 15-06 离线验证与其他脚本

内容	归档路径
boundary_review.py	export/qwen38_perf_p3_20261014_0905/boundary_review.py
cf_edge_review.py	export/qwen38_perf_p3_20261014_0905/cf_edge_review.py
engine_split_report.py	export/qwen38_perf_p3_20261014_0905/engine_split_report.py

内容	归档路径
finalize_hardware.py	export/qwen38_perf_p3_20261014_0905/finalize_hardware.py
gpu_system_bench.py	export/qwen38_perf_p3_20261014_0905/gpu_system_bench.py
gpu_system_collectives.py	export/qwen38_perf_p3_20261014_0905/gpu_system_collectives.py
gpu_system_control.py	export/qwen38_perf_p3_20261014_0905/gpu_system_control.py
gpu_system_guard.py	export/qwen38_perf_p3_20261014_0905/gpu_system_guard.py
gpu_system_observer.py	export/qwen38_perf_p3_20261014_0905/gpu_system_observer.py
gpu_system_preflight.py	export/qwen38_perf_p3_20261014_0905/gpu_system_preflight.py
gpu_system_remote.py	export/qwen38_perf_p3_20261014_0905/gpu_system_remote.py
hardware_collective_analysis.py	export/qwen38_perf_p3_20261014_0905/hardware_collective_analysis.py
hardware_completion_report.py	export/qwen38_perf_p3_20261014_0905/hardware_completion_report.py
hardware_extension_figures.py	export/qwen38_perf_p3_20261014_0905/hardware_extension_figures.py
hardware_h200_report.py	export/qwen38_perf_p3_20261014_0905/hardware_h200_report.py
hardware_partial.py	export/qwen38_perf_p3_20261014_0905/hardware_partial.py
quarantine.py	export/qwen38_perf_p3_20261014_0905/quarantine.py
redraw_report_figures.py	export/qwen38_perf_p3_20261014_0905/redraw_report_figures.py
report_coverage.py	export/qwen38_perf_p3_20261014_0905/report_coverage.py
report_gap_completion.py	export/qwen38_perf_p3_20261014_0905/report_gap_completion.py
report_overview.py	export/qwen38_perf_p3_20261014_0905/report_overview.py
report_review.py	export/qwen38_perf_p3_20261014_0905/report_review.py
report_visual_layout.py	export/qwen38_perf_p3_20261014_0905/report_visual_layout.py
report_visual_theme.py	export/qwen38_perf_p3_20261014_0905/report_visual_theme.py
review_figures.py	export/qwen38_perf_p3_20261014_0905/review_figures.py
test_arrival.py	export/qwen38_perf_p3_20261014_0905/test_arrival.py
test_business.py	export/qwen38_perf_p3_20261014_0905/test_business.py
test_cache_diagnostics.py	export/qwen38_perf_p3_20261014_0905/test_cache_diagnostics.py
test_cf_retry.py	export/qwen38_perf_p3_20261014_0905/test_cf_retry.py
test_common_atomic.py	export/qwen38_perf_p3_20261014_0905/test_common_atomic.py
test_incident.py	export/qwen38_perf_p3_20261014_0905/test_incident.py
test_metrics.py	export/qwen38_perf_p3_20261014_0905/test_metrics.py
test_public_monitor.py	export/qwen38_perf_p3_20261014_0905/test_public_monitor.py
test_quarantine.py	export/qwen38_perf_p3_20261014_0905/test_quarantine.py
test_recover.py	export/qwen38_perf_p3_20261014_0905/test_recover.py
test_report_diagnostics.py	export/qwen38_perf_p3_20261014_0905/test_report_diagnostics.py

内容	归档路径
test_runner.py	export/qwen38_perf_p3_20261014_0905/test_runner.py
test_terminal_review.py	export/qwen38_perf_p3_20261014_0905/test_terminal_review.py
validate_h200_comparison.py	export/qwen38_perf_p3_20261014_0905/validate_h200_comparison.py
verify_scientific_report.py	export/qwen38_perf_p3_20261014_0905/verify_scientific_report.py
verify_visual_system.py	export/qwen38_perf_p3_20261014_0905/verify_visual_system.py

共享代码、执行快照与运行环境

表 15-07 共享代码、执行快照与运行环境

内容	归档路径
项目配置加载入口	src/insightloop/config/loader.py
ClickHouse 只读查询客户端入口	src/insightloop/runtime/clickhouse.py
ClickHouse 客户端实现	src/insightloop/datasources/clickhouse.py
核心测试执行源码快照	export/qwen38_perf_p3_20261014_0905/evidence/executor_core/
业务测试冻结源码	export/qwen38_perf_p3_20261014_0905/evidence/business_amendment/
执行源码与配置证据总目录	export/qwen38_perf_p3_20261014_0905/evidence/
测试 Python 环境	/tmp/gp-qwen38-eval/bin/python
报告 Python 环境	/tmp/growthpulse-morphic-report-311/bin/python
项目依赖声明	pyproject.toml
项目依赖锁定清单	uv.lock
来源环境版本记录	export/qwen38_abliterated_eval_20261014_mtp/sources/environment_versions.json

输入数据、抽样与固定请求清单

表 15-08 输入数据、抽样与固定请求清单

内容	归档路径
GPU与系统模块设计清单	export/qwen38_perf_p3_20261014_0905/plans/gpu_system/manifest.json
GPU方法官方资料快照	export/qwen38_perf_p3_20261014_0905/evidence/gpu_system_revision/sources/
长度扩展请求、参数与散列	export/qwen38_perf_p3_20261014_0905/plans/length_expansion/
扩展长度逐请求分析	export/qwen38_perf_p3_20261014_0905/reports/length-observations.csv
框架方法原始资料	export/qwen38_perf_p3_20261014_0905/evidence/length_expansion/sources/
六题集固定 60 条输入	export/qwen38_perf_p3_20261014_0905/protocol/workloads.jsonl
题目抽样与长度清单	export/qwen38_perf_p3_20261014_0905/protocol/workload_manifest.json
基准规模与实际选样核对	export/qwen38_perf_p3_20261014_0905/evidence/benchmark_documentation/inventory.json
原始题库总目录	export/qwen38_abliterated_eval_20261014_mtp/datasets/

内容	归档路径
MMLU-Pro 原始数据	export/qwen38_abliterated_eval_20261014_mtp/datasets/TIGER-Lab__MMLU-Pro/
MATH-500 原始数据	export/qwen38_abliterated_eval_20261014_mtp/datasets/HuggingFaceH4__MATH-500/
GSM8K 原始数据	export/qwen38_abliterated_eval_20261014_mtp/datasets/openai__gsm8k/
IFEval 原始输入	export/qwen38_abliterated_eval_20261014_mtp/sources/instruction_following_eval/data/input_data.jsonl
HumanEval+ 原始数据	export/qwen38_abliterated_eval_20261014_mtp/datasets/humaneval_plus.jsonl
MBPP+ 原始数据	export/qwen38_abliterated_eval_20261014_mtp/datasets/mbpp_plus.jsonl
长度实验文本语料	export/qwen38_perf_p3_20261014_0905/plans/corpus.txt
长度实验分词序列	export/qwen38_perf_p3_20261014_0905/plans/corpus_tokens.json
缓存专项固定请求与设计参数	export/qwen38_perf_p3_20261014_0905/plans/cache_diagnostics/
完整请求计划目录	export/qwen38_perf_p3_20261014_0905/plans/
核心实验顺序与种子	export/qwen38_perf_p3_20261014_0905/plans/schedule.json
固定请求文件散列	export/qwen38_perf_p3_20261014_0905/plans/frozen.json
业务及前缀比例请求目录	export/qwen38_perf_p3_20261014_0905/plans/business/
业务形态与样本量清单	export/qwen38_perf_p3_20261014_0905/plans/business/manifest.json
模型配置、分词器和聊天模板	export/qwen38_abliterated_eval_20261014_mtp/sources/model/
模型与数据来源散列	export/qwen38_abliterated_eval_20261014_mtp/sources/manifest.json
完整测试方案与参考文档	export/qwen38_abliterated_eval_20261014_mtp/test_plan/

原始响应、监控与运行记录

表 15-09 原始响应、监控与运行记录

内容	归档路径
逐请求原始数据总目录	export/qwen38_perf_p3_20261014_0905/runs/requests/
区组执行记录	export/qwen38_perf_p3_20261014_0905/runs/blocks/
区组前后资源边界	export/qwen38_perf_p3_20261014_0905/runs/boundaries/
请求登记与预算记录	export/qwen38_perf_p3_20261014_0905/runs/ledger.json
按逻辑任务聚合的结果	export/qwen38_perf_p3_20261014_0905/runs/logical_outcomes/
节点仪表盘原始采样	export/qwen38_perf_p3_20261014_0905/monitor/sparkdash.jsonl
引擎与操作系统原始采样	export/qwen38_perf_p3_20261014_0905/monitor/engine-os.jsonl
客户端运行采样	export/qwen38_perf_p3_20261014_0905/monitor/client.jsonl
缓存专项窗口与实际等待	export/qwen38_perf_p3_20261014_0905/runs/cache_windows/
缓存计数与新鲜度原始采样	export/qwen38_perf_p3_20261014_0905/monitor/cache_counters.jsonl
缓存来源与执行核验	export/qwen38_perf_p3_20261014_0905/evidence/cache_evaluation/
全部运行日志与回执	export/qwen38_perf_p3_20261014_0905/runs/

内容	归档路径
监控文件总目录	export/qwen38_perf_p3_20261014_0905/monitor/
精确请求账单	export/qwen38_perf_p3_20261014_0905/evidence/billing_latest.json
配置、计数与来源证据	export/qwen38_perf_p3_20261014_0905/evidence/

单次请求文件结构

以下展示一个已保存请求的完整路径；其他请求采用相同目录结构，具体路径均可在完整清单中检索。

表 15–10 单次请求文件结构

内容	归档路径
实际发送的输入与参数	export/qwen38_perf_p3_20261014_0905/runs/requests/P0_0_HumanEval_51/request.json
发送起始记录	export/qwen38_perf_p3_20261014_0905/runs/requests/P0_0_HumanEval_51/started.json
原始服务器发送事件响应流	export/qwen38_perf_p3_20261014_0905/runs/requests/P0_0_HumanEval_51/response.sse
解析后的流式事件	export/qwen38_perf_p3_20261014_0905/runs/requests/P0_0_HumanEval_51/events.jsonl
片段接收时序	export/qwen38_perf_p3_20261014_0905/runs/requests/P0_0_HumanEval_51/chunks.jsonl
最终状态、用量与时延	export/qwen38_perf_p3_20261014_0905/runs/requests/P0_0_HumanEval_51/result.json

统计结果、图表和交付报告

表 15–11 统计结果、图表和交付报告

内容	归档路径
缓存专项完整分析	export/qwen38_perf_p3_20261014_0905/reports/cache_analysis.json
缓存条件结果	export/qwen38_perf_p3_20261014_0905/reports/cache_conditions.csv
缓存逐请求结果	export/qwen38_perf_p3_20261014_0905/reports/cache_requests.csv
缓存时间窗口	export/qwen38_perf_p3_20261014_0905/reports/cache_time_windows.csv
缓存字段覆盖	export/qwen38_perf_p3_20261014_0905/reports/cache_field_coverage.csv
首次与重复配对	export/qwen38_perf_p3_20261014_0905/reports/cache_reuse_pairs.csv
逐请求分析明细	export/qwen38_perf_p3_20261014_0905/reports/requests.csv
完整统计	export/qwen38_perf_p3_20261014_0905/reports/analysis.json
连续完整区组统计口径	export/qwen38_perf_p3_20261014_0905/reports/presentation.json
成本、长度与资源关联	export/qwen38_perf_p3_20261014_0905/reports/diagnostics.json
按负载核对的费用	export/qwen38_perf_p3_20261014_0905/reports/cohort–costs.csv
同区组节点资源	export/qwen38_perf_p3_20261014_0905/reports/cohort–resources.csv
长度矩阵	export/qwen38_perf_p3_20261014_0905/reports/length–metrics.csv
设备与电费情景	export/qwen38_perf_p3_20261014_0905/reports/cost–scenarios.csv
投资回报与回本情景	export/qwen38_perf_p3_20261014_0905/reports/investment–scenarios.csv

内容	归档路径
业务与缓存测量	export/qwen38_perf_p3_20261014_0905/reports/business_results.json
硬件时序	export/qwen38_perf_p3_20261014_0905/reports/hardware.csv
引擎与操作系统时序	export/qwen38_perf_p3_20261014_0905/reports/engine-os.csv
达标吞吐	export/qwen38_perf_p3_20261014_0905/reports/goodput.csv
中文报告（HTML）	export/qwen38_perf_p3_20261014_0905/reports/report.zh.html
中文报告（MD）	export/qwen38_perf_p3_20261014_0905/reports/report.zh.md
中文报告（PDF）	export/qwen38_perf_p3_20261014_0905/reports/report.zh.pdf
英文报告（HTML）	export/qwen38_perf_p3_20261014_0905/reports/report.en.html
英文报告（MD）	export/qwen38_perf_p3_20261014_0905/reports/report.en.md
英文报告（PDF）	export/qwen38_perf_p3_20261014_0905/reports/report.en.pdf
独立 SVG/PNG 图表与报告总目录	export/qwen38_perf_p3_20261014_0905/reports/
报告校验记录	export/qwen38_perf_p3_20261014_0905/reports/scientific_qa.json

文件索引按扫描时点生成；运行中的文件可能继续增长。索引不包含凭据、锁文件、临时文件、字节码及第三方依赖安装目录；来源根目录内的历史材料不自动纳入本轮性能统计。

硬件补测：代码、数据与复算路径

表 15-12 硬件补测：代码、数据与复算路径

用途	磁盘绝对路径
本批指令、范围与固定截止	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/authorization.json
基础条件与保护规则	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/manifest.json
扩展条件、重复及源码散列	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/extensions_manifest.json
服务器内网有界调度	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/remote_coordinator.py
外部状态采集与阶段归档	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/collect.py
基础计算 / 带宽 / 算子及持续负载	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/gpu_system_bench.py
扩展实验执行与数值校验	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/gpu_extensions.py
通用乘加、指针、共享内存等CUDA源码	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/kernels.cu
计算 / 通信四臂配对	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/gpu_overlap.py
双节点分阶段原始采样、计时和日志	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/raw
逐条CSV、汇总、覆盖与能量计算	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/analysis
离线报告更新与校验	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/finalize.py

用途	磁盘绝对路径
停服状态捕获、异常恢复与日志脱敏	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/service_custodian.py
最终双节点服务恢复核验	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/service_restoration_verification.json
源码散列、启动与验证回执	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/evidence
温度自动退避与事件记录	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/thermal_backoff.py
生效温度阈值与恢复规则	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/thermal_backoff_policy.json
有限混合负载队列、重试与终态验证	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/resume_thermal_retry.py
失败分类与重试准入	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/retry_policy.py
重试调度实时状态	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/retry_supervisor_status.json
续测授权、启动、失败判定与恢复证据	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/evidence/thermal_retry_continuation
夜间收尾、归档与报告重试及覆盖核验	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/overnight_finish.py
有界计数器诊断复核	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/counter_retry_remote.py
完成覆盖、诊断计数器及终态验证证据	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/evidence/overnight_completion
固定计数器探针的初始化错误定位	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/evidence/overnight_completion/diagnose_counter_verbose.py
保留原内核的CUDA状态诊断入口	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/evidence/overnight_completion/counter_probe_diagnostic.cu
诊断后服务核验与本轮采样结束	export/qwen38_perf_p3_20261014_0905/hardware_unloaded_confirmed_20261016/evidence/overnight_completion/close_observers.py

远端双节点目录：/home/benchmark/infron-benchmarks/hardware_unloaded_confirmed_20261016

H200逐项对照代码与规格/固定条件证据：export/qwen38_perf_p3_20261014_0905/hardware_h200_report.py · export/qwen38_perf_p3_20261014_0905/evidence/h200_comparison

驻留条件证据：export/qwen38_perf_p3_20261014_0905/hardware_completion_20261016

停服预检与控制网络配置证据：export/qwen38_perf_p3_20261014_0905/hardware_unloaded_20261016

独立引擎实验代码与原始数据

本机根目录：export/qwen38_perf_p3_20261014_0905/engine_split_20261016

执行器：engine_probe.py、run_engine.py；采集器：collect_engine.py；离线分析：analyze_engine.py；原始请求 / 响应与GPU时间线：raw/node0、raw/node1；计时表：analysis/*.csv；已安装源码快照：evidence/source。远端目录：/home/benchmark/infron-benchmarks/engine-split-20261016

SGLang完整启动与生效参数

配置记录时间（UTC）：2026-10-14T09:08:19.004649+00:00。 下表区分进程启动参数与引擎解析后的生效值；未显式传入的值来自引擎配置快照。

表 15-13 SGLang完整启动与生效参数

项目	记录值
SGLang版本	0.5.21
运行入口	/home/benchmark/Projects/qwen38/.sglang/bin/python3 -m sglang.launch_server
节点与服务名	tp_size=2; nnodes=2; node_rank=0 / 1; served_model_name=qwen38-flash
服务与分布式初始化	host=0.0.0.0; port=8000; dist_init_addr=192.0.2.10:5000
预填充与并发	chunked_prefill_size=8192; max_prefill_tokens=16384; max_running_requests=48
KV缓存页与回收策略	page_size=64; kv_cache_dtype=auto; disable_radix_cache=false; radix_eviction_policy=lru
调度与CUDA Graph	schedule_policy=fcfs; schedule_conservativeness=1.0; disable_overlap_schedule=false; enable_mixed_chunk=false; disable_cuda_graph=false
计算后端	attention_backend=flashinfer; sampling_backend=flashinfer; moe_runner_backend=flashinfer_cutlass; moe_a2a_backend=none; --fp4-gemm-backend flashinfer_cutlass
MTP启动值 / 生效值	--speculative-algorithm NEXTN → speculative_algorithm=EAGLE; num_steps=3; eagle_topk=1; num_draft_tokens=4
输出解析器	reasoning_parser=qwen3; tool_call_parser=qwen3_coder
指标与缓存字段	enable_metrics=true; enable_cache_report=false
其他生效配置	trust_remote_code=true; random_seed=523471992

节点0启动命令（认证值已遮盖）；节点1使用相同参数，--node-rank 1。

```
MODEL_PATH=/home/benchmark/.cache/huggingface/hub/
MODEL_PATH+=models--dealignai--Qwen3.8-Flash-Next-ABLITERATED-NVFP4/
MODEL_PATH+=snapshots/be794b990578ef3031eccf9f28e675a289a09ee9/
/home/benchmark/Projects/qwen38/.sglang/bin/python3 -m sglang.launch_server \
  --model-path "$MODEL_PATH" \
  --served-model-name qwen38-flash \
  --api-key '[REDACTED]' \
  --quantization modelopt_fp4 \
  --fp4-gemm-backend flashinfer_cutlass \
  --tp 2 \
  --nnodes 2 \
  --node-rank 0 \
  --dist-init-addr 192.0.2.10:5000 \
  --page-size 64 \
  --context-length 262144 \
  --mem-fraction-static 0.75 \
  --reasoning-parser qwen3 \
  --speculative-algorithm NEXTN \
  --speculative-num-steps 3 \
  --speculative-eagle-topk 1 \
  --speculative-num-draft-tokens 4 \
  --tool-call-parser qwen3_coder \
```

```
  --trust-remote-code \
  --host 0.0.0.0 \
  --port 8000 \
  --enable-metrics
```

缓存复用开关与缓存用量字段开关是两个参数：`disable_radix_cache=false` 表示允许前缀复用，`enable_cache_report=false` 表示该配置未启用逐请求缓存用量字段。

表 15–14 SGLang完整启动与生效参数

硬件测量窗口的控制网络	生效值与结果范围
节点间控制地址	SGLANG_HOST_IP=192.0.2.10 / 192.0.2.11
推理配置核验	恢复后的模型路径、版本、TP、MTP、上下文及缓存核心配置与停服前一致；公网与独立引擎性能数据均采集于此次网络绑定之前。

节点0配置与命令 · 节点1命令

独立补充实验：代码、原始证据与分析

表 15–15 独立补充实验：代码、原始证据与分析

内容	归档路径
缺口审计	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/gap_audit.zh.md
固定协议	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/manifest.json
费用上限修订	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/budget_amendment.json
持续调度	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/supervisor.py
原生固定输出	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/native_completion.py
配对剖析与缓存	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/profile_completion.py
公网执行	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/public_completion.py
硬件协调	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/hardware_coordinator.py
双精度矩阵	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/fp64_completion.py
计数器核函数	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/counter_workload.cu
计数器执行	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/hardware_worker.py
离线分析	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/analyze_completion.py
统计汇总	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/analysis/summary.json
原生请求CSV	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/analysis/native_requests.csv
节点0原始证据	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/raw/node0
节点1原始证据	export/qwen38_perf_p3_20261014_0905/gap_completion_20261017/raw/node1